

Universidade Federal do Pará
Campus Universitário de Tucuruí
Núcleo de Desenvolvimento Amazônico em Engenharia
Programa de Pós-Graduação em Computação Aplicada

Aprendizagem profunda aplicada ao diagnóstico de malária por imagem utilizando transferência de aprendizagem

RAPHAEL SARAIVA DE SOUSA

Tucuruí - PA
2026



Universidade Federal do Pará
Campus Universitário de Tucuruí
Núcleo de Desenvolvimento Amazônico em Engenharia
Programa de Pós-Graduação em Computação Aplicada

Aprendizagem profunda aplicada ao diagnóstico de malária por imagem utilizando transferência de aprendizagem

RAPHAEL SARAIVA DE SOUSA

Defesa de mestrado apresentada ao Colegiado do Programa de Pós-Graduação em Computação Aplicada do Núcleo de Desenvolvimento Amazônico em Engenharia da Universidade Federal do Pará como parte dos requisitos para a obtenção do título de mestre em computação aplicada.

Orientador: Prof. Dr. Raphael Barros Teixeira

Tucuruí - PA
2026

Dados Internacionais de Catalogação na Publicação (CIP) de acordo com ISBD
Sistema de Bibliotecas da Universidade Federal do Pará
Gerada automaticamente pelo módulo Ficat, mediante os dados fornecidos pelo(a) autor(a)

S725a Sousa, Raphael Saraiva de.
Aprendizagem profunda aplicada ao diagnóstico de malária por imagem utilizando transferência de aprendizagem / Raphael Saraiva de Sousa. — 2026.
89 f. : il. color.

Orientador(a): Prof. Dr. Raphael Barros Teixeira
Dissertação (Mestrado) - Universidade Federal do Pará, Núcleo de Desenvolvimento Amazônico em Engenharia, Mestrado Profissional em Computação Aplicada, Tucuruí, 2026.

1. Diagnóstico de Malária. 2. Visão Computacional. 3. Aprendizagem por transferência. I. Título.

CDD 004

RAPHAEL SARAIVA DE SOUSA

Aprendizagem profunda aplicada ao diagnóstico de malária por imagem utilizando transferência de aprendizagem

Defesa de mestrado apresentada ao Colegiado do Programa de Pós-Graduação em Computação Aplicada do Núcleo de Desenvolvimento Amazônico em Engenharia da Universidade Federal do Pará como parte dos requisitos para a obtenção do título de mestre em computação aplicada.

Data da defesa: 02 de Fevereiro de 2026.
Resultado:

Banca examinadora:

Prof. Dr. Raphael Barros Teixeira
Orientador - UFPA/NDAE/PPCA

gov.br Documento assinado digitalmente
OTAVIO NOURA TEIXEIRA
Data: 06/03/2026 11:47:45-0300
Verifique em https://validar.iti.gov.br

Prof. Dr. Otávio Noura Teixeira
Avaliador Interno - UFPA/NDAE/PPCA

gov.br Documento assinado digitalmente
ADRIANA ROSA GARCEZ CASTRO
Data: 06/03/2026 17:00:49-0300
Verifique em https://validar.iti.gov.br

Profa. Dra. Adriana Rosa Garcez Castro
Avaliador Externo - ITEC / UFPA

Resumo

Este estudo investiga o uso de técnicas avançadas de visão computacional baseadas em aprendizado profundo para a detecção automatizada da malária em esfregaços sanguíneos. O diagnóstico convencional da doença, realizado por meio da análise microscópica por especialistas, demanda tempo e recursos especializados, podendo comprometer a agilidade na tomada de decisões clínicas. Para superar esses desafios, este trabalho propõe a aplicação de redes neurais convolucionais, com ênfase na transferência de aprendizagem utilizando os modelos *ResNet50*, *EfficientNetB7* e *MobileNetV3*. O estudo emprega um banco de dados composto por 27.558 imagens reais de células parasitadas e não infectadas, permitindo a construção de um modelo robusto para classificação automatizada. A avaliação de desempenho foi realizada por meio de experimentos comparativos entre os modelos e validação cruzada *k-fold*, garantindo a confiabilidade dos resultados. Os achados demonstram que a abordagem proposta alcança uma precisão aproximada de 98% na detecção da malária, destacando-se como uma ferramenta promissora para apoiar o diagnóstico clínico e otimizar estratégias de controle da doença.

Palavras-chave: Diagnóstico de Malária; Visão Computacional; Aprendizagem por transferência.

Abstract

This study investigates the use of advanced computer vision techniques based on deep learning for the automated detection of malaria in blood smear images. Conventional diagnosis of the disease, performed through microscopic analysis by specialists, is time-consuming and requires specialized resources, which may compromise the timeliness of clinical decision-making. To address these challenges, this work proposes the application of convolutional neural networks, with an emphasis on transfer learning using the ResNet50, EfficientNetB7, and MobileNetV3 models. The study employs a dataset composed of 27,558 real images of parasitized and uninfected cells, enabling the development of a robust model for automated classification. Performance evaluation was conducted through comparative experiments among the models and k-fold cross-validation, ensuring the reliability of the results. The findings demonstrate that the proposed approach achieves an accuracy of approximately 98% in malaria detection, highlighting its potential as a promising tool to support clinical diagnosis and optimize disease control strategies.g tool to support clinical diagnosis and optimize disease control strategies.

Key words: Malaria Diagnosis; Computer Vision; Transfer Learning..

Lista de ilustrações

Figura 1 – Ilustração do Vetor de Transmissão: (a) mosquito *Anopheles*, (b) técnica de esfregaço sanguíneo e (c) microscópio eletrônico. 8
Figura 2 – Ilustração de uma Rede Multilayer Perceptron. 11
Figura 3 – Rede Neural Convolucional e suas respectivas camadas. 13
Figura 4 – Demonstração do funcionamento das operações de pooling. 13
Figura 5 – Comparativo entre as abordagens de aprendizado de máquina e o aprendizado por transferência. 15
Figura 6 – Arquitetura ResNet - 50. 16
Figura 7 – Arquitetura EfficientNet B7 17
Figura 8 – Arquitetura MobileNetV3 19
Figura 9 – Demonstração da técnica de Aumento de Dados 21
Figura 10 – A imagem apresenta um comparativo entre partições clássicas e validação cruzada na divisão de um conjunto de dados para treinamento e teste de modelos de aprendizado de máquina. 22
Figura 11 – Fluxo Geral 27
Figura 12 – Imagens microscópicas de células sanguíneas provenientes do *Dataset Malaria Cells*. 29
Figura 13 – Validação Cruzada utilizada no Experimento 32
Figura 14 – Desempenho do modelo ResNet50 por *fold* 36
Figura 15 – Matrizes de confusão da ResNet50 por *fold* 39
Figura 16 – Comparativo das métricas de desempenho da arquitetura ResNet-50 . . 42
Figura 17 – Evolução das métricas de treinamento da EfficientNet-B7 por *fold* . . . 45
Figura 18 – Matrizes de confusão da EfficientNet-B7 por *fold* 48
Figura 19 – Comparativo das métricas de desempenho da arquitetura EfficientNet-B7 51
Figura 20 – Desempenho do modelo MobileNetV3 por fold 54
Figura 21 – Matrizes de confusão do modelo MobileNetV3 nos cinco *folds* da validação cruzada 58
Figura 22 – Comparativo - métricas - MobileNetV3 61
Figura 23 – Evolução da perda e da acurácia da CNN Simples ao longo das épocas. 66
Figura 24 – Matriz de confusão da CNN Simples no conjunto de teste. 67

Lista de tabelas

Tabela 1 – Distribuição de casos de malária nos municípios do Pará - janeiro a outubro de 2024. 1
Tabela 2 – Matriz de confusão 23
Tabela 3 – Parâmetros das Transformações Aplicadas 30
Tabela 4 – Configuração do treinamento dos modelos 33
Tabela 5 – Indicadores de desempenho utilizados na avaliação do modelo de classificação 34
Tabela 6 – Métricas de desempenho da ResNet-50 por *fold* 41
Tabela 7 – Comparação das métricas de desempenho da ResNet-50 entre conjunto de validação e teste 43
Tabela 8 – Métricas de desempenho da EfficientNet-B7 por *fold* 50
Tabela 9 – Comparação das métricas da EfficientNet-B7 entre validação e teste . . 52
Tabela 10 – Métricas de desempenho do modelo MobileNetV3 por *fold* 60
Tabela 11 – Comparação das métricas do MobileNetV3 entre validação e teste . . . 62
Tabela 12 – Comparativo da maior acurácia de validação por *fold* 63
Tabela 13 – Hiperparâmetros e parâmetros estruturais utilizados no modelo CNN. . 65
Tabela 14 – Métricas de desempenho da CNN Simples calculadas a partir da matriz de confusão. 68
Tabela 15 – Comparação do melhor desempenho de validação entre os modelos avaliados 69

Sumário

Resumo i

Abstract ii

Lista de ilustrações iii

Lista de tabelas iv

Sumário v

1 INTRODUÇÃO 1
1.1 Contextualização 1
1.2 Motivação 1
1.3 Objetivos 3
1.4 Questão da Pesquisa 4
1.5 Organização do trabalho 4

2 REVISÃO DA LITERATURA 5

3 FUNDAMENTAÇÃO TEÓRICA 7
3.1 Malária 7
3.2 Dataset 8
3.2.1 Estrutura do Diretório do Dataset 9
3.3 Aprendizado de Máquina: Aprendizagem Profunda e Visão Computacional 10
3.4 Redes Neurais artificiais 10
3.5 Redes Neurais Convolucionais 12
3.6 Aprendizagem por Transferência 14
3.6.1 Resnet-50 15
3.6.2 EfficientNetB7 17
3.6.3 MobileNetV3 18
3.7 Aumento de Dados 20
3.8 Validação Cruzada 21
3.9 Métricas 23

4 METODOLOGIA 26

4.1 Fluxo de Trabalho Proposto . . . 27
4.2 Conjunto de dados . . . 28
4.2.1 Pré-processamento com aumento de dados . . . 29
4.3 Validação Cruzada . . . 31
4.4 Treinamento dos modelos . . . 32
4.5 Métricas de Avaliação . . . 33

5 RESULTADOS E DISCUSSÃO . . . 35
5.1 Arquitetura ResNet50 . . . 35
5.1.1 Análise de desempenho dos modelos por *fold* . . . 35
5.2 Matriz de Confusão da Arquitetura ResNet50 . . . 38
5.2.1 Análise da matriz de confusão por *fold* . . . 38
5.2.2 Métricas de desempenho por *fold* . . . 40
5.2.3 Análise Comparativa entre validação e conjunto de teste . . . 43
5.3 Arquitetura EfficientNet-B7 . . . 44
5.3.1 Matriz de confusão – EfficientNet-B7 . . . 47
5.3.2 Análise das matrizes de confusão por *fold* . . . 47
5.3.3 Métricas de desempenho por *fold* . . . 49
5.3.4 Análise Comparativa entre validação e teste da EfficientNet-B7 . . . 52
5.3.5 MobileNet-V3 . . . 53
5.3.6 Análise das Matrizes de Confusão por fold . . . 56
5.3.7 Métricas de desempenho por fold . . . 59
5.3.8 Análise Comparativa entre Validação e Teste do MobileNetV3 . . . 62
5.4 Maior acurácia de validação entre os Modelos . . . 63
5.4.1 Arquitetura CNN Simples . . . 64
5.4.1.1 Desempenho da CNN Simples . . . 66
5.4.2 Matriz de Confusão . . . 67
5.4.3 Métricas de Desempenho . . . 67
5.4.4 Análise dos Resultados . . . 68
5.4.5 Discussão dos Resultados . . . 68
5.4.6 Comparação com Arquiteturas . . . 69

6 CONCLUSÃO . . . 71
6.1 Pesquisas Futuras . . . 72

REFERÊNCIAS . . . 74

1 Introdução

1.1 Contextualização

A malária é uma grave doença infecciosa, transmitida aos humanos pelo mosquito Anopheles infectado com o parasita Plasmodium. Em 2024, as Américas reportaram aproximadamente 563 mil casos de malária, evidenciando-se um desafio de saúde pública(PAHO/OMS, 2025).

No Brasil, a malária é uma preocupação de saúde pública, especialmente em algumas regiões do país, onde as condições climáticas e ambientais favorecem a proliferação do mosquito vetor, *Anapholes* (Fundação Oswaldo Cruz, 2023). Apesar dos esforços de controle e prevenção, a alta incidência da malária no Brasil destaca a necessidade de inovação no seu diagnóstico. O método tradicional, pela análise microscópica por técnicos especializados, é limitado pela escassez de recursos, especialmente em áreas endêmicas como a Amazônia. A Tabela 1 apresenta dados recentes em municípios paraenses que somam 94,78% dos casos em 2024 (SESPA, 2024).

Tabela 1 – Distribuição de casos de malária nos municípios do Pará - janeiro a outubro de 2024.

Município (PA)	**Casos**	**% de Casos**
Jacareacanga	7.780	40,01%
Itaituba	4.356	22,40 %
Bagre	2.106	10,82%
Anajás	1.937	9,96%
Chaves	518	2,66 %
Breves	453	2,33%
Alenquer	403	2,07 %
Altamira	345	1,77 %
Oeiras do Pará	281	1,45 %
Oriximina	252	1,30%
Total	18.431	94,77%

Fonte: (SESPA, 2024).

1.2 Motivação

Recentemente, abordagens inovadoras baseadas em aprendizagem profundo (*Deep Learning* - DL) têm sido aplicadas com sucesso ao diagnóstico da malária (PETER; INTELLI-

GENCE, 2021). As Redes Neurais Convolucionais (CNNs) destacam-se pela capacidade de aprender padrões complexos em imagens de esfregaços sanguíneos, possibilitando uma detecção mais eficiente do parasita (TAYLOR; NITSCHKE, 2018). A relevância deste estudo é destacada pela necessidade de melhorias nos métodos de diagnóstico da malária. Técnicas de DL, como as CNNs, podem melhorar a precisão do diagnóstico, com classificadores mais robustos, aplicável em contextos de comunidades não dotadas dos recursos humanos e materiais apropriados ao pronto diagnóstico da doença pelo método convencional.

Nesse contexto, a Visão Computacional(VC) se destaca como um dos pilares essenciais da computação moderna, impulsionada de forma significativa pelas técnicas avançadas de (*Machine Learning* - ML) e DL em áreas onde a análise humana seria extremamente demorada (RUSSEL; NORVIG, 2022), essas técnicas reduzem a necessidade de um esforço humano massivo e repetitivo.

Atualmente, o diagnóstico laboratorial da malária é baseado na gota espessa, na qual o *Plasmodium* é visualizado microscopicamente após coloração pela técnica de Giemsa. Essa técnica possui alta sensibilidade, porém necessita de profissionais treinados para sua realização, objetivando a detecção e diferenciação das espécies de plasmódios (MENDES, 2022).

Com o avanço da Inteligência Artificial (IA), a automação da classificação de imagens biomédicas tem sido amplamente explorada para aumentar a precisão e a eficiência do diagnóstico (SINHA; GUPTA, 2023b). As CNNs têm se mostrado promissoras na análise de imagens médicas, permitindo a detecção automática de padrões visuais em imagens de tecidos e fluidos biológicos. O aprendizado profundo, aliado à técnica de (*Transfer Learning* - TL), possibilita o uso de modelos pré-treinados em grandes bases de dados, reduzindo a necessidade de treinamento extensivo em conjuntos de dados específicos. Este estudo propõe uma abordagem inovadora que utiliza as arquiteturas *ResNet50*, *EfficientNetB7* e *MobileNetV3* para a detecção automatizada de malária em imagens de glóbulos vermelhos. Além disso, são realizadas comparações de desempenho entre os modelos de aprendizado profundo pré-treinados, e emprega-se a validação cruzada *k-fold* para assegurar a robustez e a confiabilidade dos resultados. A justificativa para a escolha dessas técnicas de aprendizado por transferência em imagens médicas pode superar abordagens treinadas do zero. Ao ajustar modelos pré-treinados para a detecção de malária, é possível alcançar maior precisão e sensibilidade na identificação de células infectadas (PENG *et al.*, 2024).

1.3 Objetivos

Investigar a eficácia de modelos avançados de redes neurais convolucionais através das arquiteturas *ResNet50*, *EfficientNetB7* e *MobileNetV3* com uso de técnicas de validação cruzada e métricas quantitativas de desempenho na classificação automatizada de imagens microscópicas de células sanguíneas, visando à identificação precisa e robusta de células infectadas por *Plasmodium*, no apoio ao diagnóstico clínico da doença.

- É importante destacar que:
  - Embora apresente diversos benefícios, a proposta não substitui o diagnóstico realizado por um profissional especialista.
  - O fluxo de trabalho atua como uma ferramenta de suporte, auxiliando os profissionais de saúde na realização de diagnósticos precoces com maior precisão.
- Os objetivos específicos serão:
  1. Implementar e treinar modelos de redes neurais convolucionais (ResNet50, EfficientNetB7 e MobileNetV3) para a tarefa de classificação binária de células sanguíneas como infectadas ou saudáveis.
  2. Realizar a preparação e o pré-processamento do conjunto de dados de imagens microscópicas de sangue, garantindo sua qualidade e compatibilidade com os modelos propostos.
  3. Aplicar validação cruzada estratificada (k-fold) para avaliar a generalização dos modelos em diferentes partições do conjunto de dados.
  4. Calcular e analisar métricas de desempenho como acurácia, precisão, sensibilidade (*recall*) e *F1-score*, com o intuito de comparar a performance entre os diferentes modelos avaliados.
  5. Analisar os erros de classificação (falsos positivos e falsos negativos) a fim de compreender as limitações de cada modelo no contexto do diagnóstico médico assistido por inteligência artificial.
  6. Investigar a robustez dos modelos com base na variação das métricas entre os diferentes *folds* de validação, identificando padrões de consistência ou instabilidade.

1.4 Questão da Pesquisa

Seria possível propor uma abordagem inovadora para a detecção da malária com uso de técnicas avançadas de DL com uso de TL nos modelos *RestNet50*, *EfficienteNetB7* e *MobileNetV3*?

Para alcançar os objetivos, foram utilizados bancos de dados públicos disponíveis na literatura contendo imagens de células de esfregaço sanguíneo. Inicialmente, para classificar as que possuem o parasita da malária e casos sem o parasita, logo, foram empregados modelos pré-treinados, incluindo *ResNet50*, *EfficientNetB7* e *MobileNetV2*. Por fim, o desempenho dos modelos foi avaliado por meio de métricas como acurácia, precisão, *recall* e *F1-score*.

Contudo, as principais contribuições deste trabalho são:

- Abordagem inovadora para a detecção da malária, com aplicação de técnicas avançadas de *Deep Learning* (DL) e *Transfer Learning* (TL) para a classificação de células em esfregaços sanguíneos;
- Uso de modelos pré-treinados (*ResNet50*, *EfficientNetB7* e *MobileNetV3*) para aprimorar a precisão da detecção e otimizar a acurácia do diagnóstico;
- Comparação do desempenho de diferentes arquiteturas de *Convolutional Neural Networks* (CNNs), identificando a mais eficiente para a detecção da malária;
- Avaliação dos modelos com métricas robustas, como acurácia, precisão, *recall* e *F1-score*;
- Redução do tempo de diagnóstico por meio da automatização do processo de análise das imagens de esfregaço sanguíneo, diminuindo o tempo necessário em comparação à microscopia convencional;
- Potencial para auxiliar profissionais de saúde, principalmente em regiões com escassez de especialistas, contribuindo para diagnósticos mais rápidos e confiáveis.

1.5 Organização do trabalho

O restante do trabalho está estruturado da seguinte maneira: Seção 2 traz a Revisão da Literatura, na Sessão 3 Fundamentação Teórica, em seguida na Seção 4 detalha as etapas metodológicas adotadas na realização deste estudo. A Seção 5 apresenta a discussão dos resultados experimentais. Por fim, a Seção 5 expõe as considerações finais do projeto e sugere direções para pesquisas futuras.

2 Revisão da Literatura

Esta revisão da literatura tem como objetivo investigar os modelos de aprendizado de máquina baseados em redes neurais convolucionais (CNN) utilizados para a classificação de imagens sanguíneas, com foco na detecção do protozoário da malária. O propósito é comparar a capacidade de generalização desses modelos, avaliando diferentes arquiteturas de CNN e os parâmetros de entrada considerados na análise das imagens.

Com o avanço da IA na medicina, diversos estudos têm explorado o uso de aprendizado profundo para a classificação de imagens biomédicas. (ZHAO *et al.*, 2020) desenvolveram um aplicativo móvel automatizado baseado em uma arquitetura CNN, combinando um modelo de detecção de objetos e imagens de baixo recurso em escala. O conjunto de dados balanceado foi classificado em imagens infectadas e não infectadas, alcançando uma precisão de 96,5%.

Para (KALKAN; SAHINGOZ, 2019)desenvolveram um modelo profundo baseado em CNN para a detecção de malária a partir de um conjunto de dados contendo imagens de células. Os pesquisadores utilizaram três abordagens distintas: redes neurais recorrentes (RNN), redes neurais convolucionais (CNN) e redes neurais artificiais (ANN), empregando um total de 27.558 imagens para o treinamento. Como as imagens apresentavam variações em largura e altura, os autores as redimensionaram para um tamanho fixo. O modelo CNN foi estruturado com três camadas convolucionais, seguidas por uma camada de agrupamento máximo, uma camada de achatamento, uma camada oculta e uma camada de saída. O treinamento foi realizado com um tamanho de lote de 64 e ao longo de 20 épocas, utilizando uma função de perda binária para validar os resultados. O modelo CNN foi treinado em aproximadamente 10 minutos, alcançando uma precisão de 97% nos dados de treinamento e 95% nos dados de teste. Para assegurar a confiabilidade dos resultados, os autores aplicaram a técnica de validação cruzada.

Com (SARKAR; SHARMA; SHAH, 2020), os pesquisadores utilizaram dois modelos baseados em CNN, ResNet50 e VGG16, para a detecção de malária a partir de imagens de hemácias. O modelo VGG16 obteve um desempenho superior, atingindo uma precisão de 96,15%, sensibilidade de 94,82% e uma pontuação F1 de 96,16%, com um total de 2652 verdadeiros positivos e 2648 verdadeiros negativos. Em contrapartida, o modelo ResNet50 apresentou um desempenho inferior.

Em (OYEWOLA, 2022) apresenta uma nova abordagem baseada em redes neurais convolucionais (CNN) para detecção de parasitas da malária em imagens de esfregaço de sangue, utilizando técnicas de aumento de dados. Essa abordagem emprega aprendizado por reforço para aprimorar a precisão da classificação, alcançando uma taxa de acerto

de 94,79% em testes com imagens de amostras de sangue. O modelo demonstra ser uma solução eficiente e robusta para diagnósticos automatizados da malária em contextos clínicos.

Pesquisas recentes têm explorado o uso de redes neurais convolucionais (CNNs) para o diagnóstico de malária por meio de imagens microscópicas. (RAJ *et al.*, 2023)desenvolveram um modelo baseado em CNNs capaz de identificar a presença do parasita com uma acurácia de 94%, demonstrando a eficácia dessas arquiteturas no reconhecimento de padrões em imagens médicas. O estudo destacou a importância do pré-processamento das imagens e do ajuste fino dos hiperparâmetros da rede para otimizar a classificação.

No estudo de (SIHKA *et al.*, 2023) propõe um modelo de aprendizado profundo baseado em CNN para a detecção de malária por meio de amostras de sangue. Um dispositivo é desenvolvido para espalhar e iluminar as amostras, capturando imagens que são projetadas com o auxílio de um espelho e uma lente para garantir o foco adequado. Essas imagens são posteriormente analisadas pelo modelo CNN para determinar a presença ou ausência da infecção. Os experimentos são conduzidos com amostras infectadas e não infectadas, resultando em uma precisão de 97,1% após o treinamento do modelo por 1000 épocas.

Além disso, pesquisas mais recentes têm investigado arquiteturas mais avançadas para melhorar a precisão do diagnóstico automatizado. (CHAKRABARTY *et al.*, 2024) utilizaram a EfficientNet, uma rede neural convolucional otimizada para eficiência computacional e desempenho, alcançando uma precisão de 96% na detecção da malária. O estudo evidenciou que modelos mais leves e eficientes podem ser implementados em dispositivos com menor capacidade computacional, tornando o diagnóstico mais acessível em regiões com infraestrutura limitada.

Já o estudo de (KUMAR *et al.*, 2024) avalia a viabilidade do uso de modelos de aprendizado profundo para identificar diferentes tipos de organismos parasitas. Os experimentos incluem arquiteturas como VGG19, ResNet50V2 e EfficientNetB3, aplicadas a um extenso conjunto de dados composto por seis classes. O estudo relata uma precisão máxima de 99% ao utilizar técnicas de ajuste fino para otimizar diversos parâmetros dos modelos de aprendizado profundo.

Esses trabalhos demonstram o potencial das redes neurais profundas na identificação da malária, fornecendo direções importantes para o desenvolvimento de soluções mais eficazes e acessíveis para o diagnóstico automatizado da doença. O presente estudo busca contribuir nesse contexto, investigando o uso de técnicas complementares para aumentar ainda mais a precisão e a robustez dos modelos de aprendizado profundo aplicados à detecção da malária.

3 Fundamentação Teórica

Esse estudo se concentra no desenvolvimento e avaliação de técnicas de DL para a detecção de malária em esfregaços sanguíneos, o referencial teórico desempenha um papel crucial. O primeiro tópico abordado neste referencial será uma análise da malária, uma das doenças parasitárias mais prevalentes e devastadoras do mundo. Serão descritos aspectos epidemiológicos da doença. Além disso, serão apresentados os métodos tradicionais de diagnóstico da malária, como a microscopia de esfregaços sanguíneos, ressaltando suas limitações e desafios, que motivam a busca por abordagens mais eficazes e precisas.

Em seguida, será realizada uma imersão nos fundamentos do DL e CNNs, Aprendizagem por Transferência (AT) e aumento de dados (AD), que representam a espinha dorsal das técnicas utilizadas neste estudo. Serão explorados os princípios subjacentes ao funcionamento dessas redes neurais com as arquiteturas pré-treinadas ResNet50, EfficientNet-B7 e MobileNet-V3

Em suma, este capítulo da Fundamentação teórica fornecerá uma base sólida de conhecimento e compreensão sobre a malária, DL, CNNs, Aprendizado Profundo e técnicas específicas de aumento de dados. Essa base teórica será essencial para orientar o desenvolvimento e a análise das metodologias propostas neste estudo, contribuindo para uma compreensão mais profunda dos desafios e oportunidades na detecção da malária por meio de abordagens baseadas em DL.

3.1 Malária

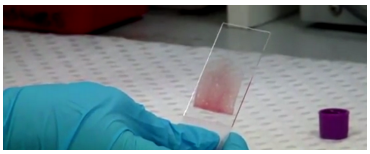
A malária é causada pelo protozoário do gênero *Plasmodium*, os quais são transmitidos ao ser humano por meio da picada do mosquito *Anopheles*, vetor responsável pela inoculação do parasita na corrente sanguínea, como mostra na Figura 1 (CRUZ, 2019).

Um estudo recente de (CALDERARO *et al.*, 2021) reforça que a microscopia tradicional de esfregaços sanguíneos, também conhecido como extensão sanguínea ou lâmina de sangue, continua sendo uma ferramenta crucial para o diagnóstico da malária. Este método permite a visualização das formas parasitárias, especialmente em esfregaços corados com Giemsa, e tem sido amplamente utilizado em áreas com recursos limitados devido à sua relação custo-benefício e à capacidade de identificar as espécies.

Figura 1 – Ilustração do Vetor de Transmissão: (a) mosquito *Anopheles*, (b) técnica de esfregaço sanguíneo e (c) microscópio eletrônico.



(a) Mosquito *Anopheles*



(b) Técnica de esfregaço sanguíneo



(c) Microscópio eletrônico

Fonte: (CRUZ, 2019)

Essas técnicas tradicionais enfrentam desafios significativos em regiões remotas e com poucos recursos, como a Amazônia, sendo ainda um processo demorado suscetível a erros ((OPS), 2024). Isto tem motivado a utilização de técnicas recentes, como as baseadas em inteligência artificial (IA), visando o diagnóstico baseado em imagens, as quais mostram potencial para superar esses obstáculos por meio da automação do processo.

De acordo com (WHO, 2020) um esfregaço bem preparado consiste em uma única camada de glóbulos vermelhos e brancos espalhados por menos da metade da lâmina como observado na Figura 1. A extremidade fosca da lâmina é usada como rótulo. A aplicação de métodos de aprendizagem profunda, demonstra o potencial de gerar diagnósticos mais rápidos, precisos e acessíveis, contribuindo significativamente para o combate à doença e promovendo um avanço no tratamento em regiões com recursos limitados.

3.2 Dataset

O *Dataset*, ou conjunto de dados, é uma coleção estruturada de informações organizadas para análise ou processamento. Segundo a (MUREL; KAVLAKOGLU, 2024). Para o desenvolvimento de sistemas inteligentes de apoio ao diagnóstico da malária, é essencial a utilização de bases de dados compostas por imagens clínicas de alta qualidade, devidamente rotuladas e organizadas. Neste trabalho, foi utilizado o conjunto de dados *Malaria Cell Images Dataset*, criado por pesquisadores do *National Institutes of Health* (NIH), dos Estados Unidos, em colaboração com centros de pesquisa especializados em doenças tropicais, como o *Mahidol Oxford Tropical Medicine Research Unit* (MORU), localizado na Tailândia. Esse dataset se consolidou como uma referência mundial em estudos sobre a detecção automatizada da malária por meio de técnicas de Visão Computacional(VC) e Aprendizado Profundo (AP) (RAJARAMAN *et al.*, 2018).

A construção do dataset foi realizada a partir da coleta de amostras clínicas de san-

gue periférico, submetidas à coloração com Giemsa, uma técnica amplamente utilizada na hematologia para destacar estruturas intracelulares, como o parasita *Plasmodium falciparum*, principal causador da malária em humanos. As imagens dos esfregaços sanguíneos foram capturadas com o auxílio de microscópios ópticos acoplados a câmeras digitais, garantindo alta resolução e riqueza de detalhes morfológicos necessários à identificação precisa do parasita. Todo o processo de aquisição de imagens ocorreu em laboratórios biomédicos parceiros do NIH, assegurando controle de qualidade e padronização metodológica.

Durante a fase de anotação, especialistas em patologia realizaram a classificação manual das imagens em duas categorias principais: *Parasitized*, representando células vermelhas infectadas pelo *Plasmodium falciparum*, e *Uninfected*, representando células normais sem sinais de infecção. Essa rotulagem manual e especializada garante a confiabilidade dos dados, essencial para o treinamento de modelos supervisionados de aprendizado de máquina e redes neurais convolucionais.

O dataset contém um total de 27.558 imagens, divididas de forma equilibrada: 13.779 imagens de células infectadas(Parasitized) e 13.779 imagens de células não infectadas (Uninfected). Cada imagem possui dimensão de 128×128 pixels, no formato RGB (Red, Green, Blue), o que facilita sua manipulação em arquiteturas de redes neurais convolucionais, garantindo consistência no pré-processamento e treinamento dos modelos. As imagens estão organizadas em duas pastas principais:

3.2.1 Estrutura do Diretório do Dataset

Com o intuito de fomentar o avanço da pesquisa científica em diagnóstico computacional de doenças infecciosas, o NIH disponibilizou esse conjunto de dados de forma pública por meio da plataforma *Kaggle*, disponível em: Kaggle – NIH Malaria Dataset, o que permite carregá-lo automaticamente em projetos de aprendizado profundo com a seguinte configuração de diretório:

```
cell_images/
|-- Parasitized/
|   |--%C33P1thinF_IMG_20150619_114756a%_cell_181.png
|   |--
|-- Uninfected/
    |--%C1_thinF_IMG_20150604_104722_cel%l_9.png
    |-- ...
```

Posteriormente, o dataset também foi incorporado ao repositório oficial de datasets da biblioteca Keras, em suma, o *Malaria Cell Images Dataset* representa uma contribuição

significativa para a pesquisa em inteligência artificial aplicada à saúde, especialmente no campo do diagnóstico automatizado de doenças tropicais. Sua abrangência, qualidade e acessibilidade tornam-no um recurso fundamental para o desenvolvimento de soluções baseadas em redes neurais profundas.

Este processo de anotação cuidadosa assegura a confiabilidade dos dados, possibilitando o treinamento supervisionado de modelos de aprendizado profundo.

3.3 Aprendizado de Máquina: Aprendizagem Profunda e Visão Computacional

O Aprendizado de Máquina (AM) ou *Machine Learning* (ML), refere-se a um conjunto de técnicas que permitem aos sistemas aprender de maneira autônoma e evoluir por conta própria (NEOWAY, 2020). Em outras palavras, a máquina tem a capacidade de ajustar seu comportamento com base nas experiências adquiridas ao longo do tempo, logo, está sendo utilizado também para classificação de imagem. No entanto, tem sido necessário desenvolver algoritmos de aprendizado tradicionais em arquiteturas mais elaboradas, formando uma área recente em inteligência artificial chamada aprendizagem profunda, em Inglês *Deep Learning*(DL).

A aprendizagem profunda é um subcampo do aprendizado de máquina onde seus algoritmos simulam a operação do cérebro humano para extrair e aprender representações ocultas a partir de entradas brutas, muitas vezes sem qualquer intervenção humana (MACHADO; SILVA; GOLDSCHMIDT, 2020).

DL é uma técnica de aprendizado de máquina na qual o programa computacional – que constitui uma CNN – aprende a distinguir entre imagens diferentes tal como humanos fazem: com a experiência. (SOUZA *et al.*, 2019). Trata-se de uma área da inteligência artificial que se destaca pela capacidade de aprender representações complexas de dados, especialmente em conjuntos de dados de imagem.

Logo, a VC emerge como um dos pilares fundamentais da computação moderna, impulsionada significativamente pelas técnicas avançadas de ML e DL num campo em que a análise humana levaria um tempo demasiadamente longo (PETER; INTELLIGENCE, 2021).

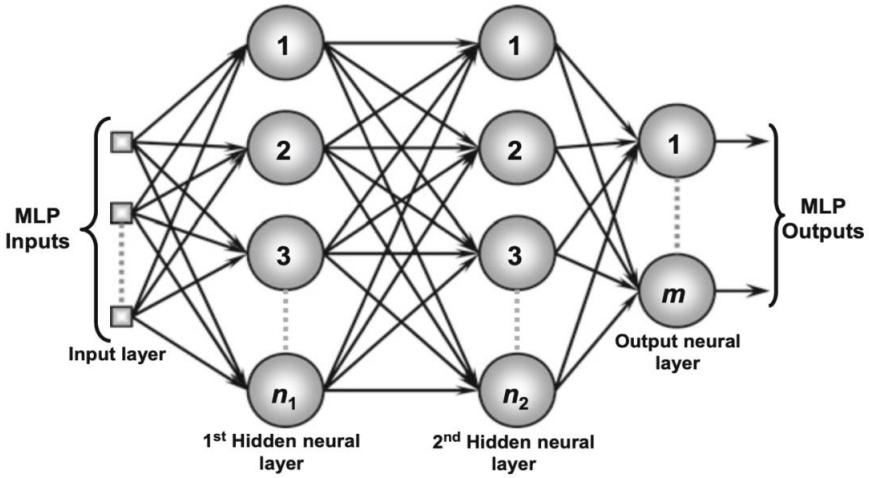
3.4 Redes Neurais artificiais

As Redes Neurais Artificiais (RNA, do inglês Artificial Neural Network) são modelos baseados no funcionamento do cérebro humano, buscando replicar a maneira como os neurônios biológicos se conectam e interagem entre si. As RNAs são algoritmos compu-

tacionais inspirados na estrutura neural dos organismos inteligentes que adquirem conhecimento por experiência. O neurônio artificial, apresentado na Figura 2, é a sua unidade de processamento fundamental.

No contexto do aprendizado de máquina, os algoritmos de redes neurais são categorizados como supervisionados, não supervisionados e semi-supervisionados. Nesta pesquisa, foi utilizado o algoritmo de rede neural Multilayer Perceptron (MLP), classificado como um modelo de aprendizado supervisionado. Esse tipo de algoritmo requer um processo de treinamento baseado em exemplos rotulados, permitindo que a rede ajuste seus parâmetros progressivamente a fim de minimizar os erros de predição. A cada iteração do treinamento, os ajustes nos pesos da rede são realizados para otimizar sua capacidade preditiva.

Figura 2 – Ilustração de uma Rede Multilayer Perceptron.



Fonte: (SILVA *et al.*, 2017)

A estrutura MLP é ilusrada na Figura 2, ao qual sua definição está em três camadas principais: camada de entrada, camadas ocultas e camada de saída, Na camada de entrada, os neurônios recebem os dados brutos que serão processados pela rede, onde cada neurônio de entrada representa uma *feature* (característica) do conjunto de dados e repassa essas informações para a próxima camada, onde O número de neurônios na camada de entrada depende da quantidade de variáveis que descrevem o problema modelado. Em seguida, no centro da imagem ocorre o aprendizado da rede. Esse modelo específico apresenta duas camadas ocultas, denominadas *1st Hidden Neural Layer* e *2nd Hidden Neural Layer*. Cada neurônio dessas camadas recebe entradas ponderadas dos neurônios da camada anterior e processa os dados aplicando funções de ativação não lineares, permitindo que a rede capture padrões complexos nos dados. Na última camada da rede, identificada na imagem como *Output Neural Layer*, contém os neurônios de saída, que geram o resultado final do modelo. O número de neurônios nessa camada depende da

natureza do problema, logo, no nosso estudo, trata-se de um problemas de classificação binária, um único neurônio de saída pode ser utilizado, aplicando funções de ativação como a *sigmoid* para gerar probabilidades. Para (SILVA *et al.*, 2017), as redes neurais artificiais são modelos computacionais inspirados no funcionamento do sistema nervoso dos seres vivos. Elas possuem a capacidade de adquirir e armazenar conhecimento, sendo compostas por unidades de processamento interconectadas, conhecidas como neurônios artificiais.

3.5 Redes Neurais Convolucionais

Dentre as diversas arquiteturas de redes neurais, as redes neurais convolucionais (CNNs, do inglês *Convolutional Neural Networks*) destacam-se como uma das abordagens mais eficazes para o processamento de dados com estrutura espacial, como imagens, vídeos e sinais biomédicos.

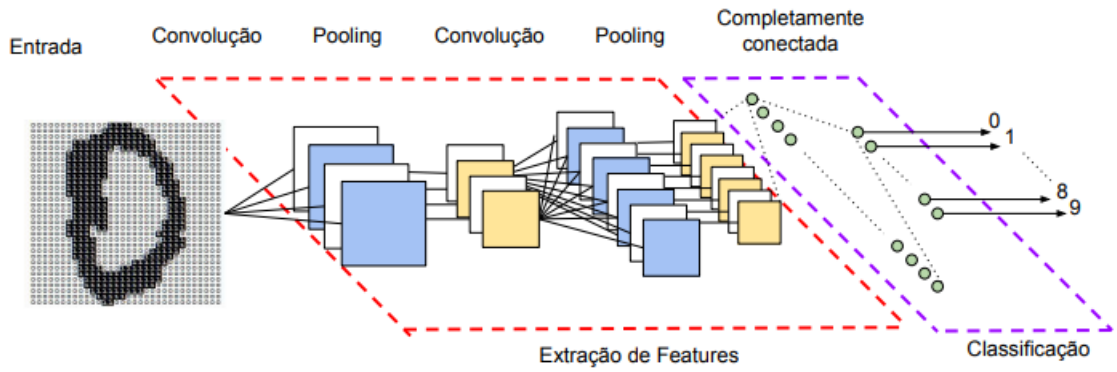
Segundo (GOODFELLOW; BENGIO; COURVILLE, 2016a), as CNNs são projetadas para processar dados que possuem uma estrutura em grade, como imagens, e têm sido amplamente utilizadas em tarefas de classificação de imagens, detecção de objetos e reconhecimento facial.

De acordo com (VARGAS; PAES; VASCONCELOS, 2016), as CNNs é uma variação das redes de Perceptrons Multicamadas, porém foram especificamente projetadas com base nos princípios biológicos que envolvem o processamento de dados visuais, na Figura 3 pode ser observado uma imagem de entrada, em seguida uma camada de convolução para extração de característica por meio de filtros, depois a redução de dimencionalidade através do *pooling*, após a extração de características, os dados são achatados e passados para camadas densas e por último a camada de saída usa a função *softmax* para atribuir probabilidades às classes, bastante utilizado em multiclasse, mesmo que o nosso estudo seja uma saída binária, também é possível utilizar. . .

As redes convolucionais são um tipo especializado de rede neural que utiliza operações matemáticas chamadas de convoluções para processar dados. Como destacado por (KRIZHEVSKY; SUTSKEVER; HINTON, 2017), "as CNNs aplicam filtros convolucionais sobre a matriz de pixels, extraindo automaticamente características locais, como bordas, texturas e padrões estruturais." A estrutura das CNNs é composta por três tipos principais de camadas: convolucionais, de pooling e totalmente conectadas, que juntas formam uma hierarquia de aprendizado eficiente (RAWAT; WANG, 2017).

As camadas convolucionais desempenham um papel fundamental na extração de características espaciais da imagem de entrada. Essas camadas aplicam filtro (do inglês, *Kernel*) específicos sobre os dados, permitindo a identificação de padrões relevantes. Cada

Figura 3 – Rede Neural Convolucional e suas respectivas camadas.

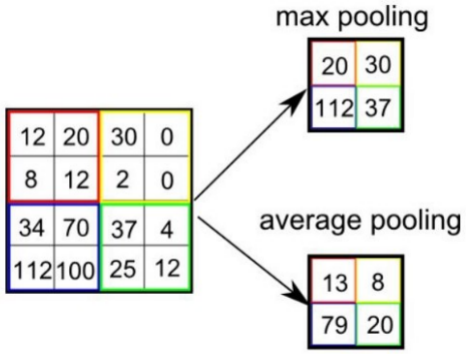


Fonte: (VARGAS; PAES; VASCONCELOS, 2016)

filtro é responsável por detectar uma característica distinta, como bordas, texturas ou formas geométricas, que auxiliam na diferenciação dos objetos representados na imagem.

Após a convolução, as camadas de *pooling* entram em ação para reduzir a dimensionalidade dos dados, mantendo as informações mais importantes extraídas pelas convoluções anteriores. Essa redução é essencial para tornar a rede neural mais eficiente, diminuindo a complexidade computacional e prevenindo o *overfitting*. Dentre as técnicas de *pooling*, o *max pooling* é uma das mais utilizadas. Esse método consiste em selecionar o valor máximo dentro de uma determinada região da imagem, garantindo que as informações mais significativas sejam preservadas. A Figura 4 ilustra esse processo, evidenciando como a aplicação do *pooling* reduz a resolução dos mapas de características sem comprometer a qualidade da informação extraída.

Figura 4 – Demonstração do funcionamento das operações de pooling.



Fonte: (RAWAT; WANG, 2017)

Ocorre que uma matriz de entrada é dividida em quatro regiões, cada uma sendo processada de maneira distinta pelos dois tipos de pooling. O max pooling seleciona o maior valor de cada região (submatriz), destacando as características mais dominantes e preservando informações de alto contraste e bordas. Já o *average pooling* calcula a média

dos valores dentro de cada região, fornecendo uma suavização da imagem e reduzindo a sensibilidade a variações locais.

O uso dessas técnicas impacta diretamente a eficiência e a generalização dos modelos de aprendizado profundo. Enquanto o *max pooling* é amplamente utilizado para enfatizar padrões mais expressivos, o *average pooling* pode ser útil em contextos onde a preservação de informações globais é preferível. Estudos recentes indicam que a escolha entre essas abordagens deve considerar a natureza dos dados e a tarefa específica a ser realizada na rede neural (SHARMA; MEHRA, 2019)(ZAFAR *et al.*, 2022)

Por fim, as camadas totalmente conectadas (do inglês, *Fully Connected Layers*) são responsáveis por combinar as características extraídas ao longo da rede para realizar a tarefa desejada, seja ela classificação ou regressão. Nessa etapa, os mapas de características gerados pelas camadas anteriores são achatados e transformados em um vetor unidimensional, que é então passado por uma ou mais camadas densamente conectadas. Essa estrutura permite que a rede aprenda combinações mais complexas das características previamente extraídas, resultando em uma tomada de decisão mais precisa.

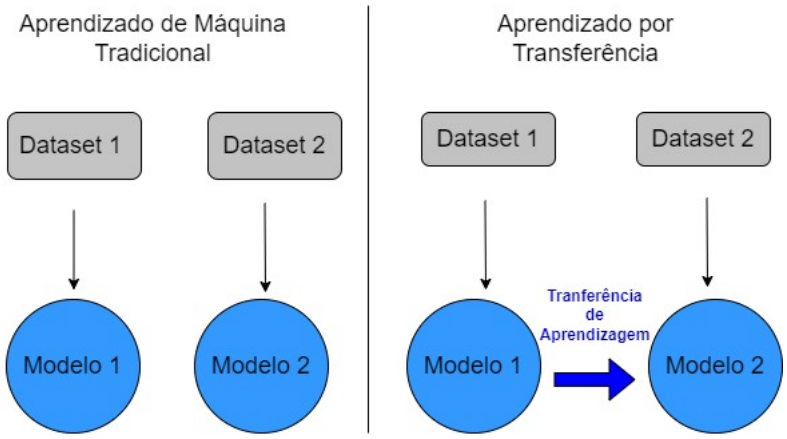
3.6 Aprendizagem por Transferência

A aprendizagem por transferência (AT), do inglês *Transfer Learning*, trata-se de uma abordagem de aprendizado de máquina que visa aprimorar o desempenho em uma determinada tarefa utilizando o conhecimento previamente adquirido em uma outra tarefa já realizada. Diferentemente dos métodos tradicionais, que exigem o treinamento de modelos do zero para cada nova tarefa, demandando grandes volumes de dados rotulados e recursos computacionais significativos, a aprendizagem por transferência reutiliza modelos pré-treinados, reduzindo substancialmente os custos de treinamento e a dependência de dados extensivos. (IMAN; ARABNIA; RASHEED, 2023)

Na Figura 5 é possível observar as diferenças entre aprendiagem de máquina e aprendizagem por transferência, onde demonstra a comparação do aprendizado de máquina tradicional e o aprendizado por transferência. No modelo tradicional (lado esquerdo), cada conjunto de dados (Dataset 1 e Dataset 2) é utilizado para treinar modelos independentes (Modelo 1 e Modelo 2), sem reaproveitamento de conhecimento prévio. No aprendizado por transferência (lado direito), um modelo inicial (Modelo 1), treinado com um conjunto de dados (Dataset 1), transfere seu conhecimento para um segundo modelo (Modelo 2), que será ajustado com um novo conjunto de dados (Dataset 2).

De acordo com (AWS, 2023), o aprendizado por transferência melhora a eficiência do treinamento, reduz a necessidade de grandes volumes de dados e acelera a convergência do aprendizado, sendo amplamente utilizado em deep learning para tarefas como

Figura 5 – Comparativo entre as abordagens de aprendizado de máquina e o aprendizado por transferência.



Fonte: Adaptado de (COSTA; WALTER; STADLER, 2022)

reconhecimento de imagens e processamento de linguagem natural.

3.6.1 Resnet-50

A ResNet (Residual Network) é uma arquitetura de rede neural convolucional (CNN) proposta por (HE *et al.*, 2016), no artigo *"Deep Residual Learning for Image Recognition"*. Ela foi desenvolvida para resolver o problema de degradação de desempenho em redes neurais muito profundas, onde o aumento do número de camadas leva a uma saturação ou até mesmo degradação da precisão. A ResNet-50 é uma das variantes da família ResNet, que inclui outras versões como ResNet-34, ResNet-101 e ResNet-152.

A principal inovação da ResNet é a introdução dos blocos residuais, do inglês *Residual Blocks*), que permitem o treinamento eficiente de redes neurais profundas ao mitigar problemas como o desaparecimento do gradiente. Esses blocos são compostos por camadas convolucionais, responsáveis pela extração de características, e por conexões residuais (ou skip connections), que permitem a passagem direta de informações entre camadas não adjacentes. Essa arquitetura facilita a propagação do gradiente durante o treinamento, resultando em uma convergência mais estável e melhor desempenho do modelo em tarefas de visão computacional. Como destacado por (ULTRALYTICS, 2023). No centro da arquitetura ResNet está o conceito de ligações residuais, também conhecidas como ligações de salto, onde o bloco residual pode ser descrito como:

$$y = F(x, \{W_i\}) + x \tag{3.1}$$

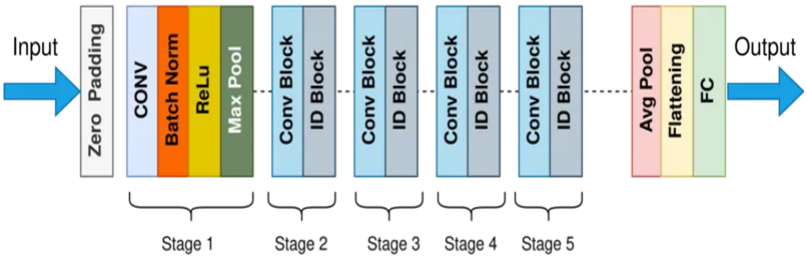
Onde:

- x é a entrada do bloco.

- $F(x, \{W_i\})$ é a transformação aplicada pelas camadas convolucionais.
- y é a saída do bloco.
- A adição $+x$ é a conexão residual, que permite que a rede aprenda uma função residual $F(x) = y - x$.

A ResNet-50 é uma arquitetura de rede neural profunda composta por 50 camadas convolucionais, dispostas em quatro estágios principais. Cada estágio apresenta um número crescente de filtros, iniciando com 64 no primeiro estágio, seguido por 128, 256 e 512 nos estágios subsequentes. Essa estrutura permite que a rede extraia características em diferentes escalas, contribuindo para uma representação hierárquica dos dados. Além disso, cada estágio é composto por múltiplos blocos residuais, que são formados por camadas convolucionais adicionais, organizadas de maneira que, mesmo em redes profundas, o treinamento permanece eficiente e estável. Como afirmado por (HE *et al.*, 2015), a ideia central da ResNet é permitir que as redes neurais profundas aprendam com facilidade ao adicionar conexões residuais.

Figura 6 – Arquitetura ResNet - 50.



Fonte: (KUNDU, 2023)

Dentro da arquitetura, a ResNet-50 utiliza uma camada de *pooling* após cada estágio para reduzir a dimensionalidade dos dados e controlar a complexidade computacional. Essa técnica de redução progressiva de dimensão contribui para a extração mais eficiente de características relevantes, além de otimizar o tempo de processamento. Ao final da rede, uma camada totalmente conectada *(fully connected)* realiza a classificação final, utilizando as representações extraídas pelas camadas anteriores. Como destacado por (HE *et al.*, 2015), o uso de camadas de *pooling* e a estrutura modular da ResNet permite que ela atinja um alto desempenho em tarefas de classificação.

A função de ativação ReLU (do inglês, *Rectified Linear Unit*) é aplicada após cada camada convolucional, com exceção da última camada de cada bloco residual. Neste caso, a ReLU é utilizada antes da adição da conexão residual, o que permite que a informação seja propagada de forma mais eficiente ao longo da rede. Essa abordagem de ativação contribui para uma convergência mais rápida do treinamento e melhora a capacidade de

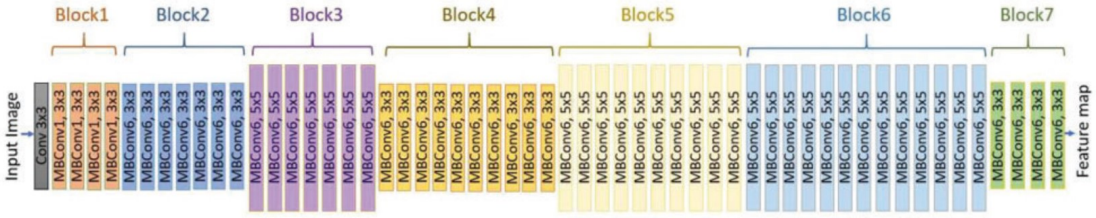
generalização do modelo, como afirmado por (ZHANG *et al.*, 2019) : "a utilização da função ReLU em redes profundas facilita a propagação de gradientes, acelerando o treinamento e evitando o problema do desaparecimento de gradientes".

No que diz respeito à normalização, a ResNet50 emprega a técnica de *Batch Normalization* após cada camada convolucional. Essa estratégia tem como objetivo acelerar o processo de treinamento e melhorar a estabilidade da rede, ajustando a distribuição dos dados em cada mini-*batch*. A normalização por lote facilita a convergência, reduzindo a necessidade de ajustes finos nos hiperparâmetros e mitigando problemas como o desaparecimento do gradiente. Como destacado por (IOFFE; SZEGEDY, 2015), "a normalização por lote é uma técnica fundamental para a estabilidade e o desempenho das redes neurais profundas". Combinando essas inovações, a ResNet50 se destaca como uma das arquiteturas mais eficientes para tarefas complexas de visão computacional.

3.6.2 EfficientNetB7

A família da arqutetura EfficientNet, proposta por (TAN; LE, 2019b), introduziu um novo paradigma no dimensionamento eficiente de CNNs, permitindo uma melhora significativa na relação entre desempenho e custo computacional. O modelo EfficientNet-B7, o mais profundo e avançado da série, adota um escalonamento composto de largura, profundidade e resolução da imagem de entrada, resultando em uma arquitetura altamente eficiente para tarefas de visão computacional.

Figura 7 – Arquitetura EfficientNet B7



Fonte:(BAHETI *et al.*, 2020)

A EfficientNetB7 é composta por sete blocos progressivos como observado na Figura 7, organizados de maneira hierárquica para processar a entrada da imagem e extrair representações robustas. A rede inicia com uma camada convolucional inicial Mobile Inverted Bottleneck (MBConv) peetencente ao Bloco 1, onde ocorre o processamento na camada convolucional 3×3, em seguida por três camadas MBConv1 (3×3), estabelecendo uma base eficiente para a propagação de informações. No Bloco 2, múltiplas repetições de MBConv6 (3×3) refinam as características extraídas, aumentando a profundidade do aprendizado. O Bloco 3 emprega MBConv6 (5×5), ampliando o campo receptivo e permitindo a captura de padrões espaciais mais complexos. Nos Blocos 4 e 5, há uma alternância

estratégica entre MBConv6 (3×3) e MBConv6 (5×5), garantindo um equilíbrio entre granularidade e capacidade de abstração. O Bloco 6, a região mais profunda da rede, é composto exclusivamente por MBConv6 (5×5), maximizando a expressividade do modelo e fortalecendo o aprendizado de representações avançadas. Finalmente, o Bloco 7 conclui a extração de características com MBConv6 (3×3) antes da transição para as camadas densamente conectadas, preparando a informação processada para a fase de classificação.

Cada bloco da arquitetura EfficientNet contém camadas convolucionais MBConv, que utilizam convoluções de profundidade separáveis (Depthwise Separable Convolutions) e blocos Squeeze-and-Excitation (SE) para aprimorar a expressividade do modelo enquanto reduzem a complexidade computacional. Essa combinação permite que a rede aprenda representações mais refinadas, otimizando o uso de parâmetros e mantendo um alto desempenho em tarefas de visão computacional. Segundo (ROBOFLOW, 2024), "a arquitetura EfficientNet utiliza blocos MBConv, que incorporam convoluções separáveis em profundidade e camadas *Squeeze-and-Excitation* (SE) para aprimorar a expressividade do modelo enquanto reduzem a complexidade computacional".

3.6.3 MobileNetV3

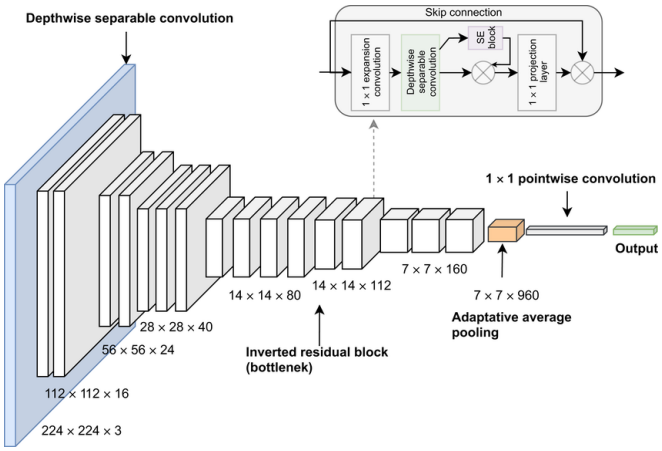
O MobileNetV3 é um tipo especial de rede neural convolucional (CNN) projetado para ser eficiente e rápido, especialmente em dispositivos como smartphones e outros aparelhos eletrônicos. Ele combina um tamanho compacto com alto desempenho, garantindo rapidez sem comprometer a precisão. Isso é possível graças ao uso de convoluções separáveis por profundidade, que reduzem significativamente o número de cálculos necessários para processar imagens. Essa abordagem é amplamente utilizada em tarefas como reconhecimento de imagens, detecção de objetos e outras aplicações em dispositivos com recursos limitados.

O MobileNetV3 representa a versão mais recente da série de arquiteturas MobileNet, cada uma trazendo melhorias em eficiência e desempenho. O MobileNetV3 introduz recursos como blocos squeeze-and-excite e resíduos invertidos eficientes com gargalos lineares. Os blocos squeeze-and-excite aprimoram a atenção entre canais, permitindo que a rede se concentre nas características mais importantes. Já os resíduos invertidos eficientes com gargalos lineares otimizam a arquitetura da rede para uma extração e transformação de características mais eficazes.

Existem duas variantes do MobileNetV3: MobileNetV3-Small e MobileNetV3-Large. Na perspectiva de (HOWARD *et al.*, 2019a)A principal diferença entre elas está no tamanho e na complexidade da rede, sendo o MobileNetV3-Small menor e mais leve, o que o torna adequado para dispositivos com recursos limitados, enquanto o MobileNetV3-Large oferece maior precisão e desempenho, mas com um custo computacional mais ele-

vado. Este estudo utiliza a versão MobileNetV3-Large.

Figura 8 – Arquitetura MobileNetV3



Fonte:(ELAZIZ *et al.*, 2023)

A Figura 8 apresenta mostra a entrada a rede MobileNetV3 que recebe imagens RGB de dimensão 224x224x3. A primeira etapa aplica convoluções separáveis em profundidade, uma técnica que reduz significativamente o número de operações computacionais ao fatorizar convoluções convencionais em duas etapas: uma convolução depthwise (por canal) e uma convolução pointwise (1x1). Como resultado, a representação da imagem passa a ter dimensão 112x112x16, permitindo a extração de características iniciais com menor custo computacional.

Os blocos de resíduo invertido (inverted residual blocks), também conhecidos como bottlenecks, são fundamentais para a eficiência da MobileNetV3, pois permitem equilibrar a expressividade da rede com baixos custos computacionais. Cada bloco segue uma sequência estruturada: inicialmente, uma convolução de expansão 1x1 aumenta a dimensionalidade dos canais, ampliando a capacidade de modelagem sem um aumento excessivo no custo computacional; em seguida, uma convolução depthwise aplica filtragem separável em profundidade, reduzindo significativamente a quantidade de cálculos necessários. Adicionalmente, um módulo squeeze-and-excitation (SE Block) reforça a importância dos canais mais relevantes para a tarefa de classificação, aprimorando a seletividade da rede. Após essa etapa, uma camada de projeção 1x1 reduz a dimensionalidade novamente, garantindo uma representação mais compacta e eficiente. Sempre que necessário, uma conexão residual (*skip connection*) é incorporada para preservar informações críticas ao longo das camadas. Essa estrutura permite que a MobileNetV3 alcance alta eficiência computacional sem comprometer o desempenho na extração de características, tornando-a particularmente adequada para aplicações em dispositivos com restrições de recursos (HOWARD *et al.*, 2019a)

A arquitetura segue uma hierarquia estruturada de camadas convolucionais, oti-

mizando a extração de características em diferentes níveis de abstração. No Estágio 1, a imagem de entrada é processada para gerar um mapa de características de 112×112×16, preservando informações espaciais iniciais. No Estágio 2, a resolução é reduzida para 56×56×24, permitindo a manutenção da discriminação de padrões locais com menor custo computacional. O Estágio 3 aprimora a complexidade das características extraídas, resultando em um mapa de 28×28×40. No Estágio 4, a rede captura padrões de alto nível, produzindo representações de 14×14×80 e 14×14×112, fundamentais para a modelagem de estruturas semânticas mais abstratas. Por fim, no Estágio 5, as representações finais atingem dimensões de 7×7×160 e, posteriormente, 7×7×960, refinando as informações extraídas e preparando os dados para a fase de classificação, garantindo um equilíbrio entre eficiência computacional e expressividade do modelo.

Após a extração de características, a MobileNetV3 aplica uma operação de pooling adaptativo médio (*adaptive average pooling*), reduzindo os mapas de características para uma forma compacta antes da última camada convolucional *pointwise* (1x1). Essa etapa gera um vetor de características pronto para ser classificado pela camada de saída.

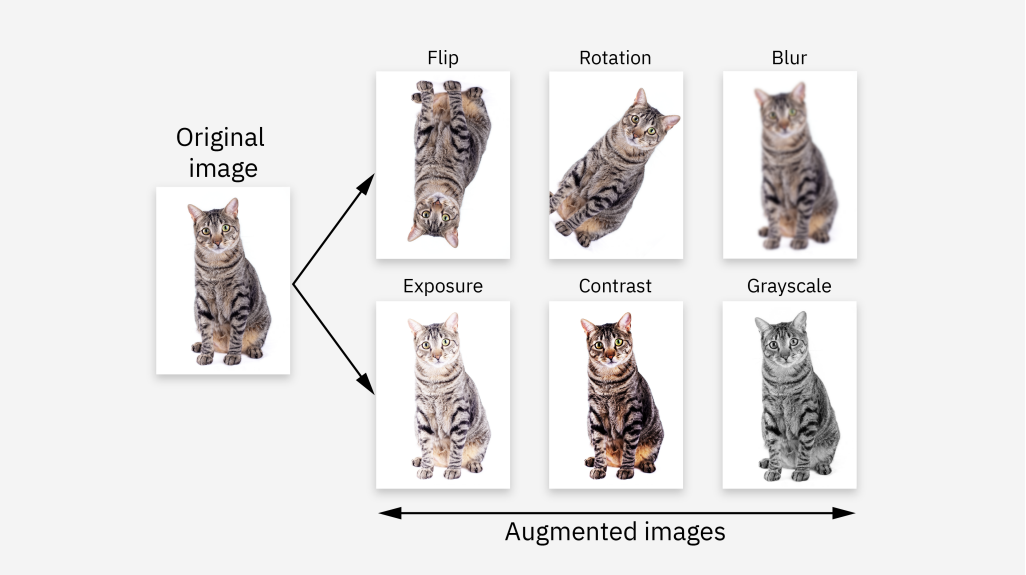
3.7 Aumento de Dados

O aumento de dados (DA), em inglês (*Data Augmentation*) de imagens consiste em aplicar transformações aleatórias às imagens originais, como rotações, inversões e zooms para criar novas instâncias de dados, aumentando assim a quantidade e a diversidade dos exemplos disponíveis para o treinamento de modelos de aprendizado de máquina (REZENDE *et al.*, 2021).

Exemplificando na Figura 9, a imagem original de um gato é modificada através de operações como espelhamento(flip), rotação(Rotation), desfoque(Blur), ajuste de exposição(exposure), alteração de contraste(Contrast) e conversão para escala de cinza (Grayscale). Essas modificações simulam variações naturais que podem ocorrer em um ambiente real, reduzindo o risco de overfitting e tornando o modelo mais capaz de generalizar para novas imagens. A técnica de data augmentation é particularmente essencial em cenários onde o volume de dados disponíveis é limitado, permitindo que redes neurais sejam treinadas de forma mais eficiente e eficaz, melhorando seu desempenho em tarefas como reconhecimento de objetos, classificação de imagens e segmentação semântica.

O aumento de dados pode ser amplamente utilizado paradiversificar os dados em treinamento de RNAs profundas, sua eficácia pode ser limitada em determinados cenários (SEMENOGLOU; SPILIOTIS; ASSIMAKOPOULOS, 2023). Em alguns casos, ele pode introduzir ruído e distorções que afetam negativamente a acurácia dos modelos, especialmente em contextos onde a manipulação geométrica ou visual exagerada altera a natureza fun-

Figura 9 – Demonstração da técnica de Aumento de Dados



Fonte:(MUREL; KAVLAKOGLU, 2024)

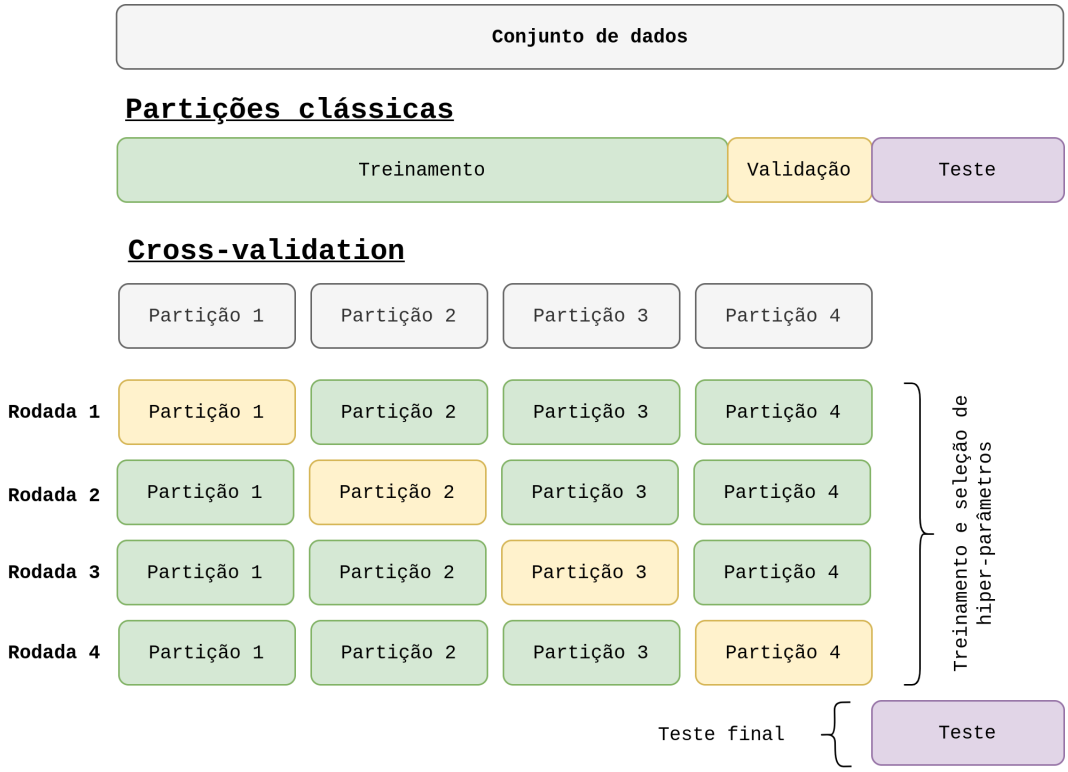
damental da imagem, prejudicando a generalização do modelo.

3.8 Validação Cruzada

A validação de modelos de aprendizado de máquina desempenha um papel crucial na construção de sistemas preditivos confiáveis. Tradicionalmente, os conjuntos de dados são divididos em três subconjuntos: treinamento, validação e teste. No entanto, esse método clássico pode levar a estimativas instáveis do desempenho do modelo. Para diminuir esse problema, a validação cruzada, em inglês *cross-validation* - (VC) tem sido amplamente utilizada como uma abordagem mais robusta. Essa técnica envolve a divisão do conjunto de dados em múltiplas partições e a realização de várias rodadas de treinamento e validação, garantindo que cada partição seja utilizada tanto para ajuste do modelo quanto para avaliação. Entre os métodos mais utilizados está a validação cruzada k-fold, na qual o conjunto de dados é dividido em k subconjuntos, e o modelo é treinado k vezes, utilizando um subconjunto diferente para validação a cada rodada. (WHITE; POWER, 2023)

Essa técnica estatística é essencial para avaliar a capacidade de generalização de modelos preditivos, como redes neurais profundas, além de desempenhar um papel fundamental na otimização de hiperparâmetros. Neste estudo, adotou-se uma estratégia de particionamento em duas etapas. Inicialmente, o conjunto de dados foi dividido em duas partições principais: 80% dos dados foram destinados ao conjunto de treinamento/validação, sobre o qual se aplicou o procedimento de validação cruzada para calibrar e avaliar

Figura 10 – A imagem apresenta um comparativo entre partições clássicas e validação cruzada na divisão de um conjunto de dados para treinamento e teste de modelos de aprendizado de máquina.



(DEVELOPERS, 2024)

o desempenho dos modelos durante o processo de ajuste. Os 20% restantes constituíram o conjunto de teste, reservado exclusivamente para a avaliação final do modelo escolhido, assegurando uma estimativa imparcial de sua performance em dados não vistos durante o treinamento. Essa abordagem garante robustez na seleção do modelo e maior confiabilidade nos resultados obtidos, conforme demonstrado por (KUHN; JOHNSON, 2023), que destacam a validação cruzada como uma prática fundamental na modelagem preditiva moderna.

Nessa abordagem não apenas melhora a generalização do modelo, mas também reduz a variância associada à seleção de uma única partição de validação. Além disso, a validação cruzada evita o *overfitting*, um problema recorrente em aprendizado de máquina, onde o modelo se ajusta excessivamente aos dados de treinamento, perdendo sua capacidade de generalização para novos dados. Como destacado por (ARLOT; CELISSE, 2010), a validação cruzada é uma técnica essencial para obter estimativas imparciais e mais confiáveis do desempenho do modelo, especialmente quando os dados disponíveis são limitados.

Portanto, a validação cruzada se estabelece como um padrão na modelagem preditiva, permitindo um ajuste mais preciso dos hiperparâmetros e uma melhor compreensão

da capacidade preditiva dos modelos em diferentes cenários de dados.

3.9 Métricas

Em problemas de classificação, a avaliação criteriosa do desempenho do modelo é um passo fundamental para assegurar a confiabilidade e precisão das previsões. A matriz de confusão destaca-se como uma ferramenta analítica primária neste processo, oferecendo uma sumarização estruturada dos resultados da classificação em quatro categorias cardinais, conforme ilustrado na Tabela 2.

Tabela 2 – Matriz de confusão

	Classe predita	
Classe real	**Positiva**	**Negativa**
Positiva	Verdadeiro positivo (VP)	Falso negativo (FN)
Negativa	Falso positivo (FP)	Verdadeiro negativo (VN)

Fonte: Do autor (2025).

Estas categorias são definidas como: Verdadeiros Positivos (VP), que representam as instâncias corretamente atribuídas à classe de interesse pelo modelo; Falsos Positivos (FP), que ocorrem quando o modelo classifica erroneamente uma amostra como pertencente a essa classe quando, na realidade, não pertence; Verdadeiros Negativos (VN), indicando as amostras corretamente identificadas como não pertencentes à classe em análise; e, por fim, Falsos Negativos (FN), que correspondem às instâncias que pertenciam à classe de interesse mas foram incorretamente designadas como não pertencentes pelo modelo.

A avaliação do desempenho de modelos de classificação é fundamental para garantir previsões precisas e confiáveis. As métricas mais utilizadas incluem Precisão, Recall e Pontuação F1, que fornecem *insights* sobre a eficácia do modelo. A Precisão Geral é definida como a razão entre o número de previsões corretamente classificadas (Verdadeiros Positivos (TP) e Verdadeiros Negativos (TN)) e o número total de previsões feitas pelo modelo, conforme mostrado na Equação 3.2.

A Precisão (Precision) mede a proporção de previsões positivas corretas em relação ao total de previsões positivas feitas pelo modelo (Equação 3.3). O Recall avalia a capacidade do modelo de identificar corretamente todas as instâncias positivas reais, conforme Equação 3.4. Por fim, a *F1-Score* é a média harmônica entre Precisão e *Recall*, fornecendo

uma métrica balanceada para avaliar o desempenho do modelo, conforme Equação 3.5.

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.2}$$

A Precisão (*Precision*) mede a proporção de previsões positivas corretas em relação ao total de previsões positivas feitas pelo modelo, conforme Equação 3.3.

$$\text{Precisão} = \frac{TP}{TP + FP} \tag{3.3}$$

O Recall avalia a capacidade do modelo de identificar corretamente todas as instâncias positivas reais, conforme Equação 3.4.

$$\text{Recall} = \frac{TP}{TP + FN} \tag{3.4}$$

Por fim, a *F1- Score* é a média harmônica entre Precisão e Recall, fornecendo uma métrica balanceada para avaliar o desempenho do modelo, conforme Equação 3.5.

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} \tag{3.5}$$

Além dessas métricas, a Sensibilidade e a Especificidade são fundamentais para avaliar a capacidade do modelo em identificar corretamente as classes.

A Sensibilidade (S) (ou Recall) mede a capacidade do modelo de identificar corretamente os casos positivos e é definida como:

$$\text{S} = \frac{TP}{TP + FN} \tag{3.6}$$

Já Especificidade (E) avalia a capacidade do modelo de reconhecer corretamente os casos negativos, sendo definida por:

$$\text{E} = \frac{TN}{TN + FP} \tag{3.7}$$

Em tarefas de classificação, a mensuração precisa do desempenho do modelo é crucial. A matriz de confusão constitui uma ferramenta fundamental para essa análise, pois organiza as predições em um formato que distingue quatro desfechos principais (Tabela 2). Os Verdadeiros Positivos (VP) são as amostras que o modelo corretamente identificou como pertencentes a uma classe específica. Os Falsos Positivos (FP), por outro lado, são amostras de classes distintas que foram incorretamente preditas como pertencentes à classe de interesse. Os Verdadeiros Negativos (VN) indicam as amostras corretamente identificadas como não pertencentes à classe em questão. Por fim, os Falsos Negativos (FN) ocorrem quando amostras da classe de interesse são erroneamente classificadas como não pertencentes a ela.

Essas métricas são amplamente utilizadas para avaliar modelos de aprendizado de máquina, especialmente em problemas de classificação multiclasse e binária, onde o último é o abordado no estudo, garantindo uma análise robusta do desempenho do modelo.

4 Metodologia

Do ponto de vista de sua natureza, esta pesquisa pode ser caracterizada como aplicada, pois tem como objetivo gerar conhecimentos voltados para a aplicação prática na solução de um problema específico. Quanto à sua abordagem, trata-se de uma pesquisa quantitativa, uma vez que busca quantificar estatisticamente a performance das redes neurais convolucionais pré-treinadas em função dos fatores investigados. Já em relação ao método, trata-se de uma pesquisa de delineamento experimental, dado que envolve a determinação de um objeto de estudo e a seleção de técnicas que podem influenciar seus resultados, como o aumento de dados e a validação cruzada.

Contudo, esta seção descreve detalhadamente o fluxo metodológico adotado, abrangendo o conjunto de dados utilizado, as etapas de pré-processamento, as estratégias de aumento de dados, a aplicação de aprendizado por transferência, o procedimento de validação cruzada, a configuração do treinamento dos modelos e as métricas empregadas para avaliação do desempenho. O objetivo central da metodologia é garantir a reprodutibilidade dos experimentos, bem como a confiabilidade e a robustez dos resultados apresentados.

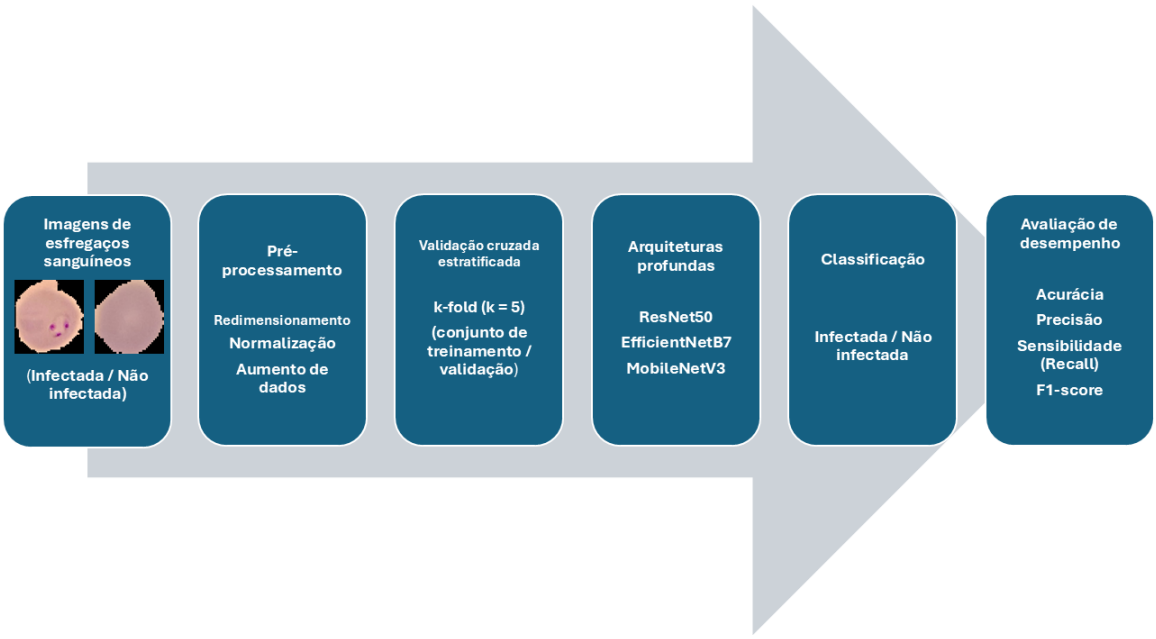
A fim de avaliar a robustez e a capacidade de generalização do modelo, as imagens foram redimensionadas para um tamanho uniforme, assegurando consistência na entrada do modelo. Posteriormente, o conjunto de dados foi particionado de maneira estratificada, sendo 80% das imagens destinadas ao treinamento e 20% reservadas para o teste. Essa divisão estratégica visa otimizar o aprendizado do modelo e proporcionar uma avaliação fidedigna de seu desempenho na classificação das células, em termos de precisão, sensibilidade e especificidade. Para a realização dos experimentos, foi utilizado inicialmente um computador pessoal com processador Intel Core i3 de 5ª geração, sistema operacional Windows 11(64 bits) e 8 GB de memória RAM. No entanto, considerando a complexidade computacional dos modelos de redes neurais profundas empregados, optou-se pela utilização da infraestrutura em nuvem fornecida pela Google Cloud Platform (GCP), por meio do ambiente Colab Pro. A instância utilizada foi a T4 High-RAM, equipada com GPU de 15 GB (NVIDIA Tesla T4), memória RAM de 51 GB, armazenamento de 235,7 GB e suporte à CUDA versão 12.1, o que permitiu acelerar significativamente o tempo de treinamento dos modelos. Os tempos médios de treinamento evidenciaram diferenças substanciais entre as arquiteturas avaliadas, sendo de aproximadamente 3 h 47 min 29 s para a ResNet-50, 11 h 45 min 37 s para a EfficientNet-B7 e apenas 1 h 05 min 06 s para a MobileNet-V3. Esses resultados refletem diretamente o grau de complexidade computacional de cada modelo, destacando a EfficientNet-B7 como a arquitetura mais onerosa em

termos de recursos, enquanto a MobileNet-V3 apresentou uma relação particularmente favorável entre eficiência computacional e desempenho. Durante o processo de treinamento, 10% dos dados do conjunto de treino foram destinados à validação, e cada modelo foi treinado ao longo de 15 épocas, com o registro sistemático das métricas de desempenho para posterior análise. Ao final, foram obtidos cinco modelos treinados, cada um validado em um subconjunto distinto dos dados, caracterizando um procedimento de validação cruzada que contribui para uma avaliação mais robusta e generalizável. Essa estratégia reduz a dependência de um único particionamento dos dados e favorece a capacidade de generalização do modelo, conforme discutido no Capítulo 5.

4.1 Fluxo de Trabalho Proposto

Para a realização do processo de detecção automatizada de malária em lâminas sanguíneas envolve uma sequência estruturada de etapas, conforme representado no fluxograma da Figura 11.

Figura 11 – Fluxo Geral



Fonte: Do autor (2025).

O fluxo inicia-se com a aquisição do *dataset* contendo imagens de células sanguíneas, categorizadas entre parasitadas e não parasitadas. Em seguida, as imagens passam por um processo de pré-processamento, que pode incluir redimensionamento, normalização, e aumento de dados, com o objetivo de padronizar os dados para o modelo.

Posteriormente, realiza-se a divisão do conjunto de dados em subconjuntos de treino e teste, garantindo uma avaliação justa da capacidade preditiva do modelo. Para

reforçar a robustez da validação, aplica-se a técnica de validação cruzada (subconjuntos), que minimiza o risco de *overfitting* ao treinar e validar o modelo em diferentes subconjuntos dos dados.

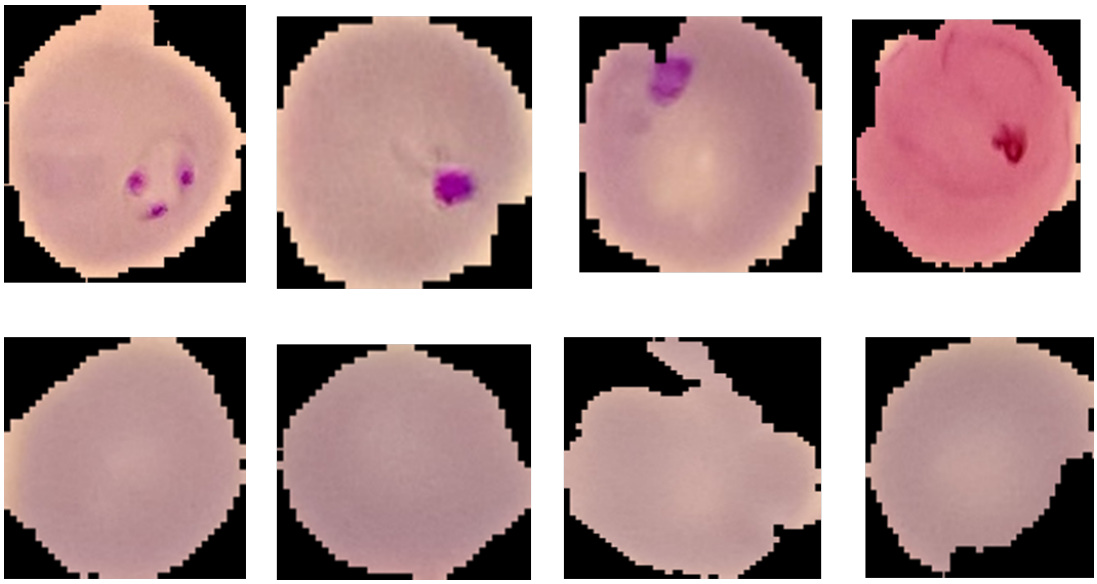
O modelo proposto, geralmente uma arquitetura de rede neural convolucional (CNN), é então treinado utilizando os dados de treino. Após o treinamento, o modelo é testado com dados novos (conjunto de teste) e avaliado com base em métricas de desempenho como acurácia, precisão, recall, F1-score. A partir dessas métricas, a performance do modelo é analisada e as imagens são classificadas como células infectadas ou não infectadas.

4.2 Conjunto de dados

Para a realização dos experimentos, utilizou-se um conjunto de dados balanceado, composto por 27.558 imagens de células sanguíneas, sendo 13.779 imagens de células infectadas e 13.779 de células não infectadas, assegurando um equilíbrio adequado entre as classes analisadas. As imagens são provenientes de bases de dados públicas, especificamente do *Dataset Malaria Cells*, disponibilizado no repositório *Kaggle*. Esse conjunto de dados é composto por amostras obtidas por meio da técnica de esfregaço sanguíneo, utilizando microscopia óptica para a aquisição das imagens.

As imagens de células da malária foram disponibilizadas pelo *National Library of Medicine* (NLM), conforme descrito por (National Library of Medicine, National Institutes of Health, 2018), e foram coletadas a partir de amostras sanguíneas de 150 pacientes infectados e 50 pacientes saudáveis. Todas as imagens apresentam resolução de 128×128 pixels e são compostas por três canais de cor no padrão RGB (*Red, Green and Blue*), armazenadas no formato PNG (*Portable Network Graphics*). As variações cromáticas observadas nas células vermelhas decorrem das diferentes técnicas de coloração empregadas durante o processo de aquisição das imagens, o que contribui para a diversidade visual do conjunto de dados.

Figura 12 – Imagens microscópicas de células sanguíneas provenientes do *Dataset Malaria Cells*.



Fonte: Adaptado de (National Library of Medicine, National Institutes of Health, 2018).

Na Figura 12, apresenta-se a distinção visual entre células sanguíneas infectadas pelo parasita da malária, dispostas na parte superior da imagem, e células sanguíneas não infectadas (saudáveis), apresentadas na parte inferior. Na porção superior, observam-se estruturas internas arroxeadas, características da presença do parasita no interior das células. Em contrapartida, na porção inferior, as células exibem morfologia homogênea, sem evidências de invasão parasitária. A correta identificação dessas diferenças morfológicas é fundamental para a realização de diagnósticos precisos e eficientes, influenciando diretamente o prognóstico clínico, as decisões terapêuticas e as estratégias de controle epidemiológico.

Destaca-se que estudos de referência, como os desenvolvidos por (RAJARAMAN, 2018) e (YU *et al.*, 2020), também empregaram esse mesmo conjunto de dados em suas análises, o que evidencia sua relevância, confiabilidade e ampla aceitação em pesquisas avançadas na área de diagnóstico automatizado da malária.

4.2.1 Pré-processamento com aumento de dados

Nesta subseção, os dados passam por duas transformações principais, que são a *train-transform*, aplicado ao conjunto de treinamento (incluindo aumento de dados), e *valtest-transform*, utilizado para validação e teste, responsável apenas pelo redimensionamento e normalização.

No processo de pré-processamento das imagens, diversas transformações foram aplicadas para garantir a robustez do modelo na tarefa de detecção de células infectadas

por malária. Inicialmente, todas as imagens foram redimensionadas para 224 × 224 pixels, garantindo compatibilidade com arquiteturas pré-treinadas de redes neurais profundas, descritas nas subseções 3.6.1,3.6.2 e 3.6.3.

Esse pipeline de transformações foi cuidadosamente projetado para otimizar o desempenho do modelo, assegurando generalização eficaz e adaptação a diferentes condições de captura das imagens microscópicas. Entretanto, foi realizado o aumento de dados para aprimorar a capacidade de generalização dos modelos, aumentar a diversidade do conjunto de dados e reduzir o risco de *overfitting*, Foram empregadas técnicas avançadas de aumento de dados em imagens, conforme recomendado por (AUTORES, 2021).

Tabela 3 – Parâmetros das Transformações Aplicadas

Parâmetro	**Valor**
Redimensionamento	(224, 224)
Flip Horizontal Aleatório	50%
Rotação Aleatória	±15°
Variação de Brilho	20%
Variação de Contraste	20%
Variação de Saturação	20%
Variação de Matiz	10%
Conversão para Tensor	Sim
Normalização (Média)	[0.485, 0.456, 0.406]
Normalização (Desvio Padrão)	[0.229, 0.224, 0.225]

Fonte: Do autor (2025)

Os parâmetros foram aplicados como mostrado na Tabela 3, incluindo *flip* horizontal aleatório com probabilidade de 50% e rotação aleatória de até ±15°, permitindo que o modelo aprenda a reconhecer padrões independentemente da orientação da célula. Além disso, foi utilizado um ajuste de brilho, contraste, saturação e matiz, variando até 20% nos três primeiros e até 10% na tonalidade, tornando o modelo mais robusto a variações nas condições de iluminação e coloração das imagens. Após essas etapas, as imagens foram convertidas para o formato de tensor, essencial para o processamento em redes neurais, e normalizadas utilizando médias [0.485, 0.456, 0.406] e desvios padrão [0.229, 0.224, 0.225], correspondentes à normalização utilizada nos modelos pré-treinados.

No conjunto de validação e teste, as imagens passam por menos transformações, pois não devem ser alteradas aleatoriamente para garantir a consistência dos resultados. Assim, são aplicadas apenas as seguintes etapas: redimensionamento para 224 × 224 pixels, conversão para tensor e normalização.

Para assegurar que o sistema mantenha a capacidade de distinguir entre diferentes tipos de imagens nas classes parasitada e saudável, durante o processo de classificação,

cada imagem do conjunto de dados será parcialmente aprimorada aleatoriamente com base nos parâmetros ativados.

4.3 Validação Cruzada

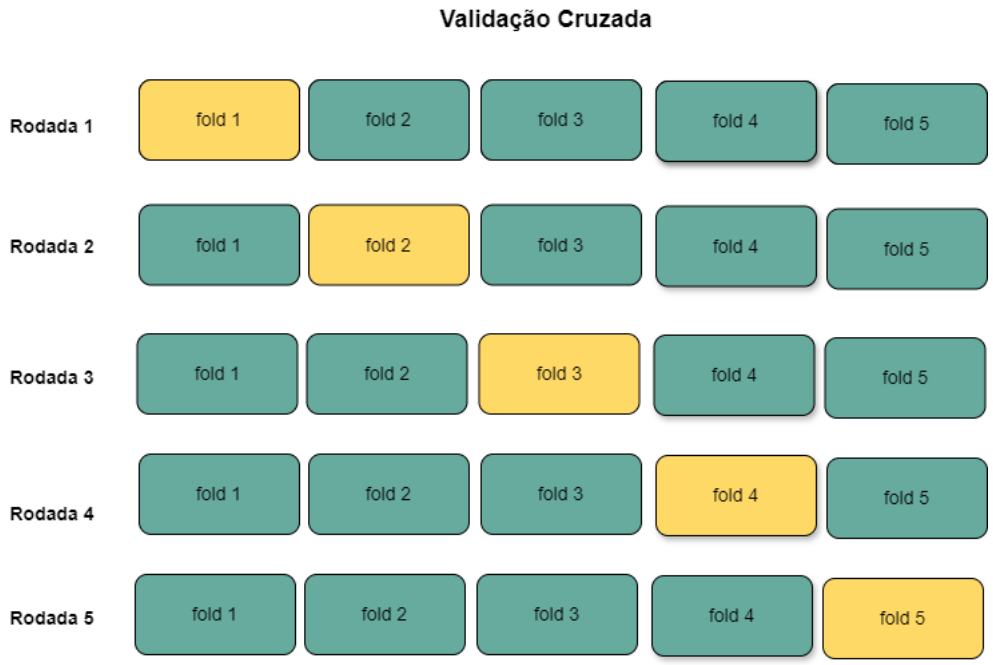
O subconjunto correspondente a 80% dos dados (destinado às fases de treinamento e validação) foi submetido a uma validação cruzada do tipo k-fold, com $k = 5$. Nesse processo, o conjunto de treinamento/validação foi dividido em cinco subconjuntos mutuamente exclusivos e aproximadamente do mesmo tamanho, denominados F_1, F_2, F_3, F_4 e F_5.

A validação cruzada consiste em cinco iterações, e em cada uma delas um *fold* diferente é utilizado como conjunto de validação, enquanto os demais quatro servem como conjunto de treinamento. Mais especificamente, em cada iteração i, o fold F_i é reservado para validação, e os demais (F_j, onde $j \neq i$) são usados para treinar o modelo. Em seguida, uma nova instância da rede neural é inicializada — seja com pesos aleatórios ou por meio de uma estratégia de pré-treinamento — e treinada exclusivamente com os dados do conjunto de treinamento da iteração em questão. Após o treinamento, o modelo é avaliado com os dados do fold de validação correspondente, e suas métricas de desempenho são registradas.

Para evitar que o treinamento continue excessivamente, levando ao *overfitting*, foi utilizada a técnica de *early stopping*. Essa estratégia monitora a acurácia de validação durante as épocas e interrompe o treinamento quando a performance não apresenta melhora por um número predefinido de épocas, logo, após cada época, é avaliada a validação, e o treinamento é interrompido antecipadamente se a acurácia de validação não aumentar por determinadas épocas consecutivas.Garantindo uma melhor generalização do modelo, evitando o ajuste excessivo ao conjunto de treino.

É importante ressaltar que, a cada iteração, uma nova instância do modelo é treinada a partir do zero (ou de um ponto de partida predefinido), sem qualquer aproveitamento dos parâmetros aprendidos nos folds anteriores. Ou seja, os pesos e vieses obtidos em uma iteração não são transferidos para as demais. Dessa forma, ao final da validação cruzada com $k = 5$, são obtidos cinco modelos independentes entre si. Essa abordagem garante uma avaliação mais confiável e menos enviesada do desempenho da arquitetura e dos hiperparâmetros utilizados. Essa metodologia assegura que cada instância dos dados seja utilizada tanto para treinamento quanto para validação, proporcionando uma estimativa mais confiável do desempenho do modelo em dados não vistos. Comparada à simples divisão entre treinamento e teste, a validação cruzada K-*fold* reduz a variância das estimativas de desempenho, tornando-se uma ferramenta essencial para avaliar a capacidade

Figura 13 – Validação Cruzada utilizada no Experimento



Fonte: Do autor (2025)

de generalização de modelos preditivos (DataCamp, 2023).

4.4 Treinamento dos modelos

A realização dos experimentos foi conduzida utilizando o conjunto de dados de imagens de células de malária disponibilizado pelo *National Institutes of Health* (NIH), processado por meio das arquiteturas ResNet50, EfficientNetB7 e MobileNetV3, com o objetivo de avaliar o desempenho na classificação de imagens de esfregaços sanguíneos para a detecção do parasita da malária. Os modelos foram treinados ao longo de 15 épocas, empregando a função de perda de entropia cruzada categórica e o otimizador Adam, com taxa de aprendizagem fixada em 0,001, valor amplamente adotado na literatura para tarefas de classificação de imagens e cenários de aprendizado profundo, por favorecer atualizações adaptativas dos pesos e uma convergência estável do processo de otimização (KINGMA; BA, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016a).

Os dados foram particionados segundo a estratégia de 80% para treino e 20% para teste, abordagem amplamente utilizada em estudos de aprendizado profundo aplicados à análise de imagens biomédicas, visando assegurar uma avaliação adequada do desempenho dos modelos em dados não vistos (LITJENS, 2017). Adicionalmente, a fase de validação foi conduzida a partir de um conjunto de dados balanceado, permitindo o monitoramento contínuo do treinamento e a aplicação do mecanismo de *early stopping*,

técnica reconhecida por reduzir o sobreajuste e auxiliar na seleção dos melhores pesos do modelo (GOODFELLOW; BENGIO; COURVILLE, 2016b). Nesse contexto, a validação é utilizada durante o treinamento para acompanhar o desempenho do modelo e aplicar o *early stopping*, possibilitando a seleção dos melhores pesos e não foi utilizada como etapa de avaliação final do modelo. A matriz de confusão e as métricas finais de desempenho foram calculadas apenas a partir do conjunto de teste totalmente independente, garantindo uma avaliação isenta de viés e assegurando a confiabilidade dos resultados apresentados. Essa separação entre validação e teste reforça a robustez metodológica do estudo e a capacidade de generalização do modelo em dados não vistos.

Tabela 4 – Configuração do treinamento dos modelos

Parâmetro	**Valor**
Número de épocas	15
Taxa de aprendizagem	0,001
Função de perda	Entropia cruzada categórica
Otimizador	Adam
Divisão treino/teste	80% treino / 20% teste
Conjunto de validação	Balanceado
Métricas de avaliação	Acurácia, Precisão, *Recall*, *F1-score*

Fonte: Do autor (2025)

O desempenho dos modelos foi quantificado por meio das métricas de acurácia, precisão, *recall* e *F1-score*, conforme apresentado na Tabela 4. Durante a etapa de ajuste de hiperparâmetros, foram testadas diferentes taxas de aprendizado, a fim de identificar a configuração mais adequada para o processo de otimização. Entre os valores avaliados, a taxa de aprendizado de 0,001 foi a que apresentou melhor desempenho global, proporcionando maior estabilidade no treinamento e melhores resultados nas métricas analisadas.

Com a configuração experimental adotada, os modelos alcançaram elevada acurácia na classificação de células parasitadas e não infectadas, com valores superiores a 90%. Esse resultado pode ser atribuído à combinação de um conjunto de dados balanceado, à estratégia de particionamento adotada e à utilização do otimizador Adam com taxa de aprendizagem ajustada empiricamente, fatores que, em conjunto, contribuíram para um desempenho equilibrado entre as classes, aspecto essencial em aplicações de apoio ao diagnóstico clínico (RAJARAMAN, 2018).

4.5 Métricas de Avaliação

No modelo de classificação na tarefa de detecção de células infectadas por *Plasmodium*, foram utilizadas métricas amplamente reconhecidas na literatura de aprendizado de má-

quina. Cada métrica fornece uma perspectiva complementar sobre a capacidade do modelo em classificar corretamente as amostras, sendo especialmente relevantes em contextos de diagnóstico médico, onde a precisão das previsões pode impactar diretamente a decisão clínica. Essas métricas são utilizadas para calcular indicadores como precisão, sensibilidade (*recall*) e *F1-score*, que fornecem uma visão mais completa sobre o desempenho do modelo, especialmente em cenários de classificação médica, onde erros podem ter impactos significativos. A Tabela 5 apresenta as principais métricas utilizadas neste trabalho, acompanhadas de suas respectivas fórmulas matemáticas e interpretações.

Tabela 5 – Indicadores de desempenho utilizados na avaliação do modelo de classificação

Métrica	**Interpretação**
Acurácia	Proporção total de previsões corretas.
Revocação(Recall)	Capacidade do modelo de identificar corretamente os casos positivos (ex.: detectar células infectadas).
Precisão (Precision)	Proporção de casos previstos como positivos que realmente são positivos.
F1-score	Média harmônica entre precisão e sensibilidade.

Fonte: Do autor (2025).

O uso combinado dessas métricas permite uma avaliação mais abrangente do modelo, destacando não apenas a proporção de acertos totais (acurácia), mas também sua habilidade em identificar corretamente os casos positivos (sensibilidade) e manter um equilíbrio entre precisão e abrangência (*F1-score*). Essa abordagem é fundamental para garantir a confiabilidade do modelo em aplicações clínicas, onde erros de classificação podem acarretar consequências graves para o paciente.

O desempenho de todos os modelos empregados neste estudo foi avaliado por meio de métricas amplamente reconhecidas, incluindo precisão, *recall*, *F1-Score*. Após o treinamento do modelo, a parte de teste foi utilizada para avaliar sua eficácia na classificação e na generalização. Além disso, a análise foi complementada pela utilização da matriz de confusão, que permite a quantificação das previsões em termos de verdadeiros positivos (TP), verdadeiros negativos (TN), falsos positivos (FP) e falsos negativos (FN), proporcionando uma visão abrangente sobre a performance dos modelos no contexto da tarefa proposta como analisada no Capítulo 5.

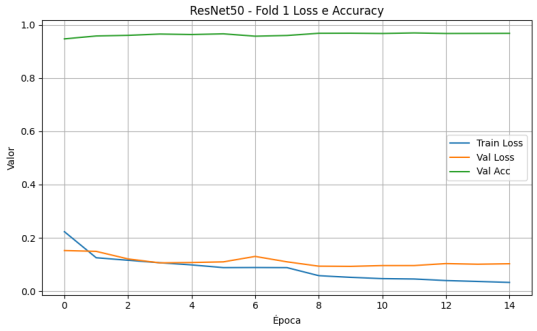
5 Resultados e Discussão

5.1 Arquitetura ResNet50

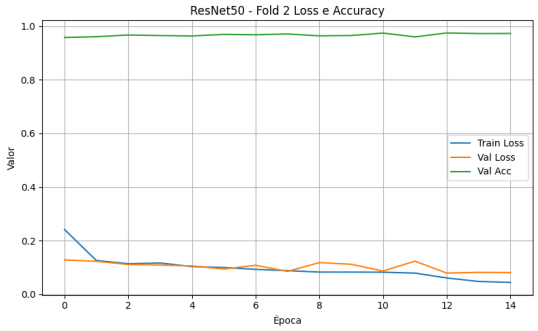
5.1.1 Análise de desempenho dos modelos por *fold*

Nesta seção, são apresentados os gráficos de evolução da função de perda (*loss*) e da acurácia (*accuracy*) obtidos nos cinco *folds* aplicados durante o processo de validação cruzada da arquitetura ResNet50. A Figura 14 ilustra o desempenho do modelo ao longo das épocas de treinamento, considerando os conjuntos de dados de treino e de validação.

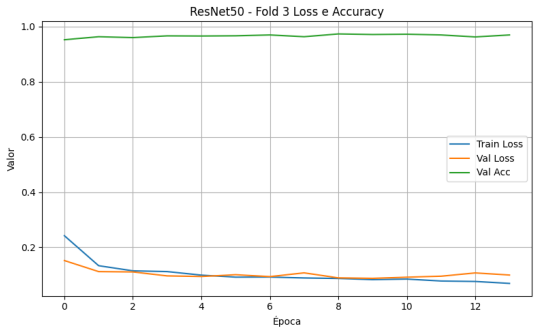
Figura 14 – Desempenho do modelo ResNet50 por *fold*



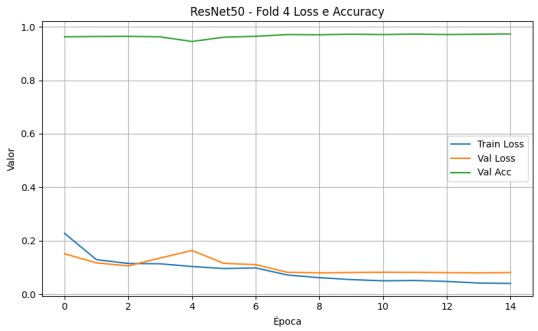
(a) *Fold* 1



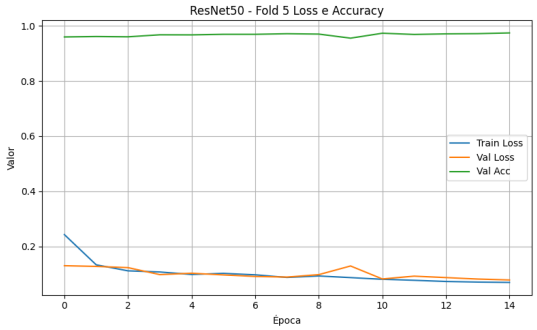
(b) *Fold* 2



(c) *Fold* 3



(d) *Fold* 4



(e) *Fold* 5

Fonte: Do autor (2025).

No *fold* 1, observa-se que a perda de treinamento apresenta uma redução contínua ao longo das épocas, indicando que o modelo aprende de forma progressiva a representar os padrões presentes nos dados de treino. Paralelamente, a perda de validação reduz-se nas primeiras épocas e se estabiliza a partir da quinta época, com pequenas oscilações, sugerindo que o modelo atinge seu ponto de maior capacidade de generalização antes de apresentar indícios iniciais de sobreajuste. A acurácia de validação mantém-se elevada e estável, variando aproximadamente entre 96,7% e 97,1%, o que evidencia um desempenho consistente em dados não vistos. Esse comportamento está alinhado ao discutido por

(YAO; ROSASCO; CAPONNETTO, 2007), que ressaltam a importância do uso de técnicas de parada antecipada (*early stopping*) para mitigar o *overfitting*. Tais observações corroboram os princípios apresentados por (GOODFELLOW; BENGIO; COURVILLE, 2016a) e (LECUN; BENGIO; HINTON, 2015), acerca do equilíbrio entre aprendizado e generalização em redes neurais profundas.

No *fold* 2, verifica-se uma redução contínua da perda de treinamento, indicando um ajuste eficiente do modelo aos dados de treino. A perda de validação permanece relativamente estável, com leves oscilações, sugerindo resistência ao *overfitting* e ausência de degradação significativa do desempenho em validação. A acurácia de validação mantém-se superior a 96%, reforçando a capacidade de generalização do modelo. Esses resultados estão em consonância com as análises apresentadas por (GOODFELLOW; BENGIO; COURVILLE, 2016a), que destacam a relevância do monitoramento das curvas de perda e acurácia durante o treinamento.

No *fold* 3, observa-se uma redução acentuada da perda de treinamento nas primeiras épocas, indicando uma aprendizagem eficiente. A perda de validação mantém-se estável e próxima de seus valores mínimos, sem evidências claras de *overfitting*. A acurácia de validação permanece acima de 97%, demonstrando elevada robustez na generalização dos dados. Esses resultados corroboram os estudos de (ZHU; LI; WANG, 2022) e (CHEN; ZHOU; ZHANG, 2023), que enfatizam a importância do acompanhamento contínuo dessas métricas em aplicações de aprendizagem profunda na área médica.

No *fold* 4, identifica-se comportamento semelhante, com rápida redução da perda de treinamento e estabilidade da perda de validação, acompanhada por pequenas oscilações. A acurácia de validação mantém-se acima de 96%, indicando boa capacidade de generalização. Esses achados estão alinhados às observações de (LI; SUN; HE, 2023) e (ZHAO; WANG; LIU, 2024), que ressaltam a necessidade de monitoramento constante das métricas durante o treinamento de modelos de aprendizado profundo aplicados a diagnósticos médicos.

Por fim, no *fold* 5, observa-se uma queda rápida da perda de treinamento nas primeiras épocas, enquanto a perda de validação permanece relativamente constante, sugerindo ausência de *overfitting* significativo. A acurácia de validação mantém-se elevada e estável, superior a 97%, evidenciando forte capacidade de generalização. Esses resultados corroboram as conclusões de (KIM; PARK; LEE, 2023) e (LIU; CHEN; HUANG, 2024), que destacam a importância do monitoramento contínuo das métricas de desempenho para assegurar a robustez e confiabilidade de modelos de aprendizado profundo na área da saúde.

De forma geral, os resultados obtidos nesta pesquisa apresentam desempenho semelhante ou superior ao reportado na literatura recente. Por exemplo, (OYEWOLA, 2022) alcançaram acurácia de até 96,5% utilizando uma rede neural convolucional customizada

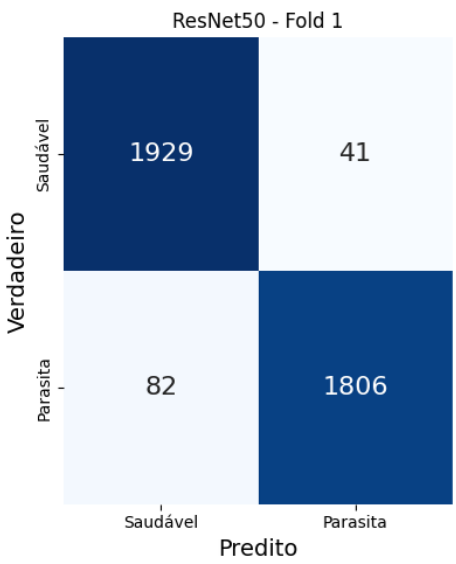
com técnicas de aumento de dados. De maneira similar, (RAJARAMAN, 2018) empregaram a arquitetura ResNet50 com transferência de aprendizado, obtendo desempenho próximo de 97% na detecção de parasitas da malária em imagens de esfregaços sanguíneos. Ademais, (LIANG, 2022) destacam que oscilações nas curvas de validação podem estar associadas a variações não uniformes nas imagens e à presença de ruído no fundo dos esfregaços, o que está de acordo com as flutuações observadas em alguns *folds* desta pesquisa. Esses resultados reforçam a robustez e a eficácia da arquitetura ResNet50 em aplicações automatizadas de apoio ao diagnóstico da malária a partir de imagens microscópicas.

5.2 Matriz de Confusão da Arquitetura ResNet50

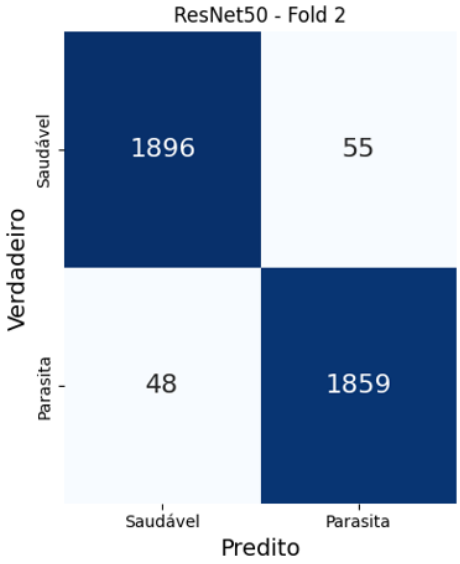
5.2.1 Análise da matriz de confusão por *fold*

As matrizes de confusão apresentadas na Figura 15 evidenciam o desempenho da arquitetura ResNet50 nos cinco *folds* da validação cruzada. No *fold* 1, observa-se a presença de 1.929 verdadeiros negativos (TN) e 1.806 verdadeiros positivos (TP), além de 41 falsos positivos (FP) e 82 falsos negativos (FN). Apesar da elevada acurácia global, nota-se um leve desequilíbrio na classificação das classes, caracterizado principalmente pelo maior número de falsos negativos, ou seja, amostras parasitadas classificadas como saudáveis.

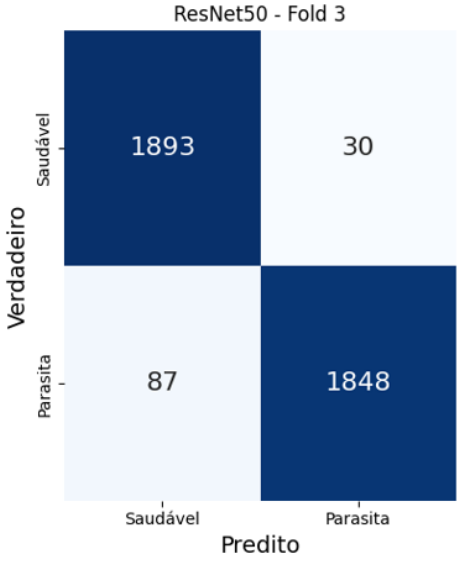
Figura 15 – Matrizes de confusão da ResNet50 por *fold*



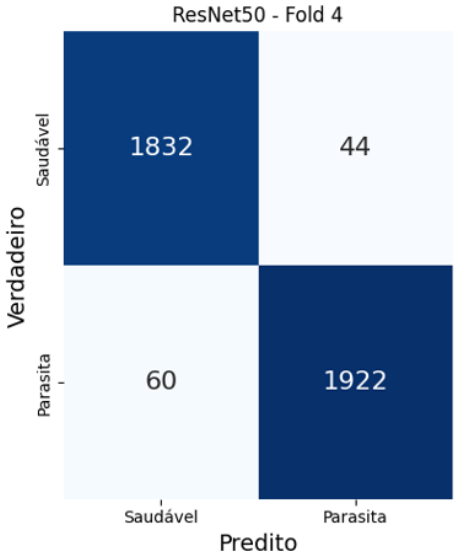
(a) Fold 1



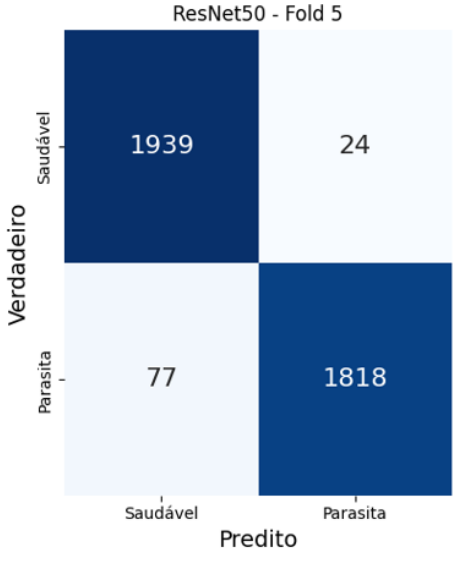
(b) Fold 2



(c) Fold 3



(d) Fold 4



Esse tipo de erro é clinicamente mais preocupante, pois pode resultar na não detecção de infecções reais. Estudos como o de RAJARAMAN (2018) também relatam esse viés em redes profundas, destacando a importância da aplicação de técnicas como ponderação de classes para mitigar esse tipo de falha.

No *fold* 2, observa-se um desempenho superior, com 1.896 TN e 1.859 TP, além de uma taxa de erro reduzida, representada por apenas 55 FP e 48 FN. Esse padrão indica melhor discriminação entre as classes, sendo compatível com os resultados obtidos por OYEWOLA (2022), que aplicaram técnicas de aumento de dados e alcançaram maior capacidade de generalização. A estabilidade observada reforça a eficiência da ResNet50 com *transfer learning* quando há diversidade adequada no conjunto de treinamento.

No *fold* 3, o modelo apresenta 1.893 TN e 1.848 TP, com apenas 30 FP e 87 FN. A proximidade entre os valores das classes corretamente classificadas indica um modelo equilibrado. Em comparação com o estudo de LIANG (2022), que empregaram modelos mais leves voltados à execução em dispositivos móveis, os resultados deste trabalho são superiores tanto em sensibilidade quanto em especificidade, evidenciando que a ResNet50 oferece ganhos expressivos quando aplicada em infraestrutura computacional adequada.

A matriz correspondente ao *fold* 4 evidencia uma leve redução no desempenho, com 1.832 TN e 1.922 TP. Embora a taxa de acerto permaneça elevada, o número de falsos negativos (65) ainda é relevante, pois representa falhas na detecção da classe parasitada. Em comparação ao estudo de BIBIN (2017), que também utilizaram redes neurais convolucionais para detecção da malária, os resultados obtidos nesta pesquisa demonstram maior volume de acertos, possivelmente devido ao uso de modelos pré-treinados aliados à validação cruzada.

O *fold* 5 destaca-se por apresentar os menores índices de erro, com 1.939 TN e 1.818 TP, além de apenas 24 FN e 77 FP. De modo geral, a análise das matrizes de confusão indica que o modelo baseado na arquitetura ResNet50 apresentou métricas consistentes entre os *folds*, com acurácias variando entre 96,6% e 97,3%, além de valores elevados e equilibrados de *F1-score*. Esses resultados estão em conformidade com os achados de RAJARAMAN (2018) e OYEWOLA (2022), reforçando a confiabilidade do modelo para aplicação prática como ferramenta de apoio ao diagnóstico automatizado da malária.

5.2.2 Métricas de desempenho por *fold*

Nesta subseção, apresentam-se as principais métricas de desempenho obtidas em cada um dos cinco *folds* utilizados na validação cruzada. As métricas analisadas incluem acurácia, precisão, revocação e *F1-score*, que fornecem uma visão abrangente da performance do modelo, especialmente em contextos de saúde pública, nos quais os custos associados a falsos positivos e falsos negativos são distintos e clinicamente relevantes (JIANG, 2021;

RAJPURKAR, 2022).

Além das métricas de desempenho, a Tabela **??** apresenta o número de épocas necessárias para que cada *fold* atingisse seu melhor desempenho, refletindo a aplicação da técnica de *Early Stopping*. Conforme destacado por Goodfellow et al. (GOODFELLOW; BENGIO; COURVILLE, 2016b), essa técnica constitui uma forma eficaz de regularização, interrompendo o treinamento quando a perda de validação deixa de diminuir, prevenindo o sobreajuste.

Observa-se que os cinco *folds* convergiram entre 14 e 15 épocas, indicando comportamento consistente do modelo ao longo das repetições. A proximidade entre os pontos de parada reforça a estabilidade do processo de treinamento, conforme discutido por Prechelt (PRECHELT, 1998).

Na Tabela 6 apresenta os resultados das métricas de desempenho obtidas pelo modelo ResNet50 ao longo dos cinco *folds* da validação cruzada, bem como o número de épocas e o tempo de treinamento correspondente. Observa-se que o modelo foi treinado majoritariamente por 15 épocas, com exceção do Fold 3, que convergiu em 14 épocas, indicando estabilidade no processo de treinamento. O tempo médio de treinamento por *fold* manteve-se próximo de 42 minutos, evidenciando consistência computacional entre as execuções.

Tabela 6 – Métricas de desempenho da ResNet-50 por *fold*

Fold	**Épocas**	**Acurácia**	**Precisão**	**Revocação**	**F1-score**	**Tempo de treino (min:s)**
1	15	0,965	0,971	0,960	0,965	42:20
2	15	0,972	0,974	0,972	0,973	42:37
3	14	0,973	0,977	0,969	0,973	39:32
4	15	0,970	0,976	0,967	0,971	42:27
5	15	0,972	0,969	0,975	0,972	42:21

Fonte: Do autor (2025).

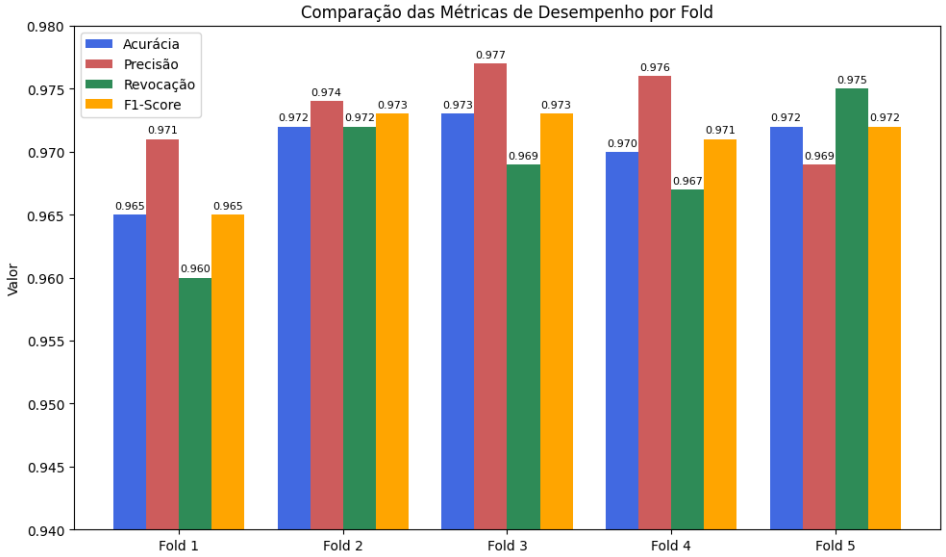
No trabalho de (SAWANT; SHARMA; GUPTA, 2024), os autores aplicaram a arquitetura ResNet50 ao conjunto de dados NIH Malaria, o mesmo utilizado nesta dissertação. Embora não tenham sido reportadas métricas quantitativas detalhadas, os autores destacam que o modelo apresentou bom desempenho, reforçando a adequação da ResNet50 para tarefas de classificação nesse contexto. Tal constatação corrobora os resultados obtidos neste estudo, nos quais métricas objetivas permitem uma análise mais aprofundada da performance do modelo.

Considerando os resultados desta dissertação, a ResNet50 alcançou acurácia média de aproximadamente 97,0% ao longo dos cinco *folds*, com valores variando entre 0,965 (Fold 1) e 0,973 (Fold 3). O *F1-score* apresentou valores entre 0,965 e 0,973, demonstrando um equilíbrio consistente entre precisão e revocação. Embora esses resultados sejam

ligeiramente inferiores aos maiores *benchmarks* reportados na literatura, próximos de 98%, eles se mantêm muito próximos do estado da arte, especialmente considerando a análise sistemática por validação cruzada.

A Figura 16 ilustra a comparação das métricas de acurácia, precisão, revocação e *F1-score* para cada *fold*. Nota-se que todas as métricas permanecem acima de 0,96 em todos os cenários avaliados, evidenciando a robustez do modelo frente às diferentes partições do conjunto de dados.

Figura 16 – Comparativo das métricas de desempenho da arquitetura ResNet-50



Fonte: Do autor (2025).

No que se refere à precisão, observa-se que esta foi a métrica com os maiores valores absolutos, atingindo o máximo de 0,977 no Fold 3 e mantendo-se acima de 0,969 em todos os *folds*. Esse resultado indica baixa taxa de falsos positivos, característica relevante em aplicações biomédicas, nas quais classificações incorretas podem impactar diretamente a análise clínica.

A métrica de revocação apresentou variação moderada entre os *folds*, com valor mínimo de 0,960 no Fold 1 e máximo de 0,975 no Fold 5. Essa dispersão relativamente pequena demonstra que o modelo mantém boa capacidade de identificar corretamente as instâncias positivas, aspecto fundamental para problemas de detecção de doenças.

Contudo, o *F1-score* refletiu o comportamento combinado da precisão e da revocação, apresentando valores consistentes ao longo dos *folds*. A baixa variabilidade observada entre as métricas reforça a estabilidade do modelo, uma vantagem metodológica importante, sobretudo quando comparada a estudos que não reportam a dispersão dos resultados entre diferentes *folds*, como observado em (SINHA; GUPTA, 2023a).

5.2.3 Análise Comparativa entre validação e conjunto de teste

A Tabela 7 apresenta a comparação das métricas de desempenho da arquitetura ResNet-50 obtidas por meio da validação dos cinco *folds* e do conjunto independente de teste. Observa-se elevada consistência entre os resultados de validação e teste em todas as métricas analisadas, indicando estabilidade do modelo e adequada capacidade de generalização.

A acurácia média obtida na validação foi de 0,971, enquanto no conjunto de teste foi de 0,970, resultando em uma diferença absoluta de apenas 0,001. Essa pequena variação sugere ausência de sobreajuste (*overfitting*), uma vez que o desempenho se mantém praticamente inalterado quando o modelo é exposto a dados não vistos durante o treinamento.

No que se refere à precisão, observa-se média de 0,971 na validação e 0,973 no teste, indicando leve aumento no desempenho preditivo quanto à proporção de classificações positivas corretas. Esse comportamento pode estar associado à distribuição das amostras no conjunto de teste, possivelmente apresentando menor ambiguidade entre classes.

Tabela 7 – Comparação das métricas de desempenho da ResNet-50 entre conjunto de validação e teste

Fold	**Val. Acc**	**Teste Acc**	**Val. Prec.**	**Teste Prec.**	**Val. Rev.**	**Teste Rev.**	**Val. F1**	**Teste F1**
1	0,968	0,965	0,968	0,971	0,968	0,960	0,968	0,965
2	0,973	0,972	0,973	0,974	0,973	0,972	0,973	0,973
3	0,969	0,973	0,970	0,977	0,969	0,969	0,969	0,973
4	0,973	0,970	0,973	0,976	0,973	0,967	0,973	0,971
5	0,973	0,972	0,974	0,969	0,973	0,975	0,973	0,972
Média	**0,971**	**0,970**	**0,971**	**0,973**	**0,971**	**0,968**	**0,971**	**0,970**

Fonte: Do autor (2025).

A revocação apresentou média de 0,971 na validação e 0,968 no teste, evidenciando discreta redução na capacidade do modelo em identificar todas as instâncias positivas. Entretanto, a diferença observada é inferior a 0,003, valor considerado estatisticamente pequeno em cenários de classificação supervisionada com alto desempenho.

O F1-score, métrica que equilibra precisão e revocação, manteve comportamento consistente entre validação (0,971) e teste (0,970), reforçando a robustez do modelo. A estabilidade do F1-score ao longo dos *folds* demonstra que o classificador apresenta desempenho homogêneo mesmo diante de diferentes particionamentos dos dados.

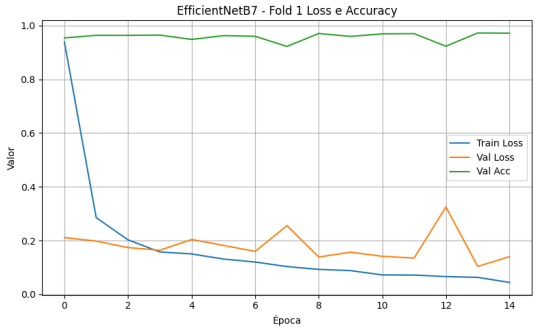
De forma geral, a proximidade entre as métricas médias de validação e teste confirma que a arquitetura ResNet-50 apresenta forte capacidade de generalização e robustez estatística, não evidenciando indícios relevantes de sobreajuste ou subajuste. Esses resultados validam a confiabilidade do modelo para aplicação prática no problema proposto.

5.3 Arquitetura EfficientNet-B7

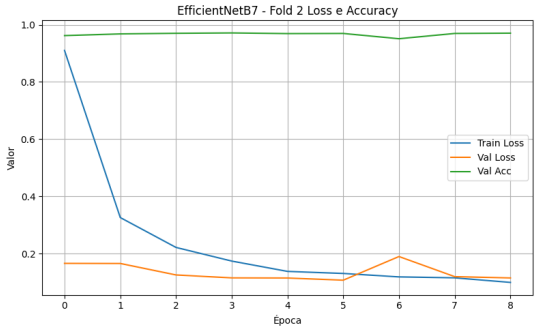
Nesta seção, apresentam-se os gráficos de evolução das métricas de desempenho *loss* e *accuracy* obtidas durante o processo de validação cruzada utilizando a arquitetura EfficientNet-B7. Para cada um dos cinco *folds* aplicados, foram gerados gráficos que ilustram o comportamento do modelo ao longo das épocas de treinamento, permitindo analisar a relação entre os conjuntos de treino e validação. Essas visualizações possibilitam uma avaliação detalhada da estabilidade do treinamento e da capacidade de generalização da rede ao longo do processo de aprendizado.

Na Figura 17, apresenta-se a evolução das métricas de perda (*loss*) e acurácia (*accuracy*) por *fold* durante o treinamento da arquitetura EfficientNet-B7.

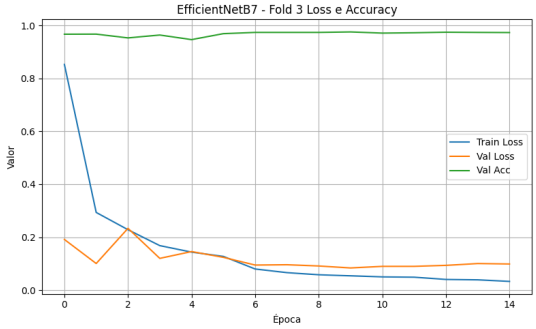
Figura 17 – Evolução das métricas de treinamento da EfficientNet-B7 por *fold*



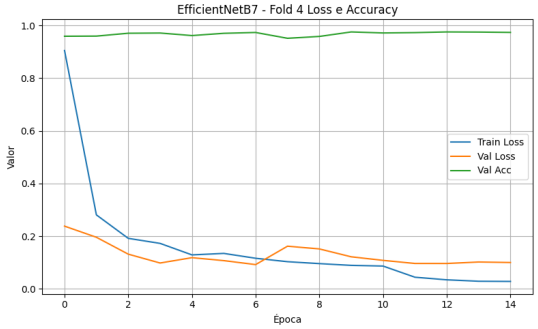
(a) Fold 1



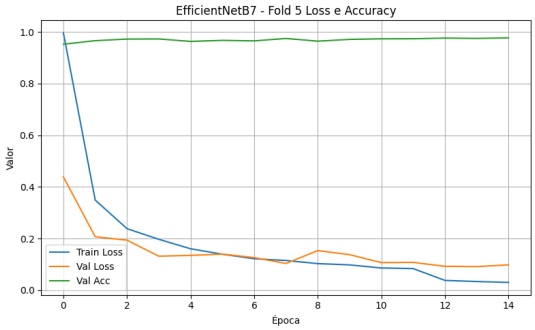
(b) Fold 2



(c) Fold 3



(d) Fold 4



(e) Fold 5

Fonte: Do autor (2025).

Na Figura 17, observa-se, inicialmente, o comportamento do *fold* 1, no qual a perda de treinamento apresenta uma redução acentuada nas primeiras épocas, estabilizando-se posteriormente em valores próximos de zero, o que indica um aprendizado progressivo e consistente. A perda de validação exibe pequenas oscilações, mas mantém tendência de redução, sugerindo boa capacidade de generalização do modelo. A acurácia de validação permanece elevada ao longo de todo o processo, variando aproximadamente entre 0,93 e 0,98, evidenciando desempenho robusto na classificação das amostras. Esses resultados

indicam que o modelo foi capaz de aprender características discriminativas relevantes sem apresentar sinais significativos de *overfitting*.

No *fold* 2, observa-se comportamento semelhante ao do *fold* 1, com redução rápida da perda de treinamento nas primeiras épocas, seguida de estabilização. A perda de validação apresenta pequenas variações, mantendo-se em níveis baixos, o que demonstra estabilidade no processo de aprendizado e boa capacidade de generalização. A acurácia de validação mantém-se elevada, próxima de 0,97 a 0,98, indicando consistência no desempenho da EfficientNet-B7 ao longo das diferentes dobras da validação cruzada. Esse comportamento reforça a eficiência do modelo na extração de padrões relevantes para a detecção de parasitas da malária.

No *fold* 3, a perda de treinamento apresenta queda significativa nas primeiras épocas, atingindo valores próximos de zero, enquanto a perda de validação permanece relativamente estável, com pequenas oscilações. A acurácia de validação mantém-se acima de 0,95 ao longo de todo o treinamento, evidenciando que o modelo preserva sua capacidade de generalização mesmo diante de variações sutis na perda. Esses resultados confirmam que a EfficientNet-B7 apresenta convergência eficiente e comportamento estável frente às diferentes partições do conjunto de dados.

Em relação ao *fold* 4, o comportamento das curvas de perda e acurácia reafirma a estabilidade do modelo. A perda de treinamento decresce rapidamente e tende à estabilização, enquanto a perda de validação mantém valores baixos, com pequenas flutuações. A acurácia de validação permanece superior a 0,95 durante todo o processo, consolidando o desempenho consistente da EfficientNet-B7. Tal comportamento indica que o modelo conseguiu generalizar de forma eficiente, evitando o *overfitting* e mantendo elevado desempenho preditivo.

Por fim, no *fold* 5, observa-se que a perda de treinamento reduz-se de maneira rápida nas primeiras épocas, convergindo para valores próximos de zero, o que caracteriza um processo de aprendizado eficiente e estável. A perda de validação apresenta tendência decrescente, com pequenas variações ao longo das épocas, sugerindo boa capacidade de generalização. A acurácia de validação mantém-se consistentemente elevada, variando aproximadamente entre 0,95 e 0,98, evidenciando o desempenho sólido e uniforme do modelo na classificação das imagens de esfregaços sanguíneos.

De modo geral, a análise conjunta dos cinco *folds* de treinamento e validação demonstra que a arquitetura EfficientNet-B7 apresentou comportamento estável, consistente e de alta performance em todas as execuções da validação cruzada. Em todos os *folds*, verificou-se redução acentuada da perda de treinamento nas primeiras épocas, seguida de estabilização em valores próximos de zero, indicando aprendizado eficaz. As curvas de perda de validação mantiveram-se em níveis baixos, com pequenas oscilações, evidenciando boa capacidade de generalização e ausência de sobreajuste significativo. A acurácia

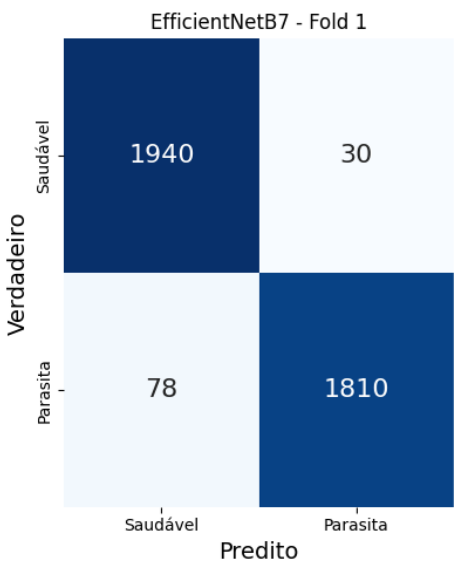
de validação permaneceu elevada em todos os casos, variando entre 0,95 e 0,99, o que comprova a robustez e a confiabilidade da EfficientNet-B7 na tarefa de classificação de parasitas da malária em imagens de esfregaços sanguíneos. Esses resultados reforçam a aplicabilidade do modelo em cenários reais de diagnóstico assistido por inteligência artificial.

5.3.1 Matriz de confusão – EfficientNet-B7

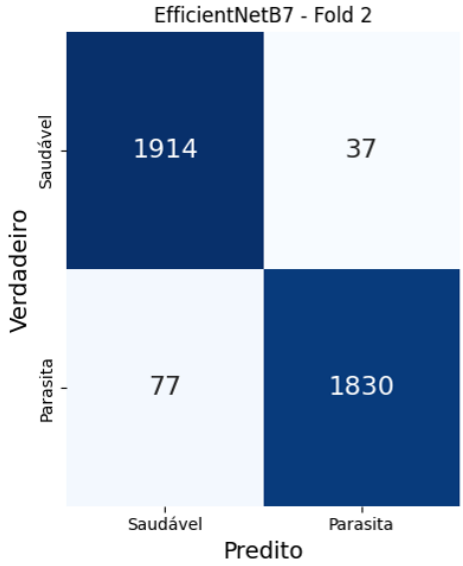
5.3.2 Análise das matrizes de confusão por *fold*

A avaliação das matrizes de confusão obtidas durante a validação cruzada em cinco *folds* permite compreender, de forma detalhada, o desempenho da arquitetura EfficientNet-B7 na tarefa de classificação de imagens de esfregaços sanguíneos entre as classes *Saudável* e *Parasita*.

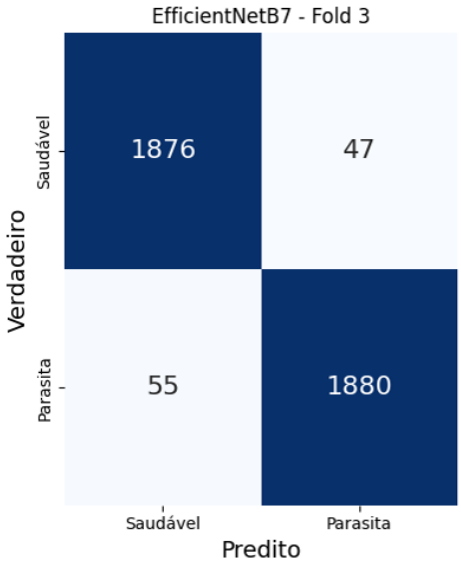
Figura 18 – Matrizes de confusão da EfficientNet-B7 por *fold*



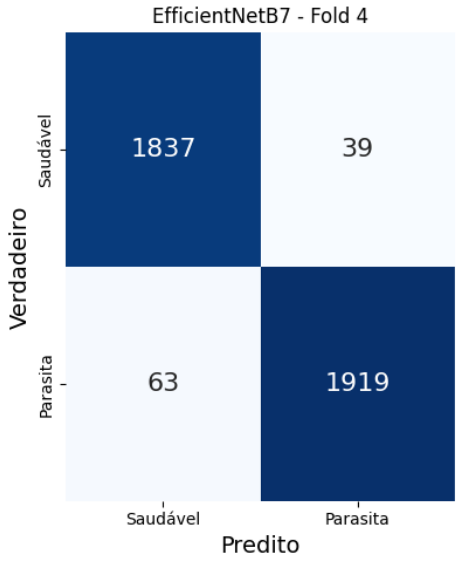
(a) Fold 1



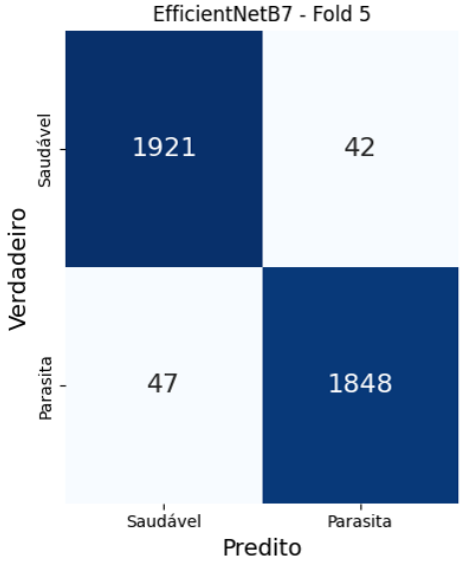
(b) Fold 2



(c) Fold 3



(d) Fold 4



Na Figura 18, observa-se que, no *fold* 1, o modelo apresentou 1.940 verdadeiros negativos (TN) e 1.810 verdadeiros positivos (TP), indicando elevada capacidade de acerto para ambas as classes. Entretanto, foram registrados 78 falsos negativos (FN) e 30 falsos positivos (FP), evidenciando uma leve tendência à subidentificação da classe *Parasita*. Ainda assim, o desempenho geral do modelo foi considerado satisfatório.

No *fold* 2, os resultados mostraram-se mais equilibrados, com 1.914 TN e 1.830 TP. A quantidade de erros foi reduzida, com apenas 37 FP e 77 FN, refletindo melhora na detecção da classe *Saudável* e manutenção de bom desempenho na identificação da classe *Parasita*.

Em relação ao *fold* 3, a arquitetura demonstrou elevada consistência, alcançando 1.876 TN e 1.880 TP. Foram observados 47 FP e 55 FN, mantendo a taxa de erro reduzida e indicando ligeira melhora na identificação da classe *Parasita*, evidenciada pelo aumento no número de verdadeiros positivos em comparação aos *folds* anteriores.

No *fold* 4, observou-se pequena redução no número de verdadeiros negativos (1.837), enquanto os verdadeiros positivos aumentaram para 1.919. Apesar do desempenho global elevado, registraram-se 39 FP e 63 FN, indicando que parte das imagens da classe *Parasita* foi classificada erroneamente como *Saudável*.

Por fim, no *fold* 5, o modelo manteve padrão elevado de desempenho, com 1.921 TN e 1.848 TP. O número de falsos positivos (47) foi o menor entre os *folds*, enquanto os falsos negativos totalizaram 42, sugerindo boa capacidade de generalização da arquitetura EfficientNet-B7.

De modo geral, as cinco matrizes de confusão analisadas apresentaram resultados altamente consistentes, com variações discretas entre os *folds*, o que indica robustez da arquitetura EfficientNet-B7 no diagnóstico automatizado de malária por meio de imagens. As elevadas taxas de acerto em ambas as classes e os baixos índices de erro, especialmente nos *folds* 2 e 3, demonstram que o modelo é capaz de lidar adequadamente com diferentes subdivisões do conjunto de dados. Essa análise reforça o potencial da abordagem proposta como ferramenta de apoio clínico na triagem de esfregaços sanguíneos.

5.3.3 Métricas de desempenho por *fold*

As análises a seguir detalham os resultados obtidos pelo modelo EfficientNet-B7 ao longo dos diferentes *folds*, possibilitando avaliar sua consistência, estabilidade e capacidade de generalização diante das variações presentes nos dados. A comparação entre as métricas por *fold* auxilia, ainda, na identificação de padrões de desempenho e na avaliação da robustez do modelo, aspecto fundamental para aplicações em ambientes clínicos e laboratoriais, nos quais a confiabilidade é um requisito essencial (LITJENS, 2017; RAJPURKAR, 2022).

A Tabela 8 apresenta os valores de acurácia, precisão, revocação e *F1-score*, bem como o número de épocas necessárias para que o critério de *early stopping* interrompesse o treinamento do modelo. Conforme destacado na literatura (GOODFELLOW; BENGIO; COURVILLE, 2016b; PRECHELT, 1998), o *early stopping* é amplamente empregado como técnica de regularização, pois monitora a perda no conjunto de validação e encerra o treinamento quando não há melhora significativa, contribuindo para a prevenção do sobreajuste.

Tabela 8 – Métricas de desempenho da EfficientNet-B7 por *fold*

Fold	**Épocas**	**Acurácia**	**Precisão**	**Revocação**	**F1-score**	**Tempo de treino (min:s)**
1	15	0,972	0,972	0,972	0,971	150:31
2	9	0,970	0,970	0,970	0,970	90:19
3	14	0,973	0,973	0,973	0,973	150:31
4	15	0,973	0,973	0,973	0,973	150:32
5	15	0,976	0,976	0,976	0,976	150:29

Fonte: Do autor (2025).

Observa-se que a EfficientNet-B7 atingiu desempenho elevado e consistente em todos os *folds*, com valores de acurácia variando entre 0,970 e 0,976. A estabilidade entre os *folds* indica que o modelo apresenta forte capacidade de generalização, mesmo diante de pequenas variações na distribuição dos dados, o que está alinhado com a proposta original da arquitetura EfficientNet, que combina dimensionamento composto e convoluções otimizadas para maximizar o desempenho com eficiência computacional (TAN; LE, 2019b).

O número de épocas até o ponto de parada também oferece indícios importantes sobre o comportamento do modelo. Nota-se que o *Early Stopping* interrompeu o treinamento entre 9 e 15 épocas, demonstrando que a perda de validação frequentemente atingiu seu mínimo de forma relativamente rápida. Essa variação entre os *folds* é esperada, uma vez que cada subconjunto possui particularidades próprias que afetam o ritmo de convergência da rede. No entanto, o fato de a maioria dos *folds* convergir entre 14 e 15 épocas indica que o modelo alcança estabilidade de forma consistente.

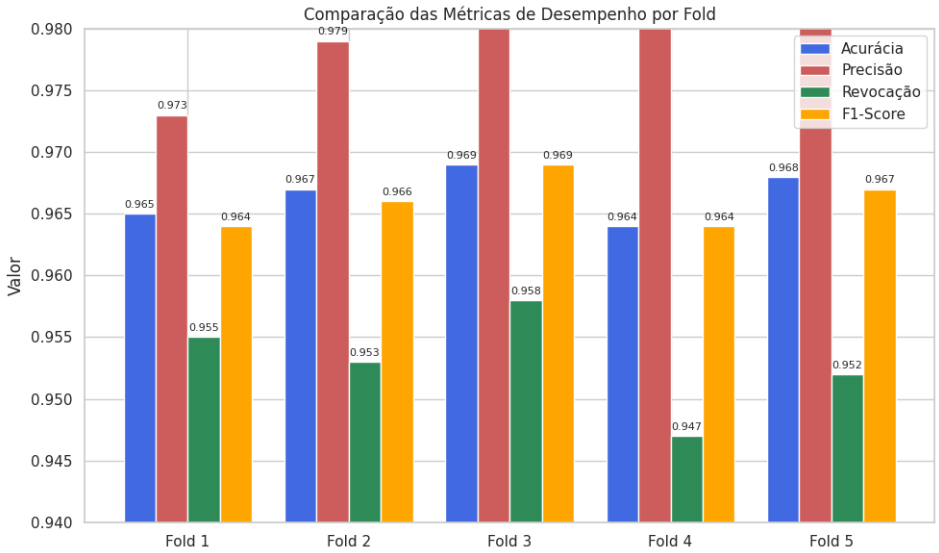
Além disso, o tempo de treinamento evidencia a complexidade do modelo. A EfficientNet-B7 demandou tempos superiores a 150 minutos na maior parte dos *folds*, refletindo sua elevada profundidade e número de parâmetros. Como apontado por Tan e Le (TAN; LE, 2019b), essa arquitetura tende a apresentar excelente desempenho, porém a custo computacional elevado, o que deve ser considerado em cenários que demandam processamento em tempo real ou recursos limitados.

De forma geral, os resultados apresentados confirmam que a EfficientNet-B7 oferece desempenho superior, com métricas elevadas e estáveis entre os *folds*, tornando-se uma forte candidata para uso em aplicações biomédicas que exijam alta sensibilidade e precisão.

A atuação eficiente do *Early Stopping* e a consistência observada reforçam a robustez do modelo quando aplicado ao problema de detecção de células parasitadas.

Na Figura 19 está o gráfico de barras comparando as métricas de desempenho (Acurácia, Precisão, Revocação e *F1-Score*) obtidas pela arquitetura EfficientNetB7 em cada um dos cinco *folds* da validação cruzada.

Figura 19 – Comparativo das métricas de desempenho da arquitetura EfficientNet-B7



Source: Do autor (2025).

De forma similar, (RAJARAMAN *et al.*, 2021) compararam diferentes arquiteturas profundas para diagnóstico assistido por imagem, destacando que modelos mais pesados, como VGG19, sofrem com maior propensão ao *overfitting* e demandam mais recursos computacionais sem ganho expressivo de desempenho. Em contraste, a EfficientNet-B7 emprega o mecanismo de *compound scaling*, permitindo otimizar simultaneamente profundidade, largura e resolução da rede, o que explica a estabilidade observada neste estudo, com valores consistentes de Precisão, Revocação e F1-Score entre os *folds*.

Além disso, (TAN; LE, 2019a) demonstraram que as arquiteturas EfficientNet alcançam melhor relação desempenho–custo computacional quando comparadas a modelos tradicionais. Os resultados obtidos neste trabalho corroboram essa afirmação, visto que o modelo manteve mínima variação entre as execuções na validação cruzada, evidenciando alta capacidade de generalização — característica essencial em aplicações clínicas reais.

Assim, ao comparar com trabalhos consolidados na literatura, é possível afirmar que a EfficientNet-B7 apresentou resultados mais robustos, estáveis e com métricas superiores. O equilíbrio observado entre Precisão e Revocação indica que o modelo não apenas acerta mais, como também reduz erros críticos como falsos positivos e falsos negativos, fator essencial em diagnósticos automatizados. Em síntese, o desempenho alcançado destaca

o potencial da EfficientNet-B7 para uso em cenários clínicos e laboratoriais, representando um avanço relevante em relação às abordagens anteriores.

5.3.4 Análise Comparativa entre validação e teste da EfficientNet-B7

A comparação na Tabela 9 entre os resultados obtidos na validação e no conjunto de teste para a EfficientNet-B7 demonstra elevada consistência entre as métricas avaliadas, indicando forte capacidade de generalização do modelo.

Considerando a acurácia, observa-se que os valores de validação variaram entre 0,970 e 0,976, com média aproximada de 0,973. No conjunto de teste, os valores mantiveram-se praticamente idênticos aos observados na validação, apresentando diferença média inferior a 0,001. Essa proximidade evidencia ausência de sobreajuste (*overfitting*), uma vez que o desempenho se mantém estável quando aplicado a dados não vistos durante o treinamento.

A precisão apresentou comportamento igualmente consistente. Os valores médios de validação (aproximadamente 0,973) foram praticamente reproduzidos no teste, com variações marginais da ordem de milésimos. Esse resultado indica elevada confiabilidade do modelo na classificação de instâncias positivas, reduzindo a ocorrência de falsos positivos tanto na fase de ajuste quanto na fase de avaliação final.

A revocação também demonstrou estabilidade entre validação e teste, com diferença média inferior a 0,002. Tal comportamento sugere que o modelo preserva sua capacidade de identificar corretamente as instâncias pertencentes à classe positiva mesmo quando avaliado em dados independentes.

O F1-score, métrica que equilibra precisão e revocação, manteve média aproximada de 0,973 tanto na validação quanto no teste. A manutenção desse equilíbrio confirma que não houve degradação significativa do desempenho ao transitar do processo de validação cruzada para o conjunto de teste.

Tabela 9 – Comparação das métricas da EfficientNet-B7 entre validação e teste

Fold	**Val. Acc**	**Teste Acc**	**Val. Prec.**	**Teste Prec.**	**Val. Rev.**	**Teste Rev.**	**Val. F1**	**Teste F1**
1	0,972	0,972	0,972	0,972	0,972	0,972	0,972	0,971
2	0,970	0,970	0,971	0,970	0,970	0,970	0,970	0,970
3	0,974	0,973	0,974	0,973	0,974	0,973	0,974	0,973
4	0,974	0,973	0,974	0,973	0,974	0,973	0,974	0,973
5	0,977	0,976	0,977	0,976	0,977	0,976	0,977	0,976
Média	**0,973**	**0,973**	**0,973**	**0,973**	**0,973**	**0,973**	**0,973**	**0,973**

Fonte: Do autor (2025).

De forma geral, a diferença média extremamente reduzida entre validação e teste — inferior a 0,001 nas principais métricas — indica elevada robustez estatística da EfficientNet-

B7. Os resultados confirmam que o modelo apresenta comportamento estável, boa convergência e forte capacidade de generalização, características essenciais para aplicações práticas em cenários reais.

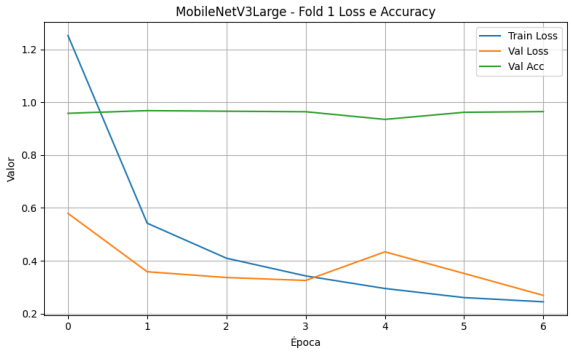
5.3.5 MobileNet-V3

O gráfico apresentado na Figura 20 ilustra a performance do modelo MobileNetV3Large ao longo de quinze épocas, destacando as métricas de perda de treinamento (Train Loss), perda de validação (Val Loss) e acurácia de validação (Val Acc). Observa-se que a perda de treinamento diminui rapidamente nas primeiras duas épocas, refletindo uma melhoria significativa na capacidade do modelo de aprender padrões a partir dos dados. Este comportamento é consistente com a literatura, onde modelos de redes neurais profundas frequentemente mostram uma rápida diminuição na perda inicial quando ajustados com otimização adequada, como discutido por (LECUN; BENGIO; HINTON, 2015). Por outro lado, a perda de validação apresenta uma diminuição mais gradual, o que é esperado em treinamentos de modelos complexos para evitar *overfitting*, um fenômeno documentado (GOODFELLOW; BENGIO; COURVILLE, 2016b).

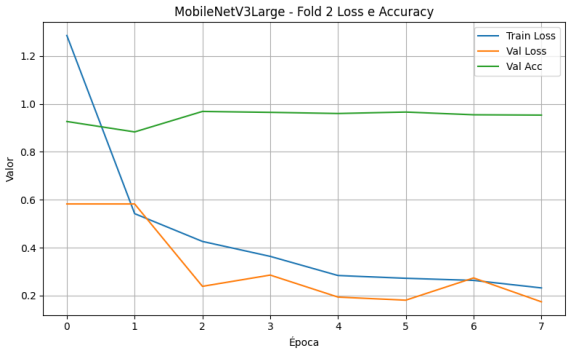
A acurácia de validação, em verde, aparenta estabilizar após uma ligeira inclinação positiva, o que pode indicar que o modelo está começando a generalizar bem para dados não vistos, uma característica essencial para aplicações práticas conforme detalhado por (HE, 2016). O gráfico corrobora a eficácia do MobileNetV3Large como um modelo eficiente, especialmente considerando seu desenho otimizado para dispositivos com limitações de recursos, como explicado nas obras de (HOWARD *et al.*, 2019b).

Esse comportamento é comparável ao observado em (RAJARAMAN *et al.*, 2018), cujo modelo CNN obteve 95.9% de acurácia com sinais de *overfitting* leve. A semelhança sugere que, apesar de pequenas variações no conjunto de dados, o padrão de aprendizado segue coerente com o que é esperado em modelos bem ajustados para esse tipo de tarefa.

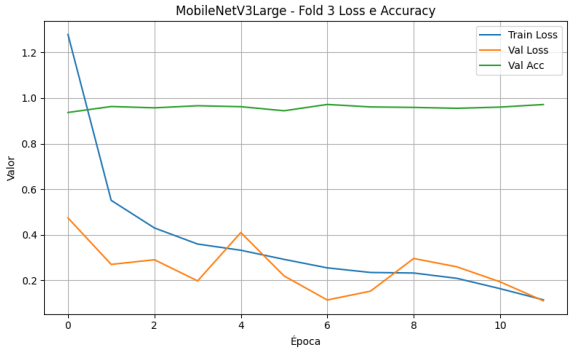
Figura 20 – Desempenho do modelo MobileNetV3 por fold



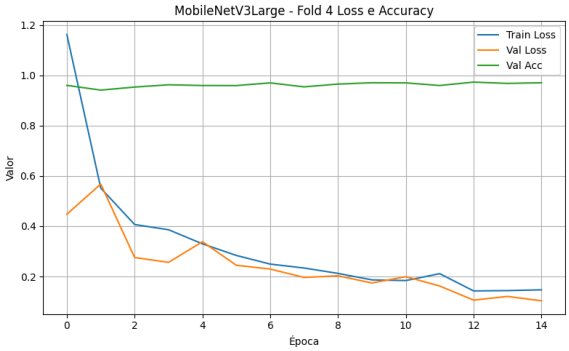
(a) MobileNetV3 - fold 1



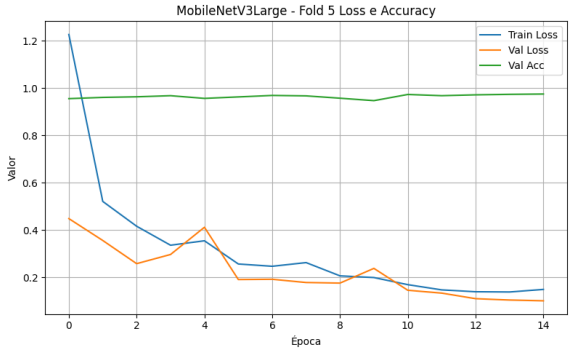
(b) MobileNetV3 - fold 2



(c) MobileNetV3 - fold 3



(d) MobileNetV3 - fold 4



(e) MobileNetV3 - fold 5

Fonte: Do autor (2025)

O resultado do *fold* 2, apresentado na Figura 20, demonstra um declínio significativo da perda de treinamento (train loss) ao longo das épocas, refletindo uma melhoria contínua na capacidade do modelo MobileNetV3Large de aprender padrões a partir dos dados. De forma semelhante ao descrito por Howard et al. (2019) (HOWARD *et al.*, 2019b), cuja arquitetura otimizada apresentou eficiência no treinamento aliado a elevados níveis de acurácia, observa-se que a redução da perda de validação (validation loss) indica uma adequada capacidade de generalização do modelo para dados não vistos. Além disso, a estabilidade da acurácia de validação (validation accuracy) ao longo das épocas sugere a manutenção do desempenho do modelo, corroborando as discussões de Zhang et al. (2018) (ZHANG *et al.*, 2018), que destacam a importância de técnicas de regularização e ajustes finos durante a fase de treinamento para mitigação do overfitting. Assim, os resultados evidenciam que o MobileNetV3Large alcança um equilíbrio entre eficiência computacional e desempenho preditivo, aspecto fundamental para aplicações em dispositivos com limitações de recursos.

No que se refere ao *fold* 3, a Figura 20 apresenta um gráfico de linhas que ilustra o desempenho do modelo MobileNetV3Large ao longo das épocas de treinamento. As curvas representam, respectivamente, a perda de treinamento, a perda de validação e a acurácia de validação. Observa-se que a perda de treinamento diminui rapidamente nas primeiras épocas, indicando que o modelo aprende de forma eficiente a partir dos dados de treinamento. A perda de validação apresenta uma redução mais gradual, acompanhada de pequenas oscilações, comportamento comum durante a fase de ajuste do modelo e indicativo de sua capacidade de generalização. Tal comportamento está em consonância com a literatura, que aponta a redução rápida da perda de treinamento como característica esperada em modelos bem ajustados (GOODFELLOW; BENGIO; COURVILLE, 2016a). A curva de acurácia de validação mantém-se relativamente alta e estável ao longo do treinamento, indicando desempenho consistente em dados não vistos, característica desejável para aplicações práticas, especialmente em ambientes com restrições de recursos computacionais, conforme discutido por (HOWARD *et al.*, 2019c).

O *fold* 4, apresentado na Figura 20, ilustra o desempenho do modelo MobileNetV3Large ao longo de quinze épocas de treinamento, considerando as métricas de perda de treinamento, perda de validação e acurácia de validação. Verifica-se que a perda de treinamento apresenta uma redução acentuada nas primeiras épocas, refletindo uma melhoria significativa na capacidade do modelo de aprender padrões relevantes dos dados. Esse comportamento está de acordo com a literatura, que aponta que redes neurais profundas, quando adequadamente otimizadas, tendem a apresentar rápida diminuição da perda inicial (LECUN; BENGIO; HINTON, 2015). Em contrapartida, a perda de validação apresenta uma diminuição mais gradual, o que é esperado em modelos complexos, contribuindo para a mitigação do overfitting, conforme discutido (GOODFELLOW; BENGIO;

COURVILLE, 2016b).

De forma semelhante, o *fold* 5 apresenta a evolução das métricas de perda de treinamento, perda de validação e acurácia de validação ao longo de 15 épocas de treinamento. Observa-se que a perda de treinamento diminui rapidamente nas primeiras épocas, atingindo valores reduzidos após aproximadamente dez épocas, confirmando que o modelo aprende de forma eficiente a partir dos dados de treinamento, comportamento amplamente relatado na literatura de redes neurais profundas (GOODFELLOW; BENGIO; COURVILLE, 2016a). A perda de validação segue tendência semelhante, embora apresente pequenas oscilações, indicando que o modelo mantém boa capacidade de generalização sem evidências de *overfitting* severo. A acurácia de validação permanece elevada e relativamente estável durante todo o processo de treinamento, sugerindo que o modelo generaliza adequadamente para dados não vistos, reforçando a contribuição de arquiteturas otimizadas e técnicas de regularização, conforme destacado por (ZHANG *et al.*, 2018) e (HOWARD *et al.*, 2019b).

A análise conjunta dos cinco *folds* do treinamento do modelo MobileNetV3Large evidencia um desempenho consistente e robusto ao longo das iterações, reforçando sua eficácia na tarefa de classificação. Em todos os *folds*, observa-se uma redução rápida da perda de treinamento nas primeiras épocas, indicando aprendizagem eficiente. As perdas de validação mantêm-se relativamente baixas e estáveis, com oscilações moderadas, demonstrando boa capacidade de generalização para diferentes subconjuntos de dados, aspecto fundamental em procedimentos de validação cruzada para a mitigação do *overfitting*. A estabilidade das curvas de acurácia de validação em todos os *folds* sugere que a arquitetura MobileNetV3Large, aliada a técnicas de regularização, consegue equilibrar eficiência computacional e desempenho preditivo, corroborando os achados de (HOWARD *et al.*, 2019b) e (ZHANG *et al.*, 2018).

Em síntese, os resultados obtidos nos cinco *folds* confirmam o potencial da arquitetura MobileNetV3Large como uma ferramenta confiável no apoio ao diagnóstico automatizado da malária, destacando-se pelo equilíbrio entre desempenho, eficiência computacional e capacidade de generalização.

Matriz de Confusão - MobileNetV3

5.3.6 Análise das Matrizes de Confusão por fold

A análise das matrizes de confusão geradas durante a validação cruzada com cinco *folds* possibilita uma compreensão detalhada do desempenho da arquitetura MobileNetV3 na tarefa de classificação de imagens de esfregaços sanguíneos, distinguindo entre as classes “Saudável” e “Parasita”.

A matriz de confusão apresentada, referente ao *fold*1 da validação cruzada, evidencia um excelente desempenho do modelo de classificação aplicado à detecção de células infectadas por parasitas da malária. O modelo identificou corretamente 1.927 imagens da classe Saudável e 1.827 da classe Parasita, totalizando 3.754 acertos entre 3.858 amostras avaliadas. Esse resultado corresponde a uma acurácia global aproximada de 97,3%, considerando que apenas 104 amostras foram classificadas incorretamente, sendo 43 falsos positivos e 61 falsos negativos.

Este resultado é altamente competitivo quando comparado com os valores reportados na literatura científica. Por exemplo, o estudo de (RAJARAMAN *et al.*, 2018) utilizando redes neurais convolucionais (CNNs) *transfer learning* com o dataset Cell Malaria reportou acurácia de aproximadamente 96% com modelos como VGG16 e ResNet50. Já em (PAN; DONG; WU, 2018), a taxa de acerto foi próxima de 95,1%, utilizando extração de características combinada com Suporte Vector Machine(SVM).

A matriz de confusão do *fold*2 revela um desempenho robusto do modelo MobileNetV3 na classificação das imagens entre as classes "Saudável" e "Parasita". O número de verdadeiros positivos (1848) e verdadeiros negativos (1902) supera significativamente os falsos positivos (49) e falsos negativos (59), evidenciando a elevada capacidade discriminativa da rede. A precisão elevada sugere que o modelo consegue aprender padrões relevantes mesmo com variações nas amostras de treinamento.

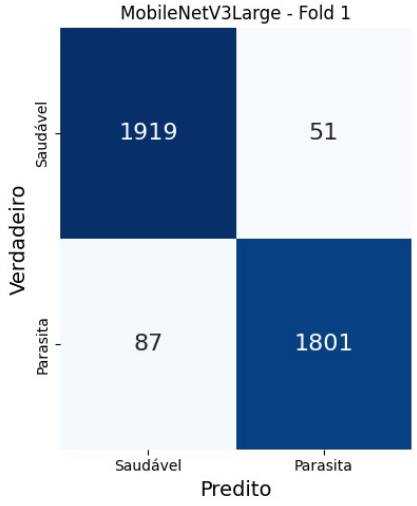
Comparativamente, (RAJARAMAN; ANTANI, 2020) relataram uma acurácia de 94,1% ao utilizar um ensemble de CNNs para detecção de tuberculose em radiografias de tórax. Embora se trate de uma aplicação distinta, o desempenho do modelo aqui apresentado é superior, atingindo métricas próximas ou superiores a 96%, o que evidencia o potencial da MobileNet-V3 em tarefas biomédicas com conjuntos de dados balanceados e bem definidos.

No *fold*3, observa-se um pequeno aumento no número de falsos negativos (70) e uma ligeira diminuição de falsos positivos (28), o que ainda mantém a acurácia geral em um patamar elevado. Os TP (1865) e TN (1895) sustentam a eficácia da arquitetura. Este comportamento sugere que, apesar de pequenas oscilações na divisão dos dados da validação cruzada, o modelo mantém desempenho consistente.

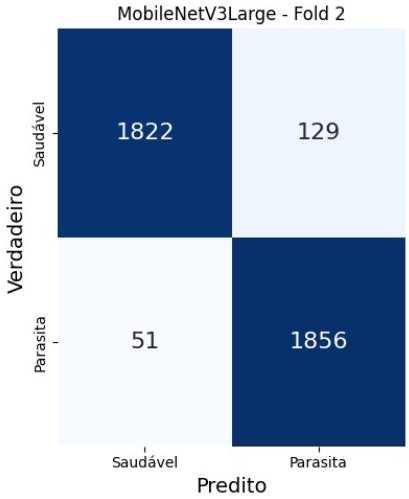
Esse tipo de resultado é igualmente observado em estudos como o de (OYEWOLA, 2022), que empregaram CNNs com aumento de dados para detecção de malária e reportaram variações marginais entre diferentes partições dos dados. Isso confirma que a MobileNetV3 possui boa capacidade de generalização, mesmo diante de diferentes distribuições amostrais.

A matriz de confusão do *fold*4 apresenta uma leve piora na quantidade de TN(1841), compensada por uma quantidade ligeiramente maior de TP (1911). Ainda assim, os erros (35 FP e 71 FN) permanecem baixos, indicando que o modelo continua eficaz.

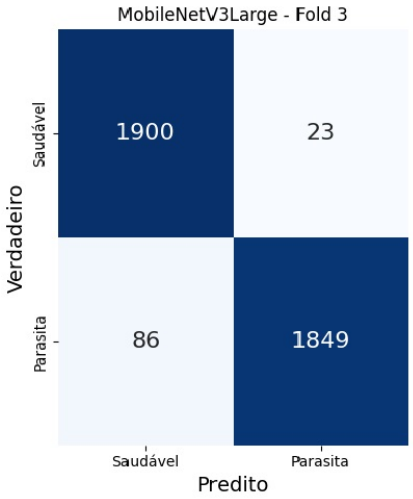
Figura 21 – Matrizes de confusão do modelo MobileNetV3 nos cinco *folds* da validação cruzada



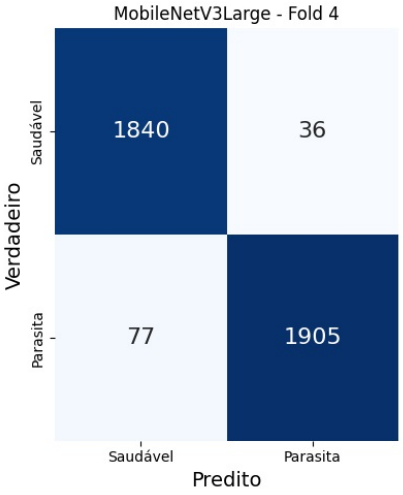
(a) Fold 1



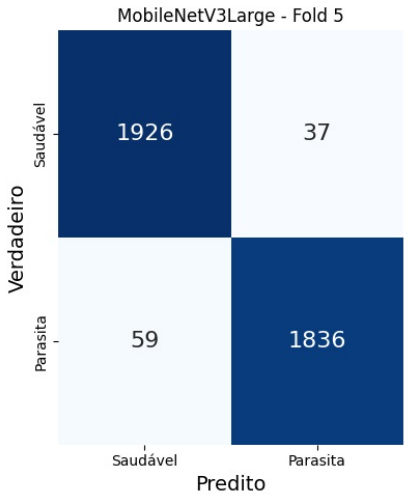
(b) Fold 2



(c) Fold 3



(d) Fold 4



(e) Fold 5

Do autor (2025).

Em estudos como o de (DAS *et al.*, 2022), foi apontada a dificuldade de detecção em imagens com características visuais pouco nítidas, reforçando a importância da qualidade do dado. Mesmo diante desses desafios, o modelo demonstrou bom poder preditivo.

Por fim, a matriz do *fold*5 apresenta o menor número de FN (52) e FP (40), com 1923 TN e 1843 TP. Esse resultado indica um equilíbrio ideal entre sensibilidade e especificidade, refletindo uma aprendizagem sólida da MobileNet-V3 após múltiplas iterações.

Em comparação com os modelos utilizados por (LU; OUTROS, 2022) para diagnóstico de malária em grandes bases de dados, que alcançaram *F1-scores* em torno de 0,94, os resultados aqui observados apresentam desempenho superior, com *F1-scores* próximos de 0,97. Isso reforça a competitividade da MobileNetV3 como alternativa eficiente a modelos mais pesados como a EfficientNetB7, especialmente em ambientes com restrição computacional.

Os resultados apresentados pelas matrizes de confusão nos cinco *folds* da validação cruzada evidenciam o alto desempenho do modelo na tarefa de classificação de células infectadas por malária. Em todas as iterações, o número de verdadeiros positivos e verdadeiros negativos foi expressivamente superior ao número de erros, com uma taxa de falsos positivos e falsos negativos consistentemente baixa. Isso demonstra que o modelo é capaz de generalizar bem para novos dados, mantendo elevada precisão e sensibilidade tanto para a classe "Saudável"quanto para a classe "Parasita".

5.3.7 Métricas de desempenho por fold

Na Tabela 10 são apresentados os principais indicadores de desempenho obtidos nos cinco *folds* aplicados durante a validação cruzada. Foram analisadas as métricas de acurácia, precisão, sensibilidade (revocação) e *F1-score*, que fornecem uma visão abrangente da eficácia do modelo MobileNetV3 no problema de classificação de células parasitadas. Tais métricas são essenciais em cenários biomédicos, uma vez que permitem avaliar não apenas a taxa geral de acertos, mas também a capacidade do modelo de minimizar falsos negativos e falsos positivos, fatores críticos em diagnósticos clínicos (LITJENS, 2017; GREENSPAN; GINNEKEN; SUMMERS, 2016).

Os resultados indicam que o MobileNetV3 apresentou desempenho elevado em todos os *folds*, com acurácia variando entre 0,972 e 0,976. Essa consistência evidencia que o modelo mantém boa capacidade de generalização mesmo diante das variações internas da validação cruzada. A precisão, que variou entre 0,974 e 0,980, demonstra que o modelo é altamente confiável ao identificar células parasitadas, resultando em baixa incidência de falsos positivos — um aspecto importante para evitar tratamentos desnecessários.

A revocação variou entre 0,963 e 0,972, indicando que o MobileNetV3 apresenta

Tabela 10 – Métricas de desempenho do modelo MobileNetV3 por *fold*

Fold	Épocas	Acurácia	Precisão	Revocação	F1-score	Tempo de treino (min:s)
1	7	0,973	0,977	0,967	0,972	8:02
2	8	0,972	0,974	0,969	0,971	9:10
3	12	0,973	0,980	0,963	0,974	13:37
4	15	0,974	0,980	0,964	0,974	16:58
5	15	0,976	0,978	0,972	0,975	17:49

Do autor (2025).

boa sensibilidade ao reconhecer verdadeiros casos positivos. Embora ligeiramente inferior à precisão, esse resultado está de acordo com a literatura, que aponta que modelos leves, como o MobileNetV3, tendem a apresentar pequenas variações no equilíbrio entre precisão e sensibilidade devido à sua arquitetura compacta (HOWARD *et al.*, 2019c). Ainda assim, os valores obtidos permanecem elevados e adequados ao contexto clínico.

O *F1-score* manteve-se entre 0,972 e 0,975, reforçando o equilíbrio do modelo entre detectar corretamente instâncias positivas e evitar classificações equivocadas. A estabilidade do *F1-score* ao longo dos *folds* evidencia que o MobileNetV3 não apenas apresenta bom desempenho, mas também o mantém de modo robusto em diferentes particionamentos dos dados.

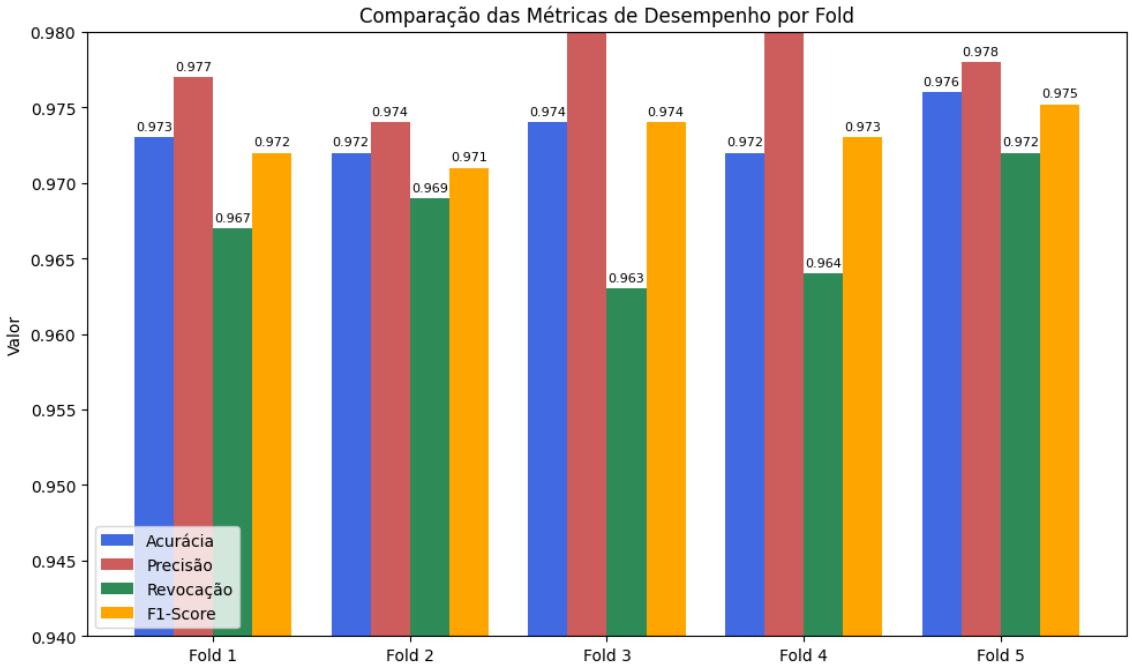
A performance observada está alinhada com a proposta da arquitetura MobileNetV3, que combina eficiência computacional com capacidade de extração de características, utilizando blocos otimizados e mecanismos como *squeeze-and-excitation* para aprimorar a qualidade das representações (HOWARD *et al.*, 2019c). Assim, os resultados demonstram que, apesar de seu baixo custo computacional, o MobileNetV3 é capaz de alcançar desempenho competitivo em tarefas complexas de visão computacional, incluindo ambientes biomédicos onde precisão e confiabilidade são fundamentais.

Portanto, as evidências apresentadas na Tabela 10 confirmam que o MobileNetV3 é uma alternativa eficiente e consistente para a detecção de células parasitadas, oferecendo excelente compromisso entre alto desempenho e eficiência computacional, características desejáveis em soluções destinadas a uso real em ambientes clínicos com recursos limitados.

A imagem apresentada na Figura 22 sintetiza a comparação das métricas de desempenho: Acurácia, Precisão, Revocação e *F1-Score*, obtidas pelo modelo em cada uma das cinco divisões (*folds*) da validação cruzada. De maneira geral, os resultados evidenciam consistência e robustez no desempenho preditivo, com variações mínimas entre os *folds*, o que reforça a capacidade de generalização do modelo.

Observa-se que a acurácia permaneceu alta em todos os *folds*, variando entre 0,972 e 0,976, o que indica que a maioria das amostras foi corretamente classificada. A precisão — métrica crítica em aplicações clínicas por indicar a proporção de verdadeiros positivos

Figura 22 – Comparativo - métricas - MobileNetV3



Fonte: Do Autor(2025)

entre todos os positivos preditos — foi a mais elevada entre todas as métricas, alcançando 0,980 em dois *folds* (*fold*3 e *fold*4) e mantendo-se acima de 0,974 nos demais. Isso sugere que o modelo apresenta baixa taxa de falsos positivos, fator essencial para evitar diagnósticos indevidos de malária.

Por outro lado, a revocação apresentou ligeira oscilação entre os *folds*, com valores entre 0,963 e 0,972. Essa métrica mede a capacidade do modelo de identificar corretamente todos os casos positivos (células parasitadas). Embora tenha sido a métrica com maior variação relativa, ainda se manteve em um patamar elevado, o que é positivo do ponto de vista da sensibilidade do modelo. A *F1-score*, que harmoniza precisão e revocação, demonstra também um padrão sólido, variando entre 0,971 e 0,975. O equilíbrio dessa métrica em todos os *folds* reforça a ideia de que o modelo não apenas identifica corretamente a maioria dos casos, mas também o faz com baixa taxa de erros de classificação. Dessa forma, os resultados apresentados no gráfico sustentam a efetividade e estabilidade do modelo, sendo especialmente relevantes quando comparados à literatura. Como exemplificado por (LU; OUTROS, 2022), modelos treinados em grandes bases de dados apresentaram *F1-scores* em torno de 0,974, ao passo que, neste estudo, os valores se aproximam de 0,975. Esse desempenho superior reflete tanto a escolha adequada da arquitetura e dos hiperparâmetros quanto a eficácia das estratégias de validação utilizadas. Assim, o modelo proposto se mostra promissor como ferramenta de apoio diagnóstico automatizado da malária.

5.3.8 Análise Comparativa entre Validação e Teste do MobileNetV3

A Tabela 11 apresenta a comparação entre os resultados obtidos na validação e no conjunto de teste para a arquitetura MobileNetV3. Observa-se diferença moderada entre as métricas médias de validação e teste, especialmente na acurácia e na precisão.

A acurácia média na validação foi de 0,967, enquanto no conjunto de teste atingiu 0,974, representando incremento aproximado de 0,007. Esse comportamento sugere que o conjunto de teste pode apresentar distribuição ligeiramente mais favorável ao modelo, não caracterizando sobreajuste, mas indicando possível variação amostral entre os subconjuntos.

A precisão apresentou diferença mais acentuada, com média de 0,967 na validação e 0,978 no teste. Esse aumento indica melhora na proporção de classificações positivas corretas quando o modelo foi avaliado no conjunto independente, sugerindo redução de falsos positivos na fase final de avaliação.

A revocação manteve-se praticamente estável entre validação e teste (0,967 em ambos os casos), evidenciando que a capacidade do modelo em identificar corretamente as instâncias positivas permaneceu consistente.

Tabela 11 – Comparação das métricas do MobileNetV3 entre validação e teste

Fold	**Val. Acc**	**Teste Acc**	**Val. Prec.**	**Teste Prec.**	**Val. Rev.**	**Teste Rev.**	**Val. F1**	**Teste F1**
1	0,964	0,973	0,964	0,977	0,964	0,967	0,964	0,972
2	0,953	0,972	0,954	0,974	0,953	0,969	0,953	0,971
3	0,972	0,973	0,972	0,980	0,972	0,963	0,972	0,974
4	0,971	0,974	0,971	0,980	0,971	0,964	0,971	0,974
5	0,975	0,976	0,975	0,978	0,975	0,972	0,975	0,975
Média	**0,967**	**0,974**	**0,967**	**0,978**	**0,967**	**0,967**	**0,967**	**0,973**

Fonte: Do autor (2025).

O F1-score apresentou média de 0,967 na validação e 0,973 no teste, reforçando o equilíbrio entre precisão e revocação. A diferença observada é estatisticamente pequena e não compromete a estabilidade do modelo.

De maneira geral, os resultados indicam que o MobileNetV3 apresenta boa capacidade de generalização, com desempenho ligeiramente superior no conjunto de teste. A estabilidade das métricas, aliada ao baixo tempo de treinamento quando comparado a arquiteturas mais profundas, demonstra que o modelo oferece relação eficiente entre custo computacional e desempenho preditivo.

5.4 Maior acurácia de validação entre os Modelos

A Tabela 12 apresenta os valores mais altos de acurácia de validação alcançados por três diferentes arquiteturas de redes neurais convolucionais: ResNet-50, EfficientNetB7 e MobileNetV3, ao longo dos cinco *folds* de validação cruzada. Esta métrica, conhecida como *Best Validation Accuracy*(maior acurácia de validação), representa o melhor desempenho que o modelo obteve no conjunto de validação durante o treinamento, sendo um importante indicativo da sua capacidade de generalização.

Tabela 12 – Comparativo da maior acurácia de validação por *fold*

Fold	**ResNet50**	**EfficientNet-B7**	**MobileNetV3**
1	0,965	0,965	0,973
2	0,972	0,967	0,972
3	0,973	0,969	0,974
4	0,970	0,964	0,974
5	0,972	0,968	0,976

Do autor (2025).

Conforme apresentado na Tabela 12, observa-se que o desempenho dos modelos avaliados varia de acordo com o *fold* da validação cruzada, evidenciando diferenças na capacidade de generalização entre as arquiteturas ResNet50, EfficientNet-B7 e MobileNetV3. De modo geral, a MobileNetV3 apresentou os maiores valores de acurácia na maioria dos *folds*, enquanto a ResNet50 demonstrou desempenho competitivo e consistente, e a EfficientNet-B7 apresentou resultados ligeiramente inferiores nos diferentes particionamentos.

No *fold* 1, a ResNet50 e a EfficientNet-B7 obtiveram acurácia idêntica de 0,965, enquanto a MobileNetV3 apresentou desempenho superior, atingindo 0,973. Esse resultado indica melhor adaptação da MobileNetV3 a esse subconjunto específico de dados. No *fold* 2, a ResNet50 e a MobileNetV3 alcançaram o mesmo valor de acurácia (0,972), superando a EfficientNet-B7, que obteve 0,967, o que evidencia maior estabilidade dessas duas arquiteturas nesse particionamento.

No *fold* 3, a MobileNetV3 voltou a apresentar o melhor desempenho, com acurácia de 0,974, seguida pela ResNet50 com 0,973 e pela EfficientNet-B7 com 0,969. Já no *fold* 4, a MobileNetV3 novamente se destacou, alcançando 0,974, enquanto a ResNet50 obteve 0,970 e a EfficientNet-B7 apresentou o menor valor entre os modelos, com 0,964.

Por fim, no *fold* 5, a MobileNetV3 atingiu a maior acurácia observada em toda a validação cruzada, com valor de 0,976, seguida pela ResNet50 (0,972) e pela EfficientNet-B7 (0,968). Esse resultado reforça a superioridade da MobileNetV3 em termos de acurácia máxima de validação ao longo dos diferentes *folds*.

De forma geral, os resultados indicam que, embora a ResNet50 apresente desempenho robusto e consistente, a MobileNetV3 demonstra maior capacidade de generalização, alcançando as maiores acurácias na maioria dos *folds*. A EfficientNet-B7, por sua vez, apresentou desempenho competitivo, porém inferior às demais arquiteturas na maior parte dos cenários avaliados. Esses achados sugerem que arquiteturas mais recentes e otimizadas, como a MobileNetV3, podem oferecer vantagens relevantes em aplicações práticas que demandam elevado desempenho preditivo.

5.4.1 Arquitetura CNN Simples

A preparação do conjunto de dados foi realizada por meio de um processo de divisão estratificada e aleatória, com o objetivo de garantir que os subconjuntos de treino, validação e teste representassem adequadamente a distribuição original das classes. Inicialmente, todos os índices das amostras foram embaralhados de forma estocástica, assegurando ausência de viés na seleção das imagens. Em seguida, as proporções de 70%, 10% e 20% foram destinadas, respectivamente, aos conjuntos de treino, validação e teste. Essa estratégia possibilita não apenas avaliar o desempenho final do modelo em dados não vistos, mas também ajustar seus hiperparâmetros de forma controlada, evitando sobreajuste durante o processo de aprendizagem.

O parâmetro *batch size* (definido previamente no código) controla a quantidade de amostras processadas simultaneamente em cada iteração, influenciando diretamente a estabilidade do gradiente e o uso de memória. Já o processo de otimização foi conduzido pelo algoritmo Adam, escolhido por sua capacidade de ajustar dinamicamente a taxa de aprendizado de cada parâmetro, proporcionando rápida convergência e bom desempenho em redes convolucionais. A função de perda adotada foi a *CrossEntropyLoss*, indicada para tarefas de classificação multiclasse, sendo aplicada de forma adequada ao problema de diferenciação entre duas categorias de células.

Tabela 13 – Hiperparâmetros e parâmetros estruturais utilizados no modelo CNN.

Parâmetro	**Valor**	**Descrição**
Divisão do Dataset		
Proporção de treino	70%	Amostras utilizadas para ajuste dos pesos do modelo.
Proporção de validação	10%	Conjunto usado para ajuste de hiperparâmetros e detecção de overfitting.
Proporção de teste	20%	Amostras jamais vistas pelo modelo, utilizadas para avaliação final.
Hiperparâmetros de Treinamento		
Batch size	`batch_size`	Quantidade de imagens processadas simultaneamente em cada iteração.
Taxa de aprendizado	`learning_rate`	Controla o tamanho das atualizações dos pesos durante a otimização.
Otimizador	Adam	Otimizador adaptativo que ajusta dinamicamente a taxa de aprendizado de cada parâmetro.
Função de perda	CrossEntropyLoss	Função utilizada para problemas de classificação multiclasse.
Arquitetura da CNN		
Conv2D (1ª camada)	3 → 32, kernel 3×3, padding 1	Extrai características iniciais como bordas e texturas simples.
MaxPool2D	2×2	Reduz a dimensão espacial pela metade.
Conv2D (2ª camada)	32 → 64, kernel 3×3, padding 1	Detecta padrões intermediários na imagem.
MaxPool2D	2×2	Redução espacial adicional.
Conv2D (3ª camada)	64 → 128, kernel 3×3, padding 1	Identifica características de alto nível.
MaxPool2D	2×2	Redução final da resolução.
Flatten	128×16×16	Reestrutura o tensor para entrada na rede densa.
Linear 1	32768 → 256	Primeira camada totalmente conectada.
Dropout	0,5	Reduz coadaptação entre neurônios e previne overfitting.
Linear 2	256 → 2	Camada final responsável pela classificação em duas classes.

Fonte: Do autor (2025).

A arquitetura desenvolvida consiste em uma rede neural convolucional (CNN) composta por três blocos de convolução seguidos de operações de *max pooling*, responsáveis pela extração hierárquica de atributos visuais. As primeiras camadas detectam padrões mais simples — como bordas e texturas — enquanto as camadas subsequentes capturam estruturas de maior complexidade. Após a etapa convolucional, o tensor resultante é

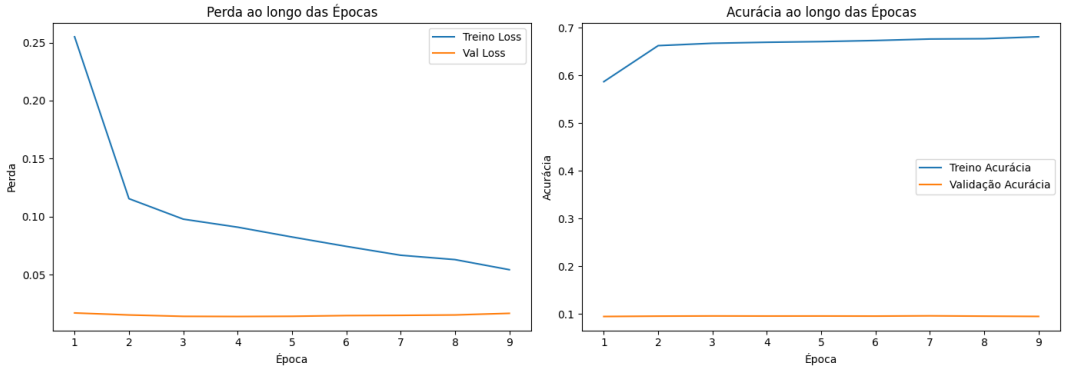
achatado e encaminhado para o módulo totalmente conectado, que contém uma camada intermediária com 256 unidades e uma camada final com duas saídas, correspondente às classes analisadas. Um mecanismo de regularização baseado em *dropout* com taxa de 0,5 foi inserido com o intuito de reduzir a coadaptação entre neurônios, mitigando o risco de sobreajuste. Essa composição arquitetural proporciona um equilíbrio entre simplicidade computacional e capacidade representativa, adequada ao problema de classificação de imagens microscópicas.

5.4.1.1 Desempenho da CNN Simples

Esta subseção apresenta os resultados experimentais obtidos pela CNN Simples aplicada ao problema de detecção de células parasitadas por *Plasmodium* em imagens microscópicas. O modelo *CNN Simples* foi implementado como *baseline* para avaliar o potencial do aprendizado profundo na detecção de células infectadas por *Plasmodium*. O treinamento foi conduzido em uma GPU Tesla T4, com 14.74 GB de memória total, durante aproximadamente 528 segundos. Foram utilizadas oito épocas, com *early stopping* ativado para evitar sobreajuste.

As curvas de perda e acurácia estão apresentadas na Figura 23, evidenciando o comportamento do modelo ao longo do treinamento.

Figura 23 – Evolução da perda e da acurácia da CNN Simples ao longo das épocas.



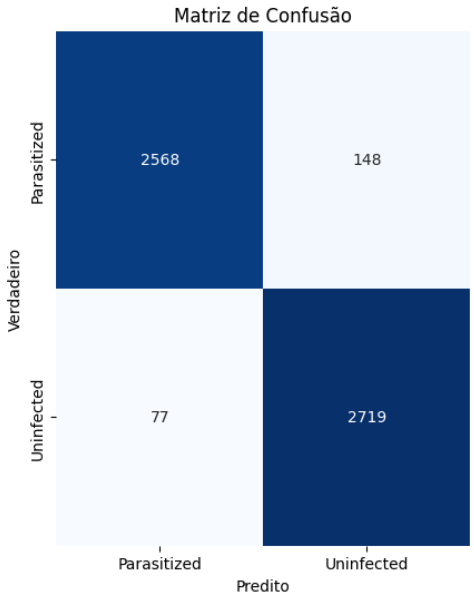
Fonte: Do autor (2025).

Observa-se uma redução expressiva da perda de treinamento nas primeiras épocas, atingindo estabilidade a partir da quinta época. No entanto, a perda de validação manteve-se quase constante, indicando possível sobreajuste (*overfitting*). A acurácia de validação manteve-se próxima de 0.095, contrastando com uma acurácia de treinamento superior a 0.67.

5.4.2 Matriz de Confusão

A matriz de confusão ilustrada na Figura 24 mostra o desempenho da CNN Simples ao classificar células parasitadas e não parasitadas no conjunto de teste. Visualmente, observa-se uma predominância de tons escuros na diagonal principal, indicando uma elevada taxa de acertos em ambas as classes. O quadrante superior esquerdo apresenta 2.568 amostras corretamente identificadas como Infectada(Parasitized), enquanto o quadrante inferior direito registra 2.719 acertos para a classe saudável(Uninfected). Esses valores evidenciam que o modelo conseguiu aprender representações discriminativas importantes para diferenciar células infectadas daquelas saudáveis.

Figura 24 – Matriz de confusão da CNN Simples no conjunto de teste.



Fonte: Do autor (2025).

Assim, a matriz de confusão evidencia que a CNN Simples apresenta desempenho consistente e robusto na tarefa de classificação binária, com taxas elevadas de acerto em ambas as classes. Esses resultados reforçam a viabilidade do modelo como ferramenta de apoio ao diagnóstico, sobretudo em cenários onde ferramentas automatizadas podem reduzir carga de trabalho e acelerar o processo de triagem. Contudo, ainda há margem para aprimoramentos visando reduzir erros residuais e potencializar a confiabilidade do sistema em aplicações reais.

5.4.3 Métricas de Desempenho

A Tabela 14 apresenta as métricas calculadas com base na matriz de confusão. Todas as métricas atingiram valores elevados, demonstrando robustez do modelo.

Tabela 14 – Métricas de desempenho da CNN Simples calculadas a partir da matriz de confusão.

Métrica	**Valor**
Acurácia	0.959
Precisão	0.971
Revocação	0.946
F1-score	0.958

Fonte: Do autor (2025).

5.4.4 Análise dos Resultados

Os resultados demonstram que a CNN Simples apresenta um desempenho sólido na tarefa de distinção entre células parasitadas e não parasitadas. A acurácia global de 95,9% indica que o modelo é capaz de classificar corretamente a maior parte das amostras analisadas. Esse valor está em linha com resultados reportados na literatura para modelos convolucionais aplicados ao diagnóstico de malária, que geralmente variam entre 93% e 98% dependendo da arquitetura adotada.

A precisão de 97,1% revela que a proporção de falsos positivos é baixa, o que é desejável em cenários clínicos, pois reduz o risco de diagnósticos incorretos de indivíduos sadios. Da mesma forma, o valor de *recall* (94,6%) demonstra que a maioria das amostras infectadas foi corretamente identificada. Embora esse valor seja ligeiramente inferior ao da precisão, ele permanece elevado o suficiente para sugerir que a CNN apresenta boa sensibilidade mesmo sem aprofundamentos arquiteturais mais complexos.

O *F1-score* de 95,8% confirma o equilíbrio entre precisão e *recall*, evidenciando que a rede realiza classificações robustas sem favorecer excessivamente uma classe em detrimento da outra.

5.4.5 Discussão dos Resultados

Comparando os resultados obtidos com estudos relacionados, observa-se que arquiteturas profundas mais sofisticadas, como EfficientNet, MobileNetV3 ou ResNet50, frequentemente apresentam desempenho marginalmente superior, especialmente no *recall*, devido à sua capacidade ampliada de extração hierárquica de características. No entanto, a CNN Simples utilizada neste estudo apresentou resultados competitivos, destacando-se pela leveza computacional e menor custo de treinamento.

A análise dos erros mostra que a maioria das falhas ocorre em amostras que apresentam características visuais ambíguas, seja por ruído do microscópio, má iluminação ou presença de artefatos celulares. Trabalhos anteriores reportam dificuldades semelhantes,

reforçando que a qualidade do *dataset* exerce papel fundamental no desempenho final dos modelos de visão computacional.

Os resultados obtidos sugerem que, embora o modelo apresente desempenho robusto, há oportunidades de aprimoramento, especialmente por meio da adoção de arquiteturas mais profundas, técnicas avançadas de aumento de dados, regularização ou ajuste fino de hiperparâmetros. Tais melhorias foram apresentadas no trabalho em capítulos anteriores, podendo observar elevada sensibilidade do modelo, reduzindo a ocorrência de falsos negativos, o que é particularmente crítico no diagnóstico de malária.

Apesar da discrepância observada entre treino e validação, a CNN Simples atingiu bom desempenho no conjunto de teste, com acurácia global de 95.83%. Esse resultado evidencia que, embora a arquitetura seja mais rasa, ela ainda é capaz de capturar características discriminantes relevantes nas imagens de esfregaços sanguíneos, alinhando-se a estudos prévios que apontam o potencial das CNNs em tarefas biomédicas (**??**RAJ *et al.*, 2023).

5.4.6 Comparação com Arquiteturas

Para efeito comparativo, as arquiteturas ResNet50 (HE, 2016), EfficientNetB7 (TAN; LE, 2019b) e MobileNetV3 (HOWARD *et al.*, 2019b) foram aplicadas sobre o mesmo conjunto de dados, empregando transferência de aprendizado (*Transfer Learning*) a partir de pesos pré-treinados no ImageNet.

Tabela 15 – Comparação do melhor desempenho de validação entre os modelos avaliados

Modelo	**Acurácia**	**Precisão**	**Revocação**	**F1-score**
ResNet50	0,973	0,974	0,973	0,973
EfficientNet-B7	0,976	0,976	0,976	0,976
MobileNetV3	0,976	0,976	0,976	0,976
CNN Simples	0,959	0,971	0,946	0,958

Fonte: Do autor (2025).

Conforme apresentado na Tabela 15, observa-se que os modelos baseados em redes neurais convolucionais profundas com uso de transferência de aprendizado apresentaram desempenho superior quando comparados à CNN Simples desenvolvida neste estudo. Em especial, os modelos EfficientNet-B7 e MobileNetV3 alcançaram os melhores resultados globais, ambos com acurácia de validação igual a 0,976, além de valores idênticos de precisão, revocação e F1-score (0,976), indicando um desempenho equilibrado e consistente na tarefa de classificação de células infectadas por parasitas da malária.

A ResNet50 também apresentou desempenho elevado, com acurácia de 0,973 e métricas de precisão, revocação e F1-score igualmente próximas (0,974, 0,973 e 0,973, respectivamente). Embora ligeiramente inferior aos modelos EfficientNet-B7 e MobileNetV3, esse resultado evidencia a robustez da arquitetura e sua capacidade de generalização, reforçando a efetividade do uso de pesos pré-treinados no ImageNet para aplicações em imagens biomédicas.

Por outro lado, a CNN Simples obteve desempenho inferior em relação aos demais modelos avaliados, apresentando acurácia de 0,959 e F1-score de 0,958. Apesar de ter alcançado uma precisão relativamente alta (0,971), o modelo apresentou menor revocação (0,946), o que indica maior dificuldade em identificar corretamente todas as amostras positivas. Esse desequilíbrio entre precisão e revocação impacta diretamente o F1-score e pode ser atribuído à menor profundidade da arquitetura e à ausência de pré-treinamento em grandes bases de dados.

Dessa forma, os resultados obtidos confirmam que arquiteturas profundas aliadas ao uso de *Transfer Learning* proporcionam ganhos significativos de desempenho na classificação de imagens biomédicas. Em particular, os modelos EfficientNet-B7 e MobileNetV3 destacam-se como as abordagens mais eficazes neste estudo, validando a metodologia proposta e evidenciando seu potencial para aplicação em sistemas de apoio ao diagnóstico automatizado da malária.

No Capítulo 6 são apresentadas as conclusões finais do estudo, retomando os objetivos propostos na Introdução, bem como as principais contribuições científicas desta dissertação. Ademais, são discutidas as limitações do trabalho e apresentadas perspectivas para pesquisas futuras, com vistas ao aprimoramento de sistemas inteligentes de apoio ao diagnóstico da malária, contribuindo para a detecção precoce e o tratamento eficaz da doença em contextos com recursos limitados.

6 Conclusão

Esta dissertação teve como objetivo principal investigar a aplicação de técnicas avançadas de Deep Learning na classificação automática de imagens microscópicas de células sanguíneas, visando à detecção de parasitas da malária sob a perspectiva da computação aplicada. Para tal, foram avaliadas diferentes arquiteturas de Redes Neurais Convolucionais (CNNs), incluindo uma CNN Simples desenvolvida como modelo base e arquiteturas profundas amplamente consolidadas na literatura — ResNet50, EfficientNet-B7 e MobileNetV3 — todas empregando a estratégia de Transfer Learning a partir de pesos pré-treinados no ImageNet.

Do ponto de vista computacional, os resultados evidenciaram que a utilização de modelos pré-treinados representa uma abordagem eficiente para acelerar o processo de treinamento e melhorar a capacidade de generalização, especialmente em cenários nos quais o volume de dados rotulados é limitado. As arquiteturas avaliadas apresentaram elevados valores de acurácia, precisão, revocação e F1-score, confirmando que técnicas modernas de aprendizado profundo são capazes de extrair representações discriminativas robustas mesmo em bases de dados complexas e sujeitas a variações intrínsecas, como imagens biomédicas.

A análise comparativa por fold, obtida por meio da validação cruzada K-Fold, demonstrou estabilidade estatística dos modelos, com variações pouco significativas entre as execuções. Esse comportamento indica que as arquiteturas avaliadas são consistentes e menos suscetíveis a sobreajuste (overfitting), o que reforça a confiabilidade do pipeline computacional proposto. Em especial, os modelos EfficientNet-B7 e MobileNetV3 destacaram-se por apresentarem as maiores acurácias médias de validação, corroborando estudos recentes que apontam essas arquiteturas como eficientes no equilíbrio entre profundidade, largura e resolução das redes.

Sob a ótica da eficiência computacional, observou-se que o desempenho preditivo não está necessariamente associado a arquiteturas mais complexas ou computacionalmente custosas. Embora a EfficientNet-B7 tenha alcançado resultados elevados, seu tempo de treinamento mostrou-se significativamente superior em comparação às demais arquiteturas. Em contrapartida, a MobileNetV3 apresentou desempenho comparável, com menor tempo de treinamento e menor demanda computacional, evidenciando-se como uma solução mais adequada para aplicações práticas, especialmente em sistemas embarcados, dispositivos móveis ou ambientes com infraestrutura computacional limitada.

A CNN Simples, apesar de apresentar desempenho inferior em relação aos modelos pré-treinados, desempenhou papel fundamental como linha de base (baseline), permitindo

quantificar os ganhos proporcionados pelo uso de arquiteturas profundas e Transfer Learning. Além disso, sua simplicidade estrutural reforça seu valor didático e sua aplicabilidade em cenários onde a interpretabilidade do modelo e a simplicidade computacional são requisitos prioritários.

Dessa forma, os resultados obtidos permitem confirmar a hipótese de pesquisa de que arquiteturas de Deep Learning pré-treinadas são mais eficazes e robustas para a tarefa de classificação automática de imagens de malária, quando comparadas a modelos convolucionais desenvolvidos do zero. O estudo evidencia que a escolha do modelo deve considerar não apenas métricas de desempenho, mas também aspectos relacionados à eficiência computacional, escalabilidade e viabilidade de implantação em ambientes reais.

Como contribuição para a área de computação aplicada, esta dissertação apresenta um pipeline experimental completo e reproduzível, abrangendo pré-processamento de dados, treinamento, validação cruzada, análise de métricas e comparação sistemática de arquiteturas. Tais contribuições podem servir de base para o desenvolvimento de sistemas inteligentes de apoio ao diagnóstico, bem como para pesquisas futuras que explorem otimizações arquiteturais, técnicas de compressão de modelos e estratégias de inferência em tempo real.

6.1 Pesquisas Futuras

Como trabalhos futuros, propõe-se a ampliação do presente estudo por meio do desenvolvimento e da implantação de sistemas inteligentes para apoio ao diagnóstico da malária em diferentes contextos de infraestrutura computacional. Inicialmente, prevê-se a implementação de um sistema *on-line* com *deploy* em servidores de alto desempenho, utilizando *frameworks* modernos como o FastAPI no *backend* e interfaces responsivas acessíveis tanto via navegador quanto por meio de aplicativos móveis. Esse sistema teria como base o modelo MobileNetV3, cuja escolha se justifica pelo equilíbrio entre elevado desempenho preditivo e alta eficiência computacional, permitindo a realização de inferências rápidas mesmo em ambientes com recursos computacionais limitados.

O sistema proposto teria como finalidade receber imagens de lâminas microscópicas enviadas por profissionais de saúde e processá-las em tempo real, retornando a classificação automática das células analisadas. A plataforma poderia ser integrada a um banco de dados centralizado, possibilitando o armazenamento dos resultados das análises para fins de monitoramento epidemiológico, acompanhamento longitudinal de casos e apoio à tomada de decisão em políticas públicas de saúde. Além disso, o acesso via navegadores convencionais eliminaria a necessidade de instalações locais, favorecendo a escalabilidade do sistema e a atualização contínua dos modelos de predição.

Em paralelo, sugere-se o desenvolvimento de uma versão embarcada do sistema, baseada em versões otimizadas dos modelos utilizando o PyTorch Mobile, integrada a microscópios digitais de baixo custo. Essa abordagem permitiria a realização de diagnósticos rápidos e automatizados diretamente no ponto de coleta, mesmo em locais sem acesso à internet, como comunidades rurais e regiões remotas. A hipótese central dessa proposta é que a integração de técnicas de inteligência artificial a múltiplos contextos de infraestrutura — desde ambientes web até sistemas embarcados — pode viabilizar diagnósticos mais precisos, ágeis e acessíveis, contribuindo para a redução de erros humanos, a ampliação do acesso a exames confiáveis e o fortalecimento das estratégias de combate à malária.

Adicionalmente, recomenda-se a investigação do uso de redes neurais adversariais generativas (GANs) para a geração de imagens sintéticas de células infectadas por malária, com o objetivo de ampliar o conjunto de dados de treinamento e melhorar a capacidade de generalização dos modelos. As GANs também podem ser exploradas para o aprimoramento de imagens microscópicas de baixa qualidade, tornando a análise mais robusta e precisa, especialmente em cenários com limitações de equipamentos e infraestrutura. Essas abordagens, quando integradas ao sistema proposto, podem contribuir significativamente para o avanço de soluções computacionais aplicadas à saúde, fortalecendo o papel da inteligência artificial no apoio ao diagnóstico e no controle de doenças endêmicas.

Referências

ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection. *Statistics Surveys*, v. 4, p. 40–79, 2010. Disponível em: https://doi.org/10.1214/09-SS054. Acesso em: 06 ago. 2025.

AUTORES. A review of medical image data augmentation techniques for deep learning applications. *J Med Imaging Radiat Oncol.*, 2021.

AWS. *O que é aprendizado por transferência?* 2023. Acesso em: 29 mar. 2025. Disponível em: <https://aws.amazon.com/pt/what-is/transfer-learning/>.

BAHETI, B.; INNANI, S.; GAJRE, S.; TALBAR, S. Eff-unet: A novel architecture for semantic segmentation in unstructured environment. In: *Proc. CVPR*. Seattle, WA, USA: [s.n.], 2020. p. 358–359.

BIBIN, D. e. a. Malaria detection using deep convolutional neural network. In: *2017 IEEE International Conference on Control, Instrumentation, Communication and Computational Technologies (ICCICCT)*. [S.l.: s.n.], 2017. p. 1–6.

CALDERARO, A.; PICCOLO, G.; PERANDI, P.; MONTAGNER, F.; MONTECCHIO, L.; GRAZIANI, A. *et al.* Automated microscopy for malaria diagnosis in elimination settings: Prospects and challenges. *Malaria Journal*, v. 20, n. 1, p. 1–9, 2021.

CHAKRABARTY, P. *et al.* Efficientnet for malaria diagnosis: Achieving high precision. *AI in Healthcare Research*, X, n. X, p. XX–XX, 2024. DOI or URL if available.

CHEN, L.; ZHOU, M.; ZHANG, Y. Validation metrics and overfitting prevention in deep medical image classification. *Computers in Biology and Medicine*, v. 158, p. 106812, 2023.

COSTA, M. C. S. F.; WALTER, M. E. M. T.; STADLER, P. F. *Aprendizado Por Transferência Para Predição de RNAs Não-Codificadores*. [S.l.], 2022. Acessado em: 07/12/2024.

CRUZ, F. O. *Glossário de doenças*. 2019. Biblioteca Virtual em Saúde do Ministério da Saúde. Dica elaborada em novembro de 2007 e revisada em abril de 2019. Disponível em: <https://bvsms.saude.gov.br/>.

DAS, D.; VONGPROMEK, R.; ASSAWARIYATHIPAT, T.; SRINAMON, K.; KENNON, K.; STEPNIEWSKA, K.; GHOSE, A.; SAYEED, A. A.; FAIZ, M. A.; NETTO, R. L. A.; SIQUEIRA, A.; YERBANGA, S. R.; OUéDRAOGO, J. B.; CALLERY, J. J.; PETO, T. J.; TRIPURA, R.; KOUKOUIKILA-KOUSSOUNDA, F.; NTOUMI, F.; ONG'ECHA, J. M.; OGUTU, B.; GHIMIRE, P.; MARFURT, J.; LEY, B.; SECK, A.; NDIAYE, M.; MOODLEY, B.; SUN, L. M.; ARCHASUKSAN, L.; PROUX, S.; NSOBYA, S. L.; ROSENTHAL, P. J.; HORNING, M. P.; MCGUIRE, S. K.; MEHANIAN, C.; BURKOT, S.; DELAHUNT, C. B.; BACHMAN, C.; PRICE, R. N.; DONDORP, A. M.; CHAPPUIS, F.; GUéRIN, P. J.; DHORDA, M. Field evaluation of the diagnostic performance of easyscan go: a digital malaria microscopy device based on machine-learning. *Malaria Journal*, v. 21, n. 1, p. 122, 2022. ISSN 1475-2875. Disponível em: <https://doi.org/10.1186/s12936-022-04146-1>.

DataCamp. *K-Fold Cross-Validation: A Robust Model Evaluation Method*. 2023. Acesso em: 01 abr. 2025. Disponível em: <https://www.datacamp.com/pt/tutorial/k-fold-cross-validation>.

DEVELOPERS, S. learn. *Cross-validation: evaluating estimator performance*. 2024. Acesso em: 27 mar. 2025. Disponível em: <https://scikit-learn.org/stable/modules/cross_validation.html>.

ELAZIZ, M. E. A.; AL-QANESS, M.; DAHOU, A.; ALSAMHI, S.; ABUALIGAH, L.; IBRAHIM, R.; EWEES, A. Evolution toward intelligent communications: Impact of deep learning applications on the future of 6g technology. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, v. 14, 11 2023.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016.

_____. *Deep learning*. [S.l.]: MIT press, 2016.

GREENSPAN, H.; GINNEKEN, B. van; SUMMERS, R. M. Deep learning in medical imaging: Overview and future promise. *IEEE Transactions on Medical Imaging*, IEEE, v. 35, n. 5, p. 1153–1159, 2016.

HE, K. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Las Vegas, NV: IEEE, 2016. p. 770–778. Disponível em: <https://doi.org/10.1109/CVPR.2016.90>. Acesso em: 30 jun. 2025.

HE, K.; ZHANG, X.; REN, S.; SUN, J. *Deep Residual Learning for Image Recognition*. 2015. <https://arxiv.org/abs/1512.03385>. Acesso em: 27 mar. 2025.

_____. Deep residual learning for image recognition. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2016. p. 770–778.

HOWARD, A.; SANDLER, M.; CHU, G.; CHEN, L.-C.; CHEN, B.; TAN, M.; WANG, W.; ZHU, Y.; PANG, R.; VASUDEVAN, V.; LE, Q. V.; ADAM, H. *Searching for MobileNetV3*. 2019. Disponível em: <https://arxiv.org/abs/1905.02244>.

HOWARD, A.; SANDLER, M.; CHU, G.; CHEN, L.-C.; CHEN, B.; TAN, M.; WANG, R.; ZHU, Y.; PANG, R.; VASUDEVAN, V. *et al.* Searching for mobilenetv3. In: *Proceedings of the IEEE International Conference on Computer Vision*. [S.l.: s.n.], 2019. p. 1314–1324.

HOWARD, A.; SANDLER, M.; CHU, G.; CHEN, L.-C.; CHEN, B.; TAN, M.; WANG, W.; ZHU, Y.; PANG, R.; VASUDEVAN, V.; LE, Q. V.; ADAM, H. Searching for mobilenetv3. *arXiv preprint arXiv:1905.02244*, 2019.

IMAN, M.; ARABNIA, H. R.; RASHEED, K. A review of deep transfer learning and recent advancements. *Technologies*, v. 11, n. 2, 2023. ISSN 2227-7080. Disponível em: <https://www.mdpi.com/2227-7080/11/2/40>.

IOFFE, S.; SZEGEDY, C. *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. 2015. <https://arxiv.org/abs/1502.03167>. Acesso em: 27 mar. 2023.

JIANG, F. e. a. Artificial intelligence in healthcare: past, present and future. *Computers in Biology and Medicine*, Elsevier, 2021.

KALKAN, S. C.; SAHINGOZ, O. K. Deep learning based classification of malaria from slide images. In: *2019 Scientific Meeting on Electrical-electronics & Biomedical Engineering and Computer Science (EBBT)*. [S.l.]: IEEE, 2019. p. 1–4.

KIM, D.; PARK, J.; LEE, H. Robustness evaluation of deep learning models for healthcare applications. *Sensors*, v. 23, n. 7, p. 3521, 2023.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2015.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, v. 60, n. 6, p. 84–90, 2017.

KUHN, M.; JOHNSON, K. *Applied Predictive Modeling*. 2. ed. Cham: Springer, 2023. Disponível em: https://doi.org/10.1007/978-3-031-28219-6. Acesso em: 06 ago. 2025.

KUMAR, Y. *et al.* Enhancing parasitic organism detection in microscopy images through deep learning and fine-tuned optimizer. *Scientific Reports*, v. 14, n. 1, p. 5753, 2024.

KUNDU, N. *Explorando o ResNet50: Uma análise aprofundada da arquitetura do modelo e da implementação do código*. 2023. <https://medium.com/@nitishkundu1993/exploring-resnet50-an-in-depth-look-at-the-model-architecture-and-code-implementation-d8d8fa67e46f>. Acessado em: 20/02/2025.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015.

LI, J.; SUN, Q.; HE, Z. Training stability analysis of deep neural networks for medical diagnosis. *Artificial Intelligence in Medicine*, v. 139, p. 102514, 2023.

LIANG, Y. Malaria parasite detection using lightweight cnn models on mobile devices. *IEEE Access*, v. 10, p. 33382–33391, 2022.

LITJENS, G. e. a. A survey on deep learning in medical image analysis. *Medical Image Analysis*, Elsevier, v. 42, p. 60–88, 2017.

LIU, Y.; CHEN, X.; HUANG, G. Reliable training strategies for deep neural networks in medical imaging. *Pattern Recognition*, v. 145, p. 109942, 2024.

LU, N.; OUTROS, C. Automated malaria diagnosis using large-scale image datasets: performance and limitations. *Journal of Medical Imaging Research*, v. 15, n. 4, p. 123–135, 2022.

MACHADO, R. G.; SILVA, E.; GOLDSCHMIDT, R. R. Adversarial machine learning in image classification: A survey towards the defender's perspective. 2020.

MENDES, C. *ASPECTOS CLÍNICOS E LABORATORIAIS NO DIAGNÓSTICO DA MALÁRIA*. [S.l.]: INSTITUTO DE PÓS - GRADUAÇÃO EM ANÁLISES CLÍNICAS E HEMATOLÓGICAS, 2022.

MUREL, P. J.; KAVLAKOGLU, E. *Data Augmentation*. 2024. Criado em: 7 maio 2024. Acesso em: 26 mar. 2025. Disponível em: <https://www.ibm.com/br-pt/think/topics/data-augmentation>.

National Library of Medicine, National Institutes of Health. *NLM - Malaria Data*. 2018. Accessed: 29 Mar. 2025. Disponível em: <https://lhncbc.nlm.nih.gov/LHC-research/LHC-projects/image-processing/malaria-datasheet.html>.

NEOWAY. *Inteligência artificial: o que é, como funciona e exemplos*. 2020. <https://blog.neoway.com.br/inteligencia-artificial/>. Acessado em: 05/09/2023.

(OPS). *Organização Pan-Americana da Saúde, Dia Mundial contra a Malária: OPAS pede aos países que aumentem acesso ao tratamento*. 2024. Acesso em: 10 set. 2024. Disponível em: <https://www.paho.org/pt/noticias/25-4-2024-dia-mundial-contra-malaria-opas-pede-aos-paises-que-aumentem-acesso-ao>.

OYEWOLA. A novel data augmentation convolutional neural network for detecting malaria parasite in blood smear images. *Applied Artificial Intelligence*, v. 36, n. 1, 2022. Disponível em: <https://doi.org/10.1080/08839514.2022.2060136>. Acesso em: 30 jun. 2025.

PAHO/OMS. *Malária*. 2025. <https://www.paho.org/pt/topicos/malaria>. Acesso em: 12 dez. 2025.

PAN, W. D.; DONG, Y.; WU, D. Classification of malaria-infected cells using deep convolutional neural networks. In: FARHADI, H. (Ed.). *Machine Learning*. Rijeka: IntechOpen, 2018. cap. 8. Disponível em: <https://doi.org/10.5772/intechopen.72426>.

PENG, L.; LIANG, H.; LUO, G.; LI, T.; SUN, J. Rethinking transfer learning for medical image classification. *arXiv preprint*, 2024. Disponível em: <https://arxiv.org/abs/2106.05152>.

PETER, N.; INTELLIGENCE, R. S. A. *A Modern Approach*. [S.l.]: Pearson Education, USA, 2021.

PRECHELT, L. Early stopping—but when? *Lecture Notes in Computer Science*, Springer, v. 1524, p. 55–69, 1998.

RAJ, A. *et al.* Using cnns to identify the presence of malaria parasites with high accuracy. *Journal of Medical Imaging and Diagnostics*, X, n. X, p. XX–XX, 2023. DOI or URL if available.

RAJARAMAN, S. Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, v. 6, p. e4568, 2018. Disponível em: <https://doi.org/10.7717/peerj.4568>.

RAJARAMAN, S.; ANTANI, S. K. Modality-specific deep learning model ensembles toward improving tb detection in chest radiographs. *IEEE Access*, IEEE, v. 8, p. 27318–27326, 2020. Epub 2020 Feb 3. PMID: 32257736. PMC7120763. Disponível em: <https://doi.org/10.1109/access.2020.2971257>.

RAJARAMAN, S.; ANTANI, S. K.; POOSTCHI, M.; SILAMUT, K.; HOSSAIN, M. A.; MAUDE, R. J.; AL. et. Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, v. 6, p. e4568, 2018.

RAJARAMAN, S. *et al.* Performance evaluation of deep neural ensembles toward malaria parasite detection in thin-blood smear images. *PeerJ Computer Science*, 2021.

RAJPURKAR, P. e. a. Ai in healthcare: The hope, the hype, the promise, the peril. *Nature Medicine*, 2022.

RAWAT, W.; WANG, Z. Deep convolutional neural networks for image classification: A comprehensive review. *Neural Computation*, v. 29, n. 9, p. 2352–2449, 2017.

REZENDE, M. T.; SILVA, R.; BERNARDO, F. d. O.; TOBIAS, A. H.; OLIVEIRA, P. H.; MACHADO, T. M.; COSTA, C. S.; MEDEIROS, F. N.; USHIZIMA, D. M.; CARNEIRO, C. M. e. a. Cric searchable image database as a public platform for conventional pap smear cytology data. *Scientific Data*, Nature Publishing Group, v. 8, n. 1, p. 1–8, 2021.

ROBOFLOW. *What is EfficientNet?* 2024. Acesso em: 27 mar. 2024. Disponível em: <https://blog.roboflow.com/what-is-efficientnet/>.

RUSSEL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. [S.l.]: Prentice Hall, 2022.

SARKAR, S.; SHARMA, R.; SHAH, K. Malaria detection from rbc images using shallow convolutional neural networks. *arXiv preprint*, 2020.

SAWANT, D.; SHARMA, H.; GUPTA, A. Deep learning-based malaria parasite detection using resnet-50 on the nih malaria dataset. *arXiv preprint arXiv:2406.20005*, 2024. Disponível em: <https://arxiv.org/abs/2406.20005>.

SEMENOGLOU, A.-A.; SPILIOTIS, E.; ASSIMAKOPOULOS, V. Data augmentation for univariate time series forecasting with neural networks. *Pattern Recognition*, v. 134, p. 109132, 2023. ISSN 0031-3203. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0031320322006124>.

SESPA, S. de Saúde Pública do P. *Boletim Epidemiológico da Malária*. Belém, 2024. Número do Protocolo: 2024/2455286, Anexo/Sequencial: 1.

SHARMA, S.; MEHRA, R. Implications of pooling strategies in convolutional neural networks: A deep insight. *Foundations of Computing and Decision Sciences*, August 2019.

SILVA, I. N. D.; SPATTI, R. F.; FLAUZINO, R. A.; ARRUDA, L. H. B. de; RIBEIRO, A. C. *Multilayer Perceptron Networks*. 1. ed. São Paulo: Springer, 2017. v. 1.

SINHA, R.; GUPTA, N. Automated detection of malaria infected cells using pre-trained resnet-50 cnn model. *International Conference on Computer Vision and Pattern Recognition (ICCV)*, 2023. Disponível em: <https://arxiv.org/abs/2304.02925>.

SINHA, S.; GUPTA, N. Computer-aided diagnosis of malaria through transfer learning using the resnet50 backbone. *arXiv preprint*, 2023. Disponível em: <https://arxiv.org/abs/2304.02925>.

SIłKA, W.; WIECZOREK, M.; SIłKA, J.; WOźNIAK, M. Malaria detection using advanced deep learning architecture. *Sensors*, v. 23, n. 3, p. 1501, 2023.

SOUZA, E. P.; GOMES, C. M.; BARROSO, D. H.; MIRANDA, V. L.; GONçALVES, R. G. Deep learning applications for disease diagnosis and identification of insect vectors. *Revista Saúde Debate*, Rio de Janeiro, v. 43, n. Especial 2, p. 147–154, novembro 2019.

TAN, M.; LE, Q. Efficientnet: Rethinking model scaling for convolutional neural networks. In: *Proceedings of the 36th International Conference on Machine Learning*. [S.l.: s.n.], 2019.

TAN, M.; LE, Q. V. Efficientnet: Rethinking model scaling for convolutional neural networks. *arXiv preprint arXiv:1905.11946*, 2019. Disponível em: <https://arxiv.org/abs/1905.11946>.

TAYLOR, L.; NITSCHKE, G. Improving deep learning with generic data augmentation. In: *2018 IEEE Symposium Series on Computational Intelligence (SSCI)*. [S.l.: s.n.], 2018. p. 1542–1547.

ULTRALYTICS. *Título do artigo ou documento*. 2023. <URLdodocumento>. Acesso em: 26 mar. 2025.

VARGAS, A. C. G.; PAES, A.; VASCONCELOS, C. N. Um estudo sobre redes neurais convolucionais e sua aplicação em detecção de pedestres. In: *SN. Proceedings of the XXIX Conference on Graphics, Patterns and Images*. [S.l.: s.n.], 2016. v. 1, n. 4. Acessado em: 19/09/2024.

WHITE, J.; POWER, S. D. k-fold cross-validation can significantly over-estimate true classification accuracy in common eeg-based passive bci experimental designs: An empirical investigation. *Sensors (Basel)*, v. 23, n. 13, p. 6077, Jul 2023.

WHO. *Guidelines for the Treatment of Malaria*. Second. [S.l.]: World Health Organization, Organização Pan-Americana da Saúde, 2020. ISBN 978-92-75-72289-3.

YAO, Y.; ROSASCO, L.; CAPONNETTO, A. Early stopping for model selection. *Constructive Approximation*, Springer, v. 26, n. 3, p. 289–315, 2007.

YU, H.; YANG, F.; RAJARAMAN, S.; ERSOY, I.; MOALLEM, G.; POOSTCHI, M.; PALANIAPPAN, K.; ANTANI, S.; MAUDE, R. J.; JAEGER, S. Malaria screener: a smartphone application for automated malaria screening. *BMC Infectious Diseases*, Springer Nature, v. 20, n. 1, p. 825, Nov 2020. Disponível em: <https://doi.org/10.1186/s12879-020-05453-1>.

ZAFAR, A.; AAMIR, M.; NAWI, N. M.; ARSHAD, A.; RIAZ, S.; ALRUBAN, A.; DUTTA, A. K.; ALMOTAIRI, S. A comparison of pooling methods for convolutional neural networks. *Applied Sciences*, v. 12, n. 17, 2022. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/12/17/8643>.

ZHANG, X.; XU, X.; LI, J.; SUN, J. Mixconv: Mixed depthwise convolutional kernels. *arXiv preprint arXiv:1812.06269*, 2018.

ZHANG, X.; ZHANG, J.; HAN, D. *et al. Improved Training of Convolutional Neural Networks by Revisiting the Initialization of ReLU Activations*. 2019. <https://arxiv.org/abs/1903.01053>. Acesso em: 27 mar. 2023.

ZHAO, O. S. *et al.* Convolutional neural networks to automate the screening of malaria in low-resource countries. *PeerJ*, v. 8, p. 9674, 2020.

ZHAO, R.; WANG, S.; LIU, F. Performance monitoring of deep learning models in clinical image analysis. *Medical Image Analysis*, v. 91, p. 103013, 2024.

ZHU, Y.; LI, X.; WANG, H. Monitoring training dynamics in deep learning models for medical image analysis. *IEEE Journal of Biomedical and Health Informatics*, v. 26, n. 5, p. 2145–2156, 2022.